

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP

DỰ BÁO TỶ GIÁ HỐI ĐOÁI DỰA VÀO
MÔ HÌNH HỌC SÂU LSTM

GIÁO VIÊN HƯỚNG DẪN: PGS.TS Dương Tuấn Anh

SINH VIÊN THỰC HIỆN: Trần Vĩnh Khiêm - 20DH112033

Nguyễn Lê Duy Minh - 20DH112081

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2024

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP

DỰ BÁO TỶ GIÁ HỐI ĐOÁI DỰA VÀO
MÔ HÌNH HỌC SÂU LSTM

GIÁO VIÊN HƯỚNG DẪN: PGS.TS Dương Tuấn Anh

SINH VIÊN THỰC HIỆN: Trần Vĩnh Khiêm - 20DH112033

Nguyễn Lê Duy Minh - 20DH112081

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2024

Lời cảm ơn

Sau một thời gian thực hiện đề án này, đến đây mọi công việc liên quan đến đề án đã hoàn tất. Trong suốt thời gian này, chúng tôi đã nhận được rất nhiều sự giúp đỡ. Ở phần đầu tiên của báo cáo, cho phép chúng tôi có đôi điều muốn bày tỏ đến những người chúng tôi vô cùng biết ơn.

Chúng tôi xin chân thành cảm ơn Khoa Công nghệ thông tin và Trường Đại học Ngoại ngữ và Tin học TP.HCM đã tạo điều kiện thuận lợi cho chúng tôi tìm hiểu, học tập và thực hiện bài báo cáo này.

Bên cạnh đó, chúng tôi xin chân thành cảm ơn giáo viên hướng dẫn là thầy PGS.TS Dương Tuấn Anh – người đã trực tiếp giúp đỡ, quan tâm, hướng dẫn chúng tôi hoàn thành tốt bài báo cáo này trong thời gian qua. Sau một thời gian thực hiện dự án này, thầy đã hướng dẫn và chỉ dẫn chúng tôi đúng hướng trong quá trình này. Nhờ sự hỗ trợ của thầy, chúng tôi đã nhận thức được những lợi ích và hạn chế của các phương pháp tiếp cận khác nhau và có thể dễ dàng khắc phục chúng.

Bước đầu đi vào thực tế của chúng tôi còn hạn chế và còn nhiều bỡ ngỡ nên không tránh khỏi những thiếu sót, chúng tôi rất mong nhận được những ý kiến đóng góp quý báu của thầy để kiến thức của chúng tôi trong lĩnh vực này được hoàn thiện hơn đồng thời có điều kiện bổ sung, nâng cao ý thức của mình. Chúng tôi xin chân thành cảm ơn!

Thành phố Hồ Chí Minh, 06/2024

Trần Vĩnh Khiêm

Nguyễn Lê Duy Minh

Lời cam đoan

Chúng tôi là Trần Vĩnh Khiêm MSSV: 20DH112033 và Nguyễn Lê Duy Minh MSSV: 20DH112081 sinh viên cử nhân học khoa Công nghệ thông tin, Đại học Ngoại ngữ & Tin học TP. HCM. Chúng tôi xin cam đoan luận văn tốt nghiệp " Dự báo tỷ giá hối đoái dựa vào mô hình học sâu LSTM" là kết quả tìm hiểu, nghiên cứu của chính bản thân của chúng tôi. Chúng tôi xin cam đoan:

1. Luận văn được thực hiện cho mục đích tìm hiểu và nghiên cứu ở bậc cử nhân.
2. Các công trình, bài báo tham khảo để xây dựng nền luận văn này đều đã được trích dẫn, tham khảo.
3. Tất cả các tài liệu đã được trích dẫn và có tính kế thừa từ các tạp chí và các công trình nghiên cứu đã được công bố.
4. Những công cụ, phần mềm cho quá trình thực hiện luận văn đều là phần mềm mã nguồn mở.
5. Hình ảnh và số liệu đã được trích dẫn nguồn tham khảo rõ ràng.
6. Kết quả nghiên cứu đã được trình bày trung thực dựa trên số liệu thực tế khi chạy chương trình.

MỤC LỤC

MỤC LỤC.....	i
DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ THUẬT NGỮ	iii
DANH SÁCH CÁC HÌNH VẼ ĐỒ THỊ.....	v
DANH SÁCH CÁC BẢNG	vii
Chương 1. MỞ ĐẦU.....	1
1.1 Giới thiệu đề tài	1
1.2 Mục tiêu nghiên cứu	1
1.3 Giới hạn đề tài.....	3
1.4 Kết quả đạt được	3
1.5 Cấu trúc báo cáo	4
Chương 2. CƠ SỞ LÝ THUYẾT	5
2.1 Tỷ giá ngoại tệ và dự báo tỷ giá ngoại tệ.....	5
2.2 Mạng nơ-ron nhân tạo (Artificial neural network – ANN).....	6
2.2.1 Cấu trúc một mạng MLP	9
2.2.2 Cách huấn luyện mạng nơ-ron cho bài toán dự báo dữ liệu chuỗi thời gian	14
2.2.3 Các vấn đề của mạng ANN	16
2.3 Mạng nơ-ron hồi quy (Recurrent Neural Network - RNN) và mạng nhớ ngắn-dài-hạn (Long Short Term Memory – LSTM).....	17
2.3.1 Học sâu	17
2.3.2 Mạng nơ-ron hồi quy	18
2.3.3 Mạng nơ-ron hồi quy hoạt động như thế nào	19
2.3.4 Các vấn đề hạn chế của RNN	22

2.3.5 Mạng nhớ ngắn-dài-hạn (Long Short Term Memory – LSTM).....	23
2.3.6 Huấn luyện mạng LSTM cho bài toán dự báo chuỗi thời gian	26
Chương 3. CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN	27
3.1 Phương pháp dự báo truyền thống.....	27
3.2 Phương pháp dự báo học máy	28
3.3 Phương pháp dự báo học sâu	29
3.4 Kết luận chương.....	30
Chương 4. PHƯƠNG PHÁP GIẢI QUYẾT VẤN ĐỀ.....	32
4.1 Phân tích dữ liệu	32
4.2 Đề xuất mô hình.....	36
4.3 Phương pháp xác định siêu tham số của mạng LSTM với giải thuật Grid Search	38
4.4 Kỹ thuật Dropout để giảm thiểu vấn đề quá khớp của mạng nơ-ron.....	39
Chương 5. HIỆN THỰC VÀ KẾT QUẢ THỰC NGHIỆM.....	40
5.1 Giới thiệu về thư viện Keras và Tensorflow	40
5.2 Tiêu chí đánh giá hiệu quả dự báo	41
5.3 Xác định kiến trúc và siêu tham số của ANN và LSTM	42
5.4 Kết quả thực nghiệm.....	47
Chương 6. KẾT LUẬN	56
6.1 Kết quả đạt được	56
6.2 Hướng nghiên cứu tiếp theo	56
TÀI LIỆU THAM KHẢO.....	58

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ THUẬT NGỮ

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt	Viết tắt
Time Series	Chuỗi thời gian	
Time Series Forecasting	Dự báo chuỗi thời gian	
Artificial Neural Network	Mạng nơ-ron nhân tạo	ANN
Long Short-time Memory	Mạng nhớ ngắn-dài-hạn	LSTM
Grid Search	Tìm kiếm lưới	
Non-parametric	Phi mô hình	
Restricted Boltzmann Machine	Máy Boltzmann giới hạn	RBM
Fully Convolutional Network	Mạng tích chập đầy đủ	FCN
Mean Square Error	Sai số bình phương trung bình	MSE
Mean Absolute Percentage Error	Sai số phần trăm tuyệt đối trung bình	MAPE
Training set	Tập huấn luyện	
Validation set	Tập kiểm định	
Testing set	Tập thử	
Back Propagation	Lan truyền ngược	
Auto Regressive Integrated Moving Average	Tự hồi quy tích hợp trung bình di động	ARIMA

Overfitting	Quá khớp	
Recurrent Neural Network	Mạng nơ-ron hồi quy	RNN
Input layer	Tầng nhập	
Hidden layer	Tầng ẩn	
Output layer	Tầng xuất	
Support Vector Machine	Máy vector hỗ trợ	SVM
Exponential Smoothing	Làm trơn hàm mũ	ES

DANH SÁCH CÁC HÌNH VẼ ĐỒ THỊ

Hình 2. 1: Mô hình mạng MLP với một tầng ẩn ([1])	8
Hình 2. 2: Quy tắc đánh chỉ số các trọng số ghép nối giữa các nơ-ron ([1]).....	9
Hình 2. 3: Cấu trúc mạng MLP với một tầng nhập, một tầng ẩn và một tầng xuất ([1])	9
Hình 2. 4: Đường biểu diễn của hàm sigmoid ([1]).....	11
Hình 2. 5: Đường biểu diễn của hàm tanh ([1]).....	12
Hình 2. 6: Đường biểu diễn của hàm truyền ReLU ([1]).....	13
Hình 2. 7: Huấn luyện mạng nơ-ron để dự báo cho một chuỗi thời gian ([1])	15
Hình 2. 8: Minh họa những điểm khác biệt giữa mô hình sâu và mô hình không sâu ([2]).....	18
Hình 2. 9: Cấu trúc mạng của mạng RNN ([2]).....	19
Hình 2. 10: Trạng thái khởi của LSTM ([2]).....	25
Hình 2. 11: Kiến trúc mô hình mạng của LSTM ([2])	25
Hình 2. 12: Minh họa quá trình huấn luyện mạng LSTM cho bài toán dự báo chuỗi thời gian sử dụng kỹ thuật cửa sổ trượt ([2])	26
Hình 4. 1: Dữ liệu USD/JPY chưa được xử lý.....	33
Hình 4. 2: Dữ liệu USD/JPY sau khi xử lý	33
Hình 4. 3: Đường biểu diễn của 4 tập dữ liệu tỷ giá ngoại tệ	34
Hình 4. 4: Histogram, Boxplot của AUD/USD.....	34
Hình 4. 5: Histogram, Boxplot của EUR/USD	35
Hình 4. 6: Histogram, Boxplot của GBP/USD	35
Hình 4. 7: Histogram, Boxplot của USD/JPY	36
Hình 4. 8: Sơ đồ tiến trình để dự báo tỷ giá ngoại tệ dựa vào mạng LSTM và mạng ANN	37
Hình 4. 9: Hình ảnh minh họa giải thuật Grid Search	38
Hình 5. 1: Tập AUD/USD được chia với tỉ lệ 80/20.....	43
Hình 5. 2: Tập EUR/USD được chia với tỉ lệ 80/20	43
Hình 5. 3: Tập GBP/USD được chia với tỉ lệ 80/20	44

Hình 5. 4: Tập USD/JPY được chia với tỉ lệ 80/20.....	44
Hình 5. 5: Kiến trúc chung của mạng ANN được dùng trong GridSearch	45
Hình 5. 6: Kiến trúc chung của mạng LSTM được dùng trong GridSearch.....	46
Hình 5. 7: Kết quả dự báo bằng ANN trên tập thử của AUD/USD	48
Hình 5. 8; Chi tiết kết quả dự báo bằng ANN trên tập thử của AUD/USD	48
Hình 5. 9: Kết quả dự báo bằng LSTM trên tập thử của AUD/USD	49
Hình 5. 10: Chi tiết kết quả dự báo bằng LSTM trên tập thử của AUD/USD	49
Hình 5. 11: Kết quả dự báo bằng ANN trên tập thử của EUR/USD	50
Hình 5. 12: Chi tiết kết quả dự báo bằng ANN trên tập thử của EUR/USD.....	50
Hình 5. 13: Kết quả dự báo bằng LSTM trên tập thử của EUR/USD	51
Hình 5. 14: Chi tiết kết quả dự báo bằng LSTM trên tập thử của EUR/USD	51
Hình 5. 15: Kết quả dự báo bằng ANN trên tập thử của GBP/USD.....	52
Hình 5. 16: Chi tiết kết quả dự báo bằng ANN trên tập thử của GBP/USD.....	52
Hình 5. 17: Kết quả dự báo bằng LSTM trên tập thử của GBP/USD.....	53
Hình 5. 18: Chi tiết kết quả dự báo bằng LSTM trên tập thử của GBP/USD.....	53
Hình 5. 19: Kết quả dự báo bằng ANN trên tập thử của USD/JPY	54
Hình 5. 20: Chi tiết kết quả dự báo bằng ANN trên tập thử của USD/JPY	54
Hình 5. 21: Kết quả dự báo bằng LSTM trên tập thử của USD/JPY	55
Hình 5. 22: Chi tiết kết quả dự báo bằng LSTM trên tập thử của USD/JPY	55

DANH SÁCH CÁC BẢNG

Bảng 5. 1: Kết quả GridSearch cho mạng ANN	46
Bảng 5. 2: Kết quả GridSearch cho mạng LSTM	47
Bảng 5. 3: Độ đo MSE và MAPE của 4 tập dữ liệu	47

Chương 1. MỞ ĐẦU

1.1 Giới thiệu đề tài

Nghiên cứu này tập trung vào việc phát triển và so sánh hiệu suất của hai phương pháp dự báo tỷ giá ngoại tệ sử dụng *mạng nơ-ron thông thường* (ANN) và *mạng nhớ ngắn-dài-hạn* (LSTM). Mục tiêu là cung cấp một phương pháp dự báo chính xác và tin cậy hơn cho tỷ giá ngoại tệ, hỗ trợ nhà giao dịch và nhà đầu tư trong việc ra quyết định đầu tư và giao dịch.

Trong phần nghiên cứu, chúng tôi sẽ thiết kế và tối ưu hóa cấu trúc mạng neural cho cả hai phương pháp, ANN và LSTM, dựa trên dữ liệu lịch sử tỷ giá ngoại tệ. Chúng tôi cũng sẽ áp dụng các kỹ thuật tiền xử lý dữ liệu và xử lý chuỗi cho mô hình LSTM để tối ưu hóa khả năng dự báo.

Sau đó, chúng tôi sẽ thực hiện các thử nghiệm và đánh giá hiệu suất dự báo của cả hai mô hình trên 4 bộ dữ liệu tỷ giá ngoại tệ AUD/USD, EUR/USD, GBP/USD và USD/JPY. Đánh giá sẽ được thực hiện dựa trên các tiêu chí như độ chính xác, độ ổn định và khả năng xử lý dữ liệu chuỗi.

Kết quả của nghiên cứu này sẽ cung cấp thông tin quan trọng về tính hiệu quả và ứng dụng của mỗi mô hình trong việc dự báo tỷ giá ngoại tệ, từ đó giúp cải thiện quyết định đầu tư và giao dịch trên thị trường ngoại hối.

1.2 Mục tiêu nghiên cứu

Mục tiêu chung:

- Mục tiêu chính của nghiên cứu là phát triển và so sánh hiệu suất của việc dự báo tỷ giá ngoại tệ bằng các mô hình *mạng nơ-ron nhân tạo* (ANN) và *mạng nhớ ngắn-dài-hạn* (LSTM). Nghiên cứu nhằm cung cấp một khung công cụ dự báo mạnh mẽ và đáng tin cậy cho dữ liệu tỷ giá ngoại tệ, hỗ trợ các nhà giao dịch và nhà đầu tư trong việc đưa ra quyết định thông minh trong giao dịch ngoại hối.

Mục tiêu cụ thể cho mô hình ANN:

- Xây dựng một mô hình mạng nơ-ron ANN có khả năng học và dự báo tỷ giá ngoại tệ.
- Tối ưu hóa cấu trúc của mạng ANN để tăng cường độ chính xác của dự báo và giảm thiểu sai số trong dự báo.
- Đánh giá hiệu suất của mô hình ANN trong việc dự báo tỷ giá ngoại tệ dựa trên dữ liệu lịch sử và điều kiện thị trường thời gian thực.

Mục tiêu cụ thể cho mô hình LSTM:

- Tận dụng khả năng xử lý chuỗi của mạng nơ-ron học sâu LSTM trong việc dự báo tỷ giá ngoại tệ, đặc biệt là trong việc nắm bắt các phụ thuộc thời gian và mô hình các mẫu dữ liệu về tiền tệ.
- Thiết kế một kiến trúc mạng LSTM phù hợp, kết hợp các kỹ thuật tiền xử lý và xử lý dữ liệu để tăng cường độ chính xác của mô hình.
- Đánh giá hiệu suất của mô hình LSTM trong việc dự báo tỷ giá ngoại tệ so với các mô hình ANN truyền thống và trên dữ liệu thị trường tiền tệ thực tế.

Phân tích so sánh:

- Thực hiện phân tích so sánh giữa hiệu suất dự báo của các mô hình ANN và LSTM.
- So sánh độ chính xác, ổn định và hiệu quả tính toán của cả hai mô hình trong việc dự báo tỷ giá ngoại tệ.
- Xác định các ưu và nhược điểm của mỗi mô hình và cung cấp thông tin để hiểu rõ về tính ứng dụng và sự phù hợp của chúng trong giao dịch và quyết định đầu tư tiền tệ.
- Thông qua việc đạt được các mục tiêu nêu trên, nghiên cứu nhằm đóng góp vào sự phát triển và tiến bộ của các phương pháp dự báo trong lĩnh vực thị trường ngoại hối. Mục tiêu là cung cấp các công cụ dự báo mạnh mẽ và đáng tin cậy, từ đó giúp cải thiện quyết định đầu tư và giao dịch của các nhà giao

dịch và nhà đầu tư trên thị trường ngoại hối. Đồng thời, nghiên cứu cũng nhằm mục đích nâng cao hiệu quả và tính khả thi của thị trường ngoại hối.

1.3 Giới hạn đề tài

Chúng tôi sẽ tiến hành so sánh kết quả dự báo của mạng nơ-ron ANN và mạng nơ-ron học sâu LSTM, còn có rất nhiều mô hình học máy và học sâu khác nhau nhưng trong đề tài này chúng tôi sẽ tập trung vào ANN và LSTM.

Kết quả dự báo của cả hai mô hình đều là một bước, nghĩa là chúng tôi sử dụng dữ liệu trong quá khứ để dự đoán cho ngày tiếp theo.

Chúng tôi chưa áp dụng mô hình dự báo này trên dữ liệu thời gian thực. Cụ thể, chúng tôi chưa sử dụng dữ liệu của ngày hiện tại để dự báo giá trị cho N ngày trong tương lai kể từ khi mô hình hoàn thành, và so sánh kết quả dự báo này với dữ liệu thực tế của N ngày sau đó.

1.4 Kết quả đạt được

Sau khi tiến hành so sánh giữa mô hình mạng LSTM và mô hình mạng ANN để dự báo trên 4 bộ dữ liệu mẫu tỷ giá ngoại tệ, kết quả cho thấy mô hình LSTM đã đạt được hiệu suất tốt hơn đáng kể so với mô hình ANN. Cụ thể, các chỉ số đánh giá như *Mean Squared Error* (MSE) và *Mean Absolute Percentage Error* (MAPE) của mô hình LSTM đều thấp hơn so với mô hình ANN, cho thấy khả năng dự báo chính xác và độ chính xác cao hơn của mô hình LSTM trong việc dự báo tỷ giá ngoại tệ.

Đặc biệt, mô hình LSTM đã phát hiện và học được các mẫu và mối quan hệ phức tạp trong dữ liệu chuỗi thời gian tỷ giá ngoại tệ một cách hiệu quả. Khả năng ghi nhớ dài hạn và xử lý thông tin ngắn hạn của mô hình LSTM đã giúp nắm bắt được các biến động và biến thiên *không có tính dừng* (non-stationary) của chuỗi thời gian tỷ giá ngoại tệ, từ đó cải thiện khả năng dự báo và đưa ra các dự báo chính xác về xu hướng giá trị tương lai.

Sự tối ưu của mô hình mạng nơ-ron học sâu LSTM không chỉ thể hiện qua hiệu suất dự báo tốt hơn mà còn qua khả năng xử lý và học được các mẫu phức tạp từ dữ

liệu chuỗi thời gian một cách tự nhiên và hiệu quả. Kết quả này đề xuất rằng mô hình LSTM là một lựa chọn lý tưởng cho các bài toán dự báo tỷ giá ngoại tệ, đặc biệt là khi đối mặt với dữ liệu có tính chất chuỗi thời gian biến động và không có tính dừng.

1.5 Cấu trúc báo cáo

Cấu trúc báo cáo được tổ chức như sau:

- Chương 1 – Mở đầu: nhằm giới thiệu tổng quan về bài toán dự báo tỷ giá ngoại tệ, phương pháp giải quyết và những kết quả đạt được.
- Chương 2 - Cơ sở lý thuyết: trình bày những lý thuyết liên quan được sử dụng trong đề tài nghiên cứu: dự báo tỷ giá ngoại tệ, mạng nơ-ron ANN truyền thống và mạng nơ-ron học sâu LSTM.
- Chương 3 - Các công trình nghiên cứu liên quan: bao gồm các công trình nghiên cứu liên quan đến bài toán dự báo chuỗi thời gian nói chung và dự báo tỷ giá ngoại tệ nói riêng.
- Chương 4 - Phương pháp giải quyết vấn đề: phân tích đặc điểm của dữ liệu và trình bày cụ thể mô hình đề xuất và cách thức mô hình hoạt động.
- Chương 5 – Hiện thực và kết quả thực nghiệm: là kết quả đánh giá của các phương pháp đề xuất và so sánh chúng với nhau trên 4 bộ dữ liệu mẫu tỷ giá ngoại tệ.
- Chương 6 - Kết luận: nêu ra các kết luận được đúc kết trong quá trình nghiên cứu và hướng phát triển tiếp theo trong tương lai.
- Tài liệu tham khảo.

Chương 2. CƠ SỞ LÝ THUYẾT

Chương này sẽ giải thích về chuỗi thời gian ở mục 2.1, tiếp theo trình bày chi tiết lý thuyết về các kiến trúc mạng nơ-ron được chúng tôi áp dụng để nghiên cứu cùng nhằm xây dựng các mô hình dự báo trong phần 2.2, 2.3.

2.1 Tỷ giá ngoại tệ và dự báo tỷ giá ngoại tệ

Dự báo tỷ giá ngoại tệ là quá trình ước lượng giá trị của một đơn vị tiền tệ so với đơn vị tiền tệ khác trong tương lai. Đây là một lĩnh vực quan trọng trong lĩnh vực tài chính và kinh tế, có ảnh hưởng lớn đến các quyết định đầu tư, kinh doanh quốc tế và chính sách tiền tệ của một quốc gia. Mục tiêu của việc dự báo tỷ giá ngoại tệ là cung cấp thông tin cho các nhà đầu tư, doanh nghiệp và chính phủ để họ có thể đưa ra quyết định hiệu quả trong việc quản lý rủi ro và tối ưu hóa lợi nhuận.

Trong quá khứ, tỷ giá ngoại tệ được xác định bởi cân đối thanh toán, chỉ là sự liệt kê các giao dịch quốc tế của một quốc gia. Tuy nhiên, các yếu tố như tỷ lệ lãi suất và cung cầu địa phương và quốc tế đã trở nên quan trọng hơn về sau. Hệ thống tỷ giá ngoại tệ cố định đã được thay thế bằng hệ thống tỷ giá nổi từ năm 1973. Sự mở cửa thêm nhiều giao dịch cũng đang được thảo luận. Nhờ vào sự ra đời của tỷ giá nổi và sự mở rộng của thị trường toàn cầu, thị trường tỷ giá ngoại tệ đã trải qua sự tăng trưởng đáng kể. Tỷ giá ngoại tệ đóng vai trò quan trọng trong việc điều chỉnh thị trường ngoại tệ và thị trường nhập khẩu - xuất khẩu hàng hóa. Tuy nhiên, việc dự báo chính xác tỷ giá ngoại tệ là một yếu tố quan trọng cho sự thành công của nhiều doanh nghiệp và tổ chức tài chính.

Dự báo giá trị tương lai của một tỷ giá ngoại tệ dường như là khả năng mà mọi người đều muốn sở hữu, đặc biệt khi nó có thể mang lại lợi ích. Điều này có thể là lý do tại sao việc dự báo tỷ giá ngoại tệ lại trở nên phổ biến đến vậy. Mặc dù những người ủng hộ giả thuyết thị trường hiệu quả tin rằng việc dự báo biến động tỷ giá ngoại tệ là không thể, một số lượng đáng kể các nhà nghiên cứu khẳng định rằng một số mô hình là chấp nhận được miễn là chúng có thể tạo ra dự báo với độ chính xác

đáng kể. Mô hình phổ biến nhất được sử dụng là *mạng nơ-ron nhân tạo* (ANN). Trong những năm gần đây, một số nhà nghiên cứu đã đề xuất rằng *mạng nhớ ngắn-dài-hạn* (LSTM) có độ chính xác dự báo cao hơn. Báo cáo này sẽ tập trung vào nguyên tắc xây dựng của hai mô hình này và sự khác biệt trong kết quả dự báo về tỷ giá ngoại tệ của cùng một cặp tiền tệ trong một khoảng thời gian nhất định, với hy vọng mang lại tiện lợi cho các nhà nghiên cứu sau này.

Trong nghiên cứu về dự báo tỷ giá ngoại tệ, một trong những vấn đề quan trọng là chọn lựa phương pháp dự báo hiệu quả nhất. Trong thời gian gần đây, *mạng nơ-ron nhân tạo* (ANN) và biến thể học sâu của nó như LSTM đã thu hút sự quan tâm đặc biệt trong việc dự báo tỷ giá ngoại tệ, nhờ vào khả năng của chúng trong việc xử lý các biến động không tuyến tính trên thị trường tài chính.

Mô hình *ARIMA* (Auto Regressive Integrated Moving Average), mặc dù là một công cụ phổ biến cho dự báo chuỗi thời gian, thường không hiệu quả trong dự báo tỷ giá ngoại tệ do hạn chế của nó trong việc xử lý chuỗi thời gian có biến động phức tạp và không tuyến tính.

Trong khi đó, ANN là một mô hình *dựa trên dữ liệu* (data-driven), không đặt ra giả định trước và được sử dụng rộng rãi trong nhiều lĩnh vực bao gồm tài chính và kinh doanh. LSTM, một biến thể học sâu của ANN, được biết đến với khả năng phân tích và dự báo các chuỗi thời gian có tính chất phức tạp và không tuyến tính.

Trong phần tiếp theo của chương này, chúng tôi sẽ tập trung vào việc thảo luận về cơ sở lý thuyết của các phương pháp dự báo sẽ được sử dụng. Điều này nhằm cung cấp thông tin hữu ích cho các nghiên cứu viên sau này trong việc lựa chọn phương pháp dự báo phù hợp nhất cho mục tiêu của mình.


2.2 Mạng nơ-ron nhân tạo (Artificial neural network – ANN)

Qua quá trình nghiên cứu về não bộ, các nhà khoa học nhận thấy rằng hệ thần kinh của con người có thể mô tả là một hệ thống gồm 3 phần chính bao gồm các *cảm biến* (receptors), *bộ não* (brain, neuron nets) và các *cơ quan thực hiện* (effectors). Các

cảm biến thu thập các ảnh hưởng từ môi trường bên ngoài, chuyển đổi chúng thành tín hiệu điện và truyền đến bộ não. Tại đó, các tín hiệu sẽ được phân tích, xử lý và dẫn đến các quyết định điều khiển. Những tín hiệu điều khiển này sau đó được chuyển đến các cơ quan thực hiện để thực hiện hành động. Trong đó, nơ-ron là phần cơ bản của hệ thần kinh.

Mạng nơ-ron là một loại mô hình phi tuyến tính có thể xấp xỉ bất kỳ hàm phi tuyến nào với một độ chính xác tùy ý và có tiềm năng được sử dụng như các công cụ dự báo trong nhiều lĩnh vực. Kiến trúc mạng nơ-ron phổ biến nhất là mạng nơ-ron lan truyền nhiều tầng. Nó bao gồm một tầng đầu vào, một tầng đầu ra và một hoặc nhiều tầng trung gian được gọi là tầng ẩn. Tất cả các nút ở mỗi tầng đều được kết nối với mỗi nút ở tầng trên bằng các trọng số gọi là trọng số kết nối. Một thuật toán huấn luyện được sử dụng để đạt được một tập hợp trọng số giảm thiểu sự khác biệt giữa giá trị mục tiêu và giá trị đầu ra thực tế được tạo ra bởi mạng. Về lý thuyết, chúng ta có thể xây dựng một mạng với cách kết nối tùy ý. Tuy nhiên, phổ biến nhất là *mạng truyền thẳng* (multilayer perceptron - MLP). Mạng MLP là một mạng truyền thẳng với các khối cơ bản là các nơ-ron McCulloch-Pitts. Ngoài ra, mạng MLP còn có một số yêu cầu về cấu trúc của mạng:

- Các nơ-ron được tổ chức thành các *tầng* (layer), trong đó mạng bao gồm một *tầng đầu vào* (input layer) để nhận tín hiệu đầu vào, một *tầng đầu ra* (output layer) để đưa ra tín hiệu đầu ra, và có thể có một số tầng trung gian gọi là các *tầng ẩn* (hidden layer). (Xem hình 2.1)
- Không có kết nối giữa các nơ-ron trên cùng một tầng, mà chỉ có kết nối giữa các nơ-ron của hai tầng liền kề. Các kết nối đều có hướng từ tầng đầu vào đến tầng đầu ra (mạng truyền thẳng).
- Các nơ-ron trên cùng một tầng sẽ có cùng một *hàm truyền* (transfer function).




Hình 2. 1: Mô hình mạng MLP với một tầng ẩn ([1])

Về mặt lý thuyết, ta có thể xây dựng mạng MLP với số lượng tầng ẩn tùy ý, tuy nhiên các nghiên cứu đã chứng minh được rằng ta chỉ cần sử dụng tối đa hai lớp ẩn là có thể mô hình hóa một hàm phi tuyến với độ chính xác tùy chọn.

Vì vậy trong thực tế ta thường chỉ các mạng không có hoặc có một hay hai tầng ẩn. Trong số đó phần lớn chỉ dùng mạng có một tầng ẩn do mạng không có tầng ẩn thì quá đơn giản, còn mạng có hai tầng ẩn trở nên lại quá phức tạp. Vì vậy trong các vấn đề được trình bày tiếp theo dưới đây sẽ sử dụng mạng có một tầng ẩn, các công thức cho mạng với cấu trúc khác có thể dễ dàng phát triển một cách tương tự.


Để thuận tiện cho việc theo dõi, trong các công thức của mạng MLP, ta có quy ước về đánh chỉ số các trọng số kết nối giữa các phần tử của mạng như hình 2.2: nếu phần tử nguồn có chỉ số là i và phần tử gốc có phần tử là j thì trọng số kết nối giữa hai phần tử đó sẽ có chỉ số là ij .



Hình 2. 2: Quy tắc đánh chỉ số các trọng số ghép nối giữa các nơ-ron ([1])

2.2.1 Cấu trúc một mạng MLP

Cấu trúc một mạng MLP với một tầng ẩn, trong đó mạng có N đầu vào, M nơ-ron trên tầng ẩn và K đầu ra. Như hình 2.3, nếu ký hiệu chung các trọng số kết nối giữa tầng đầu vào và tầng ẩn là W_{ij} thì ta có $i = 1, 2, \dots, M; j = 0, 1, 2, \dots, N$. Nếu ký hiệu các trọng số kết nối giữa tầng ẩn và tầng đầu ra là V_{jk} thì ta có $j = 1, 2, \dots, M; k = 0, 1, 2, \dots, K$. Tổng hợp lại ta có các giá trị W_{ij} tạo thành $W \in R^{M \times (N+1)}$ là ma trận các hệ số kết nối giữa tầng đầu vào và tầng ẩn, các giá trị V_{jk} tạo thành $V \in R^{K \times (M+1)}$ là ma trận các hệ số kết nối giữa tầng ẩn và tầng đầu ra.



Hình 2. 3: Cấu trúc mạng MLP với một tầng nhập, một tầng ẩn và một tầng xuất ([1])

Mạng MLP với một tầng ẩn có thể được đặc trưng bởi các thông số sau:

- Bộ ba (N, M, K) , trong đó N – số nơ-ron đầu vào, M – số nơ-ron thuộc tầng ẩn, K – số nơ-ron ở tầng đầu ra.
- Các hàm truyền: f_1 của tầng ẩn và f_2 của tầng đầu ra.
- Ma trận trọng số W kết nối giữa tầng đầu vào và tầng ẩn, ma trận trọng số kết nối V giữa tầng ẩn và tầng đầu ra.

Khi đó, với véc tơ đầu vào $x = [x_1, x_2, \dots, x_N] \in R^N$ (đầu vào phân cực cố định $x_0 = 1$), ta có đầu ra được xác định tuần tự theo chiều *lan truyền thuận* (forwardpropagation) như sau:

1. Tính tổng các kích thích đầu vào của nơ-ron ẩn thứ i (cho $i = 1, 2, \dots, M$):

$$u_i = \sum_{j=0}^N x_j W_{ij} \quad (1)$$

2. Tính đầu ra của nơ-ron ẩn thứ i (cho $i = 1, 2, \dots, M$):

$$v_i = f_1(u_i) \quad (2)$$

3. Tính tổng kích thích đầu vào của nơ-ron đầu ra thứ i (cho $i = 1, 2, \dots, K$):

$$g_i = \sum_{j=0}^M v_j V_{ij} \quad (3)$$

4. Cuối cùng ta có đầu ra thứ i của mạng (cho $i = 1, 2, \dots, K$) sẽ bằng:

$$y_i = f_2(g_i) \quad (4)$$

Tổng hợp lại ta có *hàm truyền đạt* của mạng MLP là một *hàm phi tuyến* theo công thức phụ thuộc sau:


$$y_i = f_2(g_i) = f_2 \left(\sum_{j=0}^M v_j V_{ij} \right) = f_2 \left(\sum_{j=0}^M f_1(u_j) V_{ij} \right) = f_2 \left(\sum_{j=0}^M \left[f_1 \left(\sum_{k=0}^N x_k W_{jk} \right) \right] V_{ij} \right) \quad (5)$$

Hàm truyền *sigmoid*:

- Giống như perceptron, đơn vị *sigmoid* trước tiên tính tổ hợp tuyến tính của các giá trị đầu vào và áp dụng một hàm ngưỡng lên kết quả đó. Tuy nhiên trong trường hợp của đơn vị *sigmoid*, đầu ra của hàm ngưỡng là một hàm liên tục theo giá trị đầu vào của nó. Hàm này còn được gọi là *hàm truyền* (transfer function). Hàm truyền thông dụng nhất là hàm *sigmoid*. Hàm *sigmoid* $\sigma(x)$ được định nghĩa như sau:

$$\sigma(x) = 1/(1+e^{-x}) \quad (6)$$

- Hàm *sigmoid* $\sigma(x)$ còn được gọi là hàm *logistic*. Đầu ra của hàm này trong tầm từ 0 đến 1, tăng dần một cách đơn điệu theo giá trị đầu vào. Hình 2.4 vẽ đường biểu diễn của hàm *sigmoid*.



Hình 2. 4: Đường biểu diễn của hàm *sigmoid* ([1])

- Đạo hàm của hàm *sigmoid* có một tính chất đặc biệt như sau:

$$\sigma'(x) = \sigma(x)(1-\sigma(x)) \quad (7)$$


- Ta có thể áp dụng nguyên tắc *suy giảm độ dốc* để huấn luyện mạng nhiều tầng kết nối nhiều đơn vị *sigmoid*. Giải thuật huấn luyện này có tên là giải thuật *lan truyền ngược* (backpropagation).

Hàm truyền *tanh*:

- Bên cạnh hàm truyền *sigmoid*, chúng ta có thể sử dụng một hàm truyền khác, đó là hàm *tanh* được định nghĩa như sau:

$$\tanh(x) = (e^x - e^{-x}) / (e^x + e^{-x}) \quad (8)$$

- Trị xuất ra của hàm này trong tầm từ -1 đến 1, gia tăng một cách đơn điệu theo giá trị đầu vào. Hình 2.5 vẽ đường biểu diễn của hàm tanh.



Hình 2. 5: Đường biểu diễn của hàm *tanh* ([1])

- Đạo hàm của hàm tanh có một tính chất đặc biệt như sau:

$$\tanh'(x) = 1 - [\tanh(x)]^2 \quad (9)$$


Hàm truyền *ReLU*:

- Hàm truyền *ReLU* (Rectified Linear Unit) gần đây được sử dụng rộng rãi trong mạng nơ-ron ANN, mạng nơ-ron hồi quy RNN và cả những mạng nơ-ron học sâu.

- Hàm truyền *ReLU* có tính đơn giản, được định nghĩa như sau:

$$\sigma(x) = \max(0, x) \quad (10)$$

- Đường biểu diễn của hàm truyền này được minh họa trong hình 2.6.



Hình 2. 6: Đường biểu diễn của hàm truyền *ReLU* ([1])

- Đạo hàm của hàm *ReLU* bằng không tại các điểm âm, bằng một tại các điểm dương. Hàm truyền *ReLU* được chứng minh giúp việc huấn luyện các mạng nơ-ron đa tầng nhanh hơn nhiều so với hàm *tanh*. Với các mạng sử dụng hàm kích hoạt *ReLU*, hàm mất mát giảm rất nhanh sau một vài epoch đầu tiên.

Quá trình điều chỉnh các thông số của mạng để thích nghi với một bộ dữ liệu cụ thể được gọi là quá trình học của mạng *MLP*, hay còn được biết đến như quá trình huấn luyện mạng *MLP* theo một bộ dữ liệu mẫu cho trước. Trong khi các thông số cấu trúc như số tầng nơ-ron, các hàm kích hoạt của mỗi tầng, số nơ-ron trên mỗi tầng thường được chọn thông qua thực nghiệm hoặc bằng cách thử nghiệm các giá trị rời rạc nhất định, các trọng số kết nối giữa các nơ-ron có thể được điều chỉnh thông qua thuật toán *lan truyền ngược* (backpropagation).

Giải thuật này dựa trên tỷ lệ lỗi của *hàm mất mát* (loss function) thu được trong các vòng lặp trước đó để tinh chỉnh trọng số của mô hình. Việc điều chỉnh trọng số

sao cho tỷ lệ lỗi giảm đối với mạng sẽ làm cho mô hình trở nên đáng tin cậy hơn bằng cách tăng tính tổng quát của nó.

Đối với quá trình này, các phương pháp tối ưu hóa như *suy giảm độ dốc* (gradient descent) và các biến thể của nó thường được sử dụng để cực tiểu hóa hàm mất mát. Các thuật toán tối ưu hóa này sẽ điều chỉnh từng trọng số của mạng một cách đồng nhất và liên tục để tìm ra các giá trị trọng số tối ưu nhất để mô hình có thể dự báo chính xác nhất trên dữ liệu mới.

2.2.2 Cách huấn luyện mạng nơ-ron cho bài toán dự báo dữ liệu chuỗi thời gian


Mạng nơ-ron thường được dùng cho bài toán dự báo chuỗi thời gian, trong đó *mạng nơ-ron truyền thẳng* (feed-forward networks) thường kết hợp với *cửa sổ trượt* (sliding window) để huấn luyện mạng nơ-ron thích hợp với chuỗi thời gian đầu vào.

Mạng nơ-ron làm việc với chuỗi thời gian $X_1, \dots, X_n$ dưới dạng thức nhiều lần ánh xạ một *vector đầu vào* (input vector) thành một *trị đầu ra* (output value).

Một số điểm dữ liệu kế cận nhau của chuỗi thời gian nằm dưới cửa sổ nhập kích thước s ($X_{t-s+1}, X_{t-s+2}, \dots, X_t$) được đưa vào tại các đơn vị đầu vào của tầng nhập.

Kích thước s của cửa sổ nhập tương ứng với số đơn vị đầu vào của mạng nơ-ron.

Trên bước truyền thẳng tới, các giá trị đầu vào này được lan truyền qua tầng ẩn và đi đến một đơn vị đầu ra. Sai số được dùng cho quá trình huấn luyện lan truyền ngược được tính bằng cách so sánh giá trị tại đơn vị đầu ra với giá trị của chuỗi thời gian tại thời điểm $t+1$. Sai số này được truyền ngược về các đường nối giữa tầng xuất và tầng ẩn và các đường nối giữa tầng ẩn và tầng nhập. Sau khi tất cả các trọng số được cập nhật ứng với một lần duyệt qua mọi điểm trong chuỗi thời gian, giải thuật huấn luyện lan truyền ngược đã hoàn tất một lượt lặp. Hình 2.7 minh họa cách huấn luyện mạng nơ-ron để dự báo một chuỗi thời gian sử dụng kỹ thuật cửa sổ trượt.



Hình 2. 7: Huấn luyện mạng nơ-ron để dự báo cho một chuỗi thời gian ([1])

Giả sử cho một chuỗi thời gian gồm 12 điểm dữ liệu như sau:

$$X = \langle 2, 3, 5, 4, 6, 8, 5, 7, 11, 13, 9, 7 \rangle$$

Nếu chúng ta dùng một cửa sổ trượt với kích thước $s = 7$, các vector đầu vào được rút trích từ chuỗi thời gian X để đưa vào huấn luyện mạng nơ-ron sẽ là:

- $X_1 = \langle 2, 3, 5, 4, 6, 8, 5 \rangle$
- $X_2 = \langle 3, 5, 4, 6, 8, 5, 7 \rangle$
- $X_3 = \langle 5, 4, 6, 8, 5, 7, 11 \rangle$
- $X_4 = \langle 4, 6, 8, 5, 7, 11, 13 \rangle$

- $X_5 = \langle 6, 8, 5, 7, 11, 13, 9 \rangle$
- $X_6 = \langle 8, 5, 7, 11, 13, 9, 7 \rangle$

Tóm lại, từ chuỗi thời gian X được cho, chúng ta rút trích được $n - s + 1 = 12 - 7 + 1 = 6$ vector đầu vào để đưa vào huấn luyện mạng nơ-ron.

Quá trình huấn luyện mạng nơ-ron với giải thuật lan truyền ngược đòi hỏi phải duyệt qua toàn bộ dữ liệu nhập nhiều *lượt lặp* (epoch). Thí dụ, mạng nơ-ron có thể phải lặp từ 60 đến 138 epochs.

Mạng nơ-ron có thể dự báo chuỗi thời gian với hiệu quả dự báo cao vì chúng có thể nắm bắt các đặc tính phi tuyến của chuỗi thời gian.

2.2.3 Các vấn đề của mạng ANN

Mạng nơ-ron nhân tạo (Artificial Neural Networks - ANN) là một công cụ mạnh mẽ trong học máy, nhưng cũng có những hạn chế:

1. Khả năng xử lý dữ liệu cấu trúc thấp: ANN không hiệu quả khi xử lý dữ liệu cấu trúc thấp như ảnh, âm thanh hoặc văn bản. Trong các tác vụ này, cần phải sử dụng các kiến trúc mạng *học sâu* (deep learning) hoặc mạng nơ-ron chuyên biệt như *mạng nơ-ron tích hợp* (Convolutional Neural Networks - CNNs) hoặc *mạng nơ-ron hồi quy* (Recurrent Neural Networks - RNNs).
2. Yêu cầu lượng dữ liệu lớn: ANN yêu cầu một lượng lớn dữ liệu huấn luyện để đạt được hiệu suất tốt. Nếu lượng dữ liệu huấn luyện ít, mô hình ANN có thể bị *quá khớp* (overfitting), tức là không thể tổng quát hóa tốt cho dữ liệu mới.
3. Khả năng diễn giải kém: ANN thường được xem như một mô hình "hộp đen" vì khó khăn trong việc diễn giải kết quả dự báo của nó. Điều này có thể làm giảm niềm tin từ phía người dùng hoặc các bên liên quan.
4. Cần nhiều tài nguyên tính toán: Huấn luyện và triển khai ANN đòi hỏi nhiều tài nguyên tính toán, đặc biệt là đối với các mạng lớn và sâu. Điều này có thể làm tăng chi phí tính toán và đưa ra các yêu cầu về cơ sở hạ tầng tính toán.

5. Nhạy cảm với các siêu tham số: ANN có nhiều *siêu tham số* (hyper-parameters) cần được điều chỉnh như số lượng tầng, số lượng nơ-ron trong mỗi tầng, hàm kích hoạt, v.v. Việc tinh chỉnh các siêu tham số này có thể là một quá trình thử nghiệm tốn thời gian và công sức.
6. Khó khăn trong việc huấn luyện mạng sâu: Đối với các *ANN sâu* (Deep Neural Networks), việc huấn luyện có thể gặp phải các vấn đề như độ dốc biến mất, độ dốc cực lớn và thời gian huấn luyện lâu dài.

Mặc dù có những hạn chế, ANN vẫn là một công cụ quan trọng và mạnh mẽ trong lĩnh vực học máy và có thể được sử dụng hiệu quả trong nhiều ứng dụng khác nhau khi được áp dụng đúng cách.

2.3 Mạng nơ-ron hồi quy (Recurrent Neural Network - RNN) và mạng nhớ ngắn-dài-hạn (Long Short Term Memory – LSTM)

2.3.1 Học sâu

Học sâu (deep learning) là một trong những kỹ thuật học máy trong đó nhiều *tầng* (layer) của các chặng xử lý thông tin với kiến trúc phân cấp được tận dụng để *học các đặc trưng* (feature learning) và phân lớp mẫu.

Một mô hình kiến trúc sâu bao gồm nhiều tầng kết hợp các *tác vụ phi tuyến* (non-linear operation) tại các đơn vị xuất của nó.


Ý tưởng chính là có những *đơn vị phát hiện đặc trưng* (feature detector unit) tại mỗi tầng mà rút trích dần và tinh chế những đặc trưng tinh tế và bất biến từ những dữ liệu thô ban đầu.

Các tầng thấp rút trích những đặc trưng đơn giản và những đặc trưng này được nạp qua những tầng cao hơn để phát hiện những đặc trưng phức tạp hơn.

Ngược lại những *mô hình không sâu* (shallow models), như các mạng nơ-ron một tầng ẩn, chỉ gồm một ít tầng chủ yếu ánh xạ những đặc trưng ban đầu của dữ liệu nhập sang một không gian đặc trưng của ứng dụng cần xử lý.

Hình 2.8 minh họa sự khác biệt giữa mô hình học sâu và mô hình không sâu.

Các kiến trúc học sâu làm việc hiệu quả và hữu hiệu gấp bội lần so với các kiến trúc không sâu.



Hình 2. 8: Minh họa những điểm khác biệt giữa mô hình sâu và mô hình không sâu ([2])


2.3.2 Mạng nơ-ron hồi quy

Mạng nơ-ron hồi quy (RNN) là một mô hình học sâu được đào tạo để xử lý và chuyển đổi đầu vào dữ liệu tuần tự thành đầu ra dữ liệu tuần tự cụ thể. *Dữ liệu tuần tự* (Sequential data) là dữ liệu, chẳng hạn như từ, câu trong văn bản hoặc dữ liệu chuỗi thời gian, trong đó các thành phần tuần tự tương quan với nhau dựa trên ngữ nghĩa phức tạp và quy tắc cú pháp. RNN là một hệ thống phần mềm gồm nhiều thành phần được kết nối với nhau theo cách con người thực hiện chuyển đổi dữ liệu tuần tự, chẳng hạn như dịch văn bản từ ngôn ngữ này sang ngôn ngữ khác. Phần lớn RNN đang được thay thế bằng *trí tuệ nhân tạo* (Artificial Intelligence - AI) dựa trên công

cụ biến đổi và các *mô hình ngôn ngữ lớn* (Large Language Model - LLM), hiệu quả hơn nhiều trong việc xử lý dữ liệu tuần tự.

Cấu trúc của một RNN bao gồm một loạt các *đơn vị thời gian* (time steps) liên kết với nhau theo một chuỗi. Mỗi đơn vị thời gian tương ứng với một bước trong chuỗi dữ liệu. Mỗi đơn vị thời gian có một *đầu vào* (input), một *trạng thái ẩn* (hidden state), và một *đầu ra* (output). (Xem hình 2.9)

- x_t là *đầu vào* (input).
- A là *trạng thái ẩn* (hidden state).
- h_t là *đầu ra* (output).



Hình 2. 9: Cấu trúc mạng của mạng RNN ([2])

Trong quá trình huấn luyện, RNN sẽ được cung cấp một chuỗi dữ liệu đầu vào, và mục tiêu là dự báo đầu ra cho mỗi bước thời gian dựa trên thông tin từ các bước trước đó. Trạng thái ẩn của mỗi đơn vị thời gian đóng vai trò quan trọng trong việc truyền thông tin từ các bước trước đó đến các bước sau đó.

2.3.3 Mạng nơ-ron hồi quy hoạt động như thế nào

RNN được tạo thành từ các nơ-ron: các nút xử lý dữ liệu kết hợp cùng nhau để thực hiện các tác vụ phức tạp. Các nơ-ron được tổ chức dưới dạng tầng đầu vào, đầu ra và ẩn. Tầng đầu vào nhận thông tin để xử lý và tầng đầu ra cung cấp kết quả. Quá trình xử lý dữ liệu, phân tích và dự báo diễn ra trong tầng ẩn.

RNN hoạt động bằng cách lần lượt truyền dữ liệu tuần tự nhận được đến các tầng ẩn. Tuy nhiên, RNN cũng có quy trình làm việc tự lặp lại hay hồi quy: tầng ẩn có thể ghi nhớ và sử dụng các đầu vào trước đó cho các dự báo trong tương lai trong một thành phần bộ nhớ ngắn hạn. Quy trình này sử dụng đầu vào hiện tại và bộ nhớ đã lưu trữ để dự báo chuỗi tiếp theo.

Ví dụ: hãy xem xét chuỗi: Apple is red (Táo màu đỏ). Bạn muốn RNN dự báo red (màu đỏ) khi nhận được chuỗi đầu vào Apple is (Táo màu). Khi xử lý từ Apple (Táo), lớp ẩn sẽ lưu trữ một bản sao trong bộ nhớ. Tiếp theo, khi thấy từ is (màu), lớp ẩn gọi lại Apple (Táo) từ bộ nhớ của mình và hiểu toàn bộ chuỗi: Apple is (Táo màu) là ngữ cảnh. Sau đó, lớp ẩn có thể dự báo red (màu đỏ) để cải thiện độ chính xác. Do đó, RNN trở nên hữu ích trong nhận dạng giọng nói, dịch máy và các tác vụ lập mô hình ngôn ngữ khác.

Các kỹ sư *học máy* (Machine Learning - ML) sẽ đào tạo các mạng nơ-ron sâu như RNN bằng cách cung cấp dữ liệu đào tạo cho mô hình và tinh chỉnh hiệu năng của mô hình. Trong ML, trọng số của nơ-ron là tín hiệu để xác định mức độ ảnh hưởng của thông tin đã học trong quá trình đào tạo khi dự báo đầu ra. Mỗi tầng trong RNN đều có trọng số bằng nhau.

Các kỹ sư ML điều chỉnh trọng số để dự báo chính xác hơn. Họ sử dụng một kỹ thuật gọi là *lan truyền ngược qua thời gian* (Backpropagation Through time – BPTT) là một thuật toán huấn luyện *mạng nơ-ron hồi quy* (RNN) bằng cách sử dụng phương pháp *lan truyền ngược* (backpropagation) trong các chuỗi thời gian) để tính lỗi mô hình và điều chỉnh trọng số của mô hình cho phù hợp. BPTT khôi phục đầu ra về bước thời gian trước và tính lại tỷ lệ lỗi. Qua đó, kỹ thuật này có thể xác định trạng thái ẩn nào trong chuỗi đang gây ra lỗi đáng kể và điều chỉnh lại trọng số để giảm biên lỗi.

Công thức của *mạng nơ-ron hồi quy* (RNN) biểu diễn cách mà mạng này xử lý và tính toán thông tin từ dữ liệu tuần tự như chuỗi văn bản, âm thanh, hoặc chuỗi thời gian. Một RNN hoạt động theo các bước thời gian, trong đó mỗi bước thời gian tương

ứng với một từ trong văn bản hoặc một mẫu dữ liệu trong chuỗi thời gian. Công thức cơ bản của một *mạng nơ-ron hồi quy* (RNN) được biểu diễn như sau:

- Đầu vào tại bước thời gian t : $x^{(t)}$
- Trạng thái ẩn tại bước thời gian t : $h^{(t)}$
- Trọng số và bias cho tầng ẩn: W_{hh} và b_h
- Trọng số và bias cho tầng đầu vào: W_{xh} và b_x
- Hàm kích hoạt (activation function) cho tầng ẩn: ϕ

Với các biến trên, quá trình lan truyền tiến của một mạng RNN có thể được mô tả bằng các phương trình sau:

1. Tính toán trạng thái ẩn mới tại bước thời gian t :

$$h^{(t)} = \phi(W_{hh}h^{(t-1)} + W_{xh}x^{(t)} + b_h) \quad (11)$$

Trong quá trình tính toán của RNN, trạng thái ẩn ($h^{(t)}$) tại mỗi bước thời gian (t) được tính toán dựa trên trạng thái ẩn của bước thời gian trước đó ($h^{(t-1)}$) và đầu vào ($x^{(t)}$) tại thời điểm hiện tại. Công thức tính toán trạng thái ẩn sử dụng các ma trận trọng số (W_{hh} , W_{xh}) và bias (b_h) để kết hợp thông tin từ trạng thái ẩn trước đó và đầu vào hiện tại, và sau đó áp dụng một hàm kích hoạt (ϕ) để tạo ra trạng thái ẩn mới. Trạng thái ẩn này chứa thông tin được tổng hợp từ cả quá khứ và hiện tại của dữ liệu đầu vào.

2. Đầu ra tại bước thời gian t :

$$y^{(t)} = g(W_{hy}h^{(t)} + b_y) \quad (12)$$

Trong đó:

- W_{hy} là ma trận trọng số của lớp kết nối đầu ra.
- b_y là bias cho lớp kết nối đầu ra.

- g là hàm kích hoạt cho đầu ra, thường là hàm softmax (nếu là bài toán phân loại) hoặc hàm tuyến tính (nếu là bài toán hồi quy).

Sau khi tính toán trạng thái ẩn, mạng sử dụng trạng thái ẩn này để tính toán đầu ra ($y^{(t)}$) tại bước thời gian (t). Đầu ra được tính toán bằng cách sử dụng ma trận trọng số (W_{hy}) và bias (b_y) để kết hợp trạng thái ẩn và sau đó áp dụng một hàm kích hoạt (g) để tạo ra dự báo cuối cùng của mạng.

Các trọng số và bias trong mạng RNN được điều chỉnh thông qua quá trình huấn luyện, trong đó chúng được điều chỉnh sao cho dự báo của mạng gần với đầu ra thực tế nhất có thể. Điều này được thực hiện bằng cách sử dụng hàm mất mát để đo lường sự sai lệch giữa dự báo và đầu ra thực tế, và sau đó sử dụng thuật toán lan truyền ngược để tính toán gradient của hàm mất mát đối với các trọng số và bias, từ đó cập nhật chúng để giảm thiểu sai lệch này.

2.3.4 Các vấn đề hạn chế của RNN

Vấn đề độ dốc biến mất là một điều kiện, trong đó độ dốc của mô hình đạt đến 0 trong quá trình đào tạo. Khi độ dốc biến mất, RNN không học một cách hiệu quả từ dữ liệu đào tạo, dẫn đến chưa khớp. Mô hình chưa khớp không thể hoạt động tốt trong các ứng dụng thực tế vì các trọng số chưa được điều chỉnh thích hợp. RNN sẽ có rủi ro gặp phải vấn đề độ dốc cực lớn và biến mất khi xử lý các chuỗi dữ liệu dài.

1. *Độ dốc cực lớn* (Exploding Gradient): Trong quá trình lan truyền ngược, gradient có thể tăng lên quá nhanh khi đi qua nhiều bước thời gian, gây ra hiện tượng độ dốc cực lớn. Khi điều này xảy ra, các trọng số có thể được điều chỉnh quá nhanh, dẫn đến các bước cập nhật lớn và không ổn định, làm mất đi sự hội tụ của thuật toán huấn luyện.
2. *Độ dốc biến mất* (Vanishing Gradient): Ngược lại, trong một số trường hợp, gradient có thể giảm đi quá nhanh khi đi qua nhiều bước thời gian, gây ra hiện tượng độ dốc biến mất. Khi gradient tiến dần về zero, việc cập nhật các trọng số trở nên rất nhỏ, làm cho mạng không thể học được thông tin từ các bước thời gian xa, đặc biệt là trong các chuỗi dài.

3. Thời gian đào tạo chậm: Độ dốc cực lớn và độ dốc biến mất không chỉ ảnh hưởng đến hiệu suất huấn luyện mà còn làm chậm quá trình đào tạo. Khi gradient trở nên quá lớn hoặc quá nhỏ, thuật toán tối ưu hóa có thể cần phải thực hiện nhiều bước nhỏ hoặc nhiều lần lặp lại để đạt được sự hội tụ, làm tăng thời gian đào tạo.

LSTM (Long Short-Term Memory) và các biến thể của nó như GRU (Gated Recurrent Unit) được phát triển để giải quyết vấn đề này bằng cách giữ và sử dụng thông tin dài hạn trong chuỗi dữ liệu, đồng thời tránh được vấn đề độ dốc biến mất hoặc phân biệt dài hạn.

2.3.5 Mạng nhớ ngắn-dài-hạn (Long Short Term Memory – LSTM)

LSTM, là một dạng đặc biệt của RNN, có khả năng học được những sự phụ thuộc trong một thời gian dài, được phát minh bởi Hochreiter và Schmidhuber [3]. LSTM được thiết kế để giải quyết vấn đề triệu tiêu thông tin của RNN. Mạng LSTM có thể gồm nhiều *ô nhớ* (memory cells) được kết nối với nhau đại diện thông tin theo thời gian như các nốt ẩn của RNN. Điểm chính của LSTM được gọi là *trạng thái khối* (cell state). LSTM có khả năng thêm hoặc xóa bớt thông tin của trạng thái khối thông qua các cổng. Cổng là cách để tùy chỉnh lượng thông tin được truyền trải qua. Nó kết hợp với hàm kích hoạt sigmoid, giá trị nằm giữa 0 và 1, sẽ biểu thị bao nhiêu thông tin được truyền tải qua. Khi sigmoid có giá trị 0 có nghĩa là không có chút thông tin nào được đi qua, trong khi giá trị 1 có nghĩa là tất cả thông tin được phép truyền đi tiếp. LSTM có tổng cộng 3 cổng, để điều khiển và bảo vệ trạng thái khối đó là *cổng bỏ thông tin* (forget gate), *cổng đầu vào* (input gate) và *cổng đầu ra* (output gate).

1. Cổng bỏ thông tin thực hiện nhiệm vụ xóa bỏ thông tin không cần thiết nhận được ở khối trước đó. Được biểu diễn bằng công thức ở dưới. Trong đó là đầu ra của cổng ở thời gian hiện tại, σ là hàm sigmoid, C_{t-1} và h_{t-1} tương ứng là trạng thái khối và đầu ra của lớp ẩn ở bước trước đó, W_f và b_f tương ứng là trọng số và bias từ lớp dữ liệu đầu vào.

$$f_t = \sigma(W_f[C_{t-1}, h_t, x_t] + b_f) \quad (13)$$

2. Cổng đầu vào giúp lựa chọn những thông tin cần thiết để thêm vào trạng thái khối. Cổng sẽ gồm 2 thành phần chính: lớp sigmoid và lớp tanh. Lớp sigmoid lọc những thông tin từ h_{t-1}, x_t, C_{t-1} . Lớp tanh sinh ra những giá trị sẽ được thêm vào ô nhớ LSTM. Đầu ra của 2 lớp này được tính theo công thức sau:

$$i_t = \sigma(W_i [C_{t-1}, h_{t-1}, x_t] + b_i) \quad (14)$$

$$C'_t = \tanh(W_c [h_{t-1}, x_t] + b_c) \quad (15)$$

Trong công thức (14), i_t là đầu ra của cổng đầu vào; W_i và b_i là trọng số và bias của cổng đầu vào. Và W_c, b_c trong công thức (1) là trọng số và bias của trạng thái khối. Trạng thái khối cũ C_{t-1} được sử dụng để cập nhật C_t . Được thực hiện bằng cách nhân trạng thái khối cũ với f_t và sau đó cộng $i_t \times C_t$ như công thức sau:

$$C_t = f_t \times C_{t-1} + i_f \times C_t \quad (16)$$

3. Cổng đầu ra xác định thông tin của trạng thái khối hiện tại được sử dụng là dữ liệu đầu ra. Trong công thức (17) và (18) ở dưới, o_t là đầu ra của cổng đầu ra. W_o và b_o đại diện cho trọng số và bias của cổng đầu vào và h_t là đầu ra của lớp ẩn ở trạng thái hiện tại.


$$o_t = \sigma(W_o [C_t, h_{t-1}, x_t] + b_o) \quad (17)$$

$$h_t = o_t \times \tanh(C_t) \quad (18)$$


Khối của LSTM được mô tả ở hình 2.10. Mạng nơ-ron LSTM học sâu có nhiều hơn 1 tầng ẩn. Nó bao gồm nhiều khối LSTM với đầu ra của tầng trước là dữ liệu đầu vào của tầng tiếp theo. Kiến trúc của mạng nơ-ron LSTM được mô tả ở hình 2.11. Giả sử dữ liệu chuỗi thời gian là $x = \langle x_1, x_2, \dots, x_t \rangle$ là đầu vào của LSTM. Đầu ra của mạng LSTM tự động tính giá trị dự báo ở bước thời gian tiếp theo sử dụng thông tin trước đó.

Mạng LSTM có thể được mở rộng cho chuỗi thời gian nhiều biến bằng cách thêm chiều ở tham số W và b .

Quá trình huấn luyện mạng RNN và LSTM cùng sử dụng giải thuật lan truyền ngược để cập nhật các trọng số của mô hình.




Hình 2. 10: Trạng thái khối của LSTM ([2])



Hình 2. 11: Kiến trúc mô hình mạng của LSTM ([2])

2.3.6 Huấn luyện mạng LSTM cho bài toán dự báo chuỗi thời gian

Cách huấn luyện mạng LSTM cho bài toán dự báo chuỗi thời gian cũng tương tự như cách huấn luyện mạng nơ-ron ANN cho bài toán dự báo chuỗi thời gian (trình bày ở mục 2.2.2). Cách huấn luyện này cũng dựa vào kỹ thuật cửa sổ trượt để biến đổi chuỗi thời gian thành nhiều *vector đầu vào* (input vector). Hình 2.12 minh họa quá trình huấn luyện mạng LSTM cho bài toán dự báo chuỗi thời gian.



Hình 2. 12: Minh họa quá trình huấn luyện mạng LSTM cho bài toán dự báo chuỗi thời gian sử dụng kỹ thuật cửa sổ trượt ([2])

Chương 3. CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

Chương này trình bày các công trình liên quan được chúng tôi tìm hiểu trong quá trình nghiên cứu thực hiện đề tài.

Dựa vào các kỹ thuật khác nhau để giải quyết bài toán dự báo tỷ giá ngoại tệ, có thể chia các công trình liên quan đã công bố thành các nhóm:

- Phương pháp dự báo truyền thống
- Phương pháp dự báo học máy
- Phương pháp dự báo học sâu

Dự báo giá trị tỷ giá ngoại tệ là một bài toán đầy thách thức bởi vì tỷ giá ngoại tệ thường không ổn định, hỗn loạn, có nhiều nhiễu (Abu-Mostafa và Atiya, 1996 [4]) mà không có một thông tin đầy đủ nào có thể thể hiện mối quan hệ chính xác giữa giá trị ở tương lai và những biến động xảy ra trong quá khứ. Một giả định thường được sử dụng khi giải quyết bài toán này là dữ liệu lịch sử có thể đại diện được cho tất cả các yếu tố tác động trong quá khứ.

3.1 Phương pháp dự báo truyền thống

Trong nhiều năm trước đây, các nhà nghiên cứu sử dụng các kỹ thuật tuyến tính để giải quyết bài toán dự báo tỷ giá ngoại tệ, như kỹ thuật *Auto-Regressive Integrated Moving Average* (ARIMA) và *làm trơn hàm mũ* (Exponential Smoothing - ES) (Maniatis, 2012 [5]). Maniatis [5] đã tiến hành dự báo tỷ giá giữa đồng Euro và đô-la Mỹ sử dụng phương pháp ARIMA và ES. Các mô hình này cho kết quả còn hạn chế vì đơn giản chỉ là tính toán xác suất đối với những thay đổi ngắn hạn của tỷ giá ngoại tệ nằm trong các phạm vi cụ thể. Vì đơn giản và phổ biến nên phương pháp này được sử dụng rộng rãi để so sánh với các mô hình hiện đại hơn. Tuy nhiên, phương pháp này lại giả định dữ liệu chuỗi thời gian là tuyến tính và có *tính dừng* (stationary), vì vậy, nó không phù hợp với các bài toán dự báo mà dữ liệu có tính chất phi tuyến và *hỗn loạn* (chaotic).

3.2 Phương pháp dự báo học máy

Nhiều phương pháp học máy cũng được áp dụng vào bài toán dự báo chuỗi thời gian nói chung và dự báo tỉ giá ngoại tệ nói riêng.

Cao và các cộng sự, 2005 [6] sử dụng phương pháp *máy vector hỗ trợ* (support vector machine - SVM) để dự báo giá trị đóng phiên giao dịch của tỷ giá đồng bảng Anh và đô-la Mỹ (GBP/USD). Để lựa chọn được các giá trị tham số phù hợp với mô hình, các tác giả tiến hành thực nghiệm với nhiều bộ tham số khác nhau và chọn bộ tham số cho kết quả tốt nhất. Kết quả của mô hình dự báo còn cách giá trị thực tế một khoảng cách lớn.

Với đặc điểm có thể mô hình hóa các bài toán phi tuyến, *mạng nơ-ron nhân tạo* (Artificial Neural Networks -ANN) được sử dụng phổ biến trong các bài toán dự báo chuỗi thời gian. Nhiều nghiên cứu đã xác nhận rằng ANN là một kỹ thuật hiệu quả trong bài toán dự báo dữ liệu tài chính. Tang và Fishwich, 1993 [7], Wang và Leu, 1996 [8] đã chỉ ra rằng ANN cho kết quả dự báo tốt hơn kỹ thuật ARIMA, đặc biệt với các dữ liệu không có *tính dừng* (non-stationary). Dunis và Williams, 2003 [9] đã xác nhận rằng với mạng ANN đơn giản gồm 12 *nút đầu vào* (input node), 7 *nút tầng ẩn* (hidden node) và 1 *nút đầu ra* (output node) cho kết quả dự báo chính xác hơn các phương pháp truyền thống như *trung bình di động* (moving average) và *tự hồi quy - trung bình di động* (autoregressive moving average - ARMA). Thinyane và Millin, 2011 [10] chỉ ra rằng với kiến trúc ANN càng phức tạp thì kết quả dự báo càng chính xác. Kết quả này nhờ vào khả năng biểu diễn xấp xỉ hàm liên tục bất kỳ nào của mạng nơ-ron và là phương pháp *phi mô hình* (non-parametric), không cần bất kỳ giả định nào về đặc tính của dữ liệu đầu vào. Nhưng vì số kết nối giữa các tầng trong ANN khá lớn dẫn đến số trọng số của kiến trúc này khá nhiều. Vì thế, ANN không thể xây dựng được các mô hình phức tạp và dễ bị hiện tượng quá khớp mà không thể làm tốt với dữ liệu ngoài thực tế. Để giải quyết vấn đề này Nag và Mitra, 2002 [11] đã sử dụng giải thuật di truyền để xác định các siêu tham số cho mô hình như giá trị của *hệ số học* (learning rate), giá trị *quán tính* (momentum), số tầng ẩn, số nút của mỗi lớp, hàm kích hoạt (hàm truyền).

3.3 Phương pháp dự báo học sâu

Với sự kết hợp giữa các tầng nơ-ron ẩn và mô hình xác suất *máy Boltzmann giới hạn* (restricted Boltzmann machine - RBM), Hinton và các cộng sự [12] đã phát minh ra kiến trúc *Deep Belief Network* (DBN). DBN đã chứng tỏ được sức mạnh của mạng này qua việc giải quyết tốt nhiều loại bài toán khác nhau như: phân lớp, thu giảm số chiều, trích xuất đặc trưng. Và DBN cũng được kiểm chứng trong lĩnh vực dự báo chuỗi thời gian tài chính, Chao và các cộng sự [13] đã sử dụng mạng nơ-ron DBN để giải quyết bài toán dự báo tỉ giá ngoại tệ giữa đồng bảng Anh và đồng đô-la Mỹ, giữa đồng tiền Ấn Độ và đô-la Mỹ. Bằng phương pháp thực nghiệm, các tác giả đã xây dựng kiến trúc 6-16-8-1 (với 6 nút dữ liệu đầu vào, 16 nút ở tầng ẩn đầu tiên, 8 nút ở tầng ẩn thứ hai, và 1 nút đầu ra cho tập dữ liệu tỉ giá đồng bảng Anh và đô-la Mỹ và kiến trúc 10-3-3-1 cho tập dữ liệu tỉ giá đồng tiền Ấn Độ với đô-la Mỹ. Kết quả của thực nghiệm đã chứng minh DBN vượt trội hơn so với phương pháp mạng nơ-ron truyền thống thông thường.

Với sự phát triển của phần cứng trong những năm gần đây, những mô hình mạng học sâu như: *mạng nơ-ron tích chập* (Convolutional Neural Network - CNN), *mạng nhớ ngắn-dài-hạn* (Long Short Term Memory - LSTM) đã thể hiện được sự ưu việt của chúng trong nhiều bài toán phức tạp. CNN được biết nhiều đến với các bài toán về xử lý ảnh, với khả năng có thể phân loại ảnh có thể so sánh với khả năng con người. Không những thế CNN cũng đang dần được áp dụng vào các bài toán phân tích và dự báo chuỗi thời gian. Galeshchuk và Mukherjee năm 2017 [14] đã áp dụng CNN để phân loại xu hướng của dữ liệu tỉ giá ngoại tệ. Tỉ giá đóng phiên hàng ngày từ năm 2010 đến năm 2015 của đồng EURO với đồng đô-la Mỹ (EUR/USD), đồng bảng Anh và đô-la Mỹ (GBP/ USD), đồng đô-la Mỹ và đồng yên Nhật (USD/JPY) được sử dụng để phân tích với 1043 giá trị đóng phiên từ năm 2010 đến năm 2013 được sử dụng cho huấn luyện và 522 giá trị được sử dụng để đánh giá phương pháp. Chỉ bằng cách xây dựng mô hình CNN đơn giản với 4 *tầng tích chập* (convolutional layer) với tham số kernel của *chiều rộng* (width), *chiều cao* (height), *chiều sâu* (depth), *bước dịch chuyển* (stride), số ô được *chèn thêm* (padding) tương ứng lần lượt là 5, 1, 1, 2,

0, kết hợp với hàm tối ưu Adam, hàm kích hoạt softmax đã chứng tỏ rằng CNN cho kết quả tốt hơn đáng kể so với các phương pháp ARIMA và ANN.

Tuy nhiên các mạng nơ-ron truyền thống nói chung và CNN nói riêng chỉ nhìn dữ liệu đầu vào là các giá trị độc lập. Điều này làm cho mất đi mối tương quan quan trọng giữa các giá trị đầu vào với nhau.

RNN được biết đến như là công cụ giải quyết được các bài toán với các loại dữ liệu có mối quan hệ theo thời gian với nhau như: dịch máy, chuyển giọng nói thành câu văn và ngược lại,... Trong đó *Long Short Time Memory* (LSTM) được sử dụng phổ biến vì nó giải quyết được vấn đề triệt tiêu và bùng nổ giá trị khi huấn luyện mô hình RNN truyền thống. Dữ liệu chuỗi thời gian nói chung và tỷ giá ngoại tệ nói riêng đều có sự tương quan giữa các giá trị theo thời gian. Vì thế, trong những năm gần đây, nhiều nhà nghiên cứu đã bắt đầu ứng dụng LSTM vào trong các bài toán phân loại, dự báo chuỗi thời gian và đạt kết quả tốt so với các kỹ thuật khác.

Escudero và các cộng sự năm 2021 [15] đã sử dụng mạng LSTM và mạng Elman (một kiểu của mạng RNN) vào bài toán dự báo tỷ giá ngoại tệ giữa đồng Euro với đồng đô-la Mỹ (EUR/USD) và so sánh hiệu quả dự báo của hai mạng học sâu này với mô hình ARIMA. Các tác giả thực nghiệm bộ dữ liệu này với nhiều tầm dự báo (forecasting horizon) khác nhau. Kết quả thực nghiệm cho thấy cả hai mạng học sâu LSTM và Elman đều đem lại hiệu quả dự báo tốt hơn mô hình truyền thống ARIMA và mạng LSTM đem lại kết quả tốt nhất đối với tầm dự báo ngắn hạn trong khi mạng Elman đem lại kết quả tốt nhất đối với tầm dự báo dài hạn.

3.4 Kết luận chương

Qua quá trình nghiên cứu tìm hiểu các công trình liên quan đến bài toán dự báo chuỗi thời gian nói chung và bài toán dự báo tỷ giá ngoại tệ nói riêng, chúng tôi thấy rằng đây là lĩnh vực được nhiều nhà nghiên cứu quan tâm và áp dụng nhiều phương pháp để giải quyết, từ những phương pháp thống kê truyền thống cho đến những mô hình học sâu phức tạp. Với sự phát triển mạnh mẽ của phần cứng, các mô hình học sâu dễ dàng vượt trội hơn những phương pháp cổ điển hoặc mạng nơ-ron không sâu.

RNN và LSTM được thiết kế để xử lý dữ liệu dạng chuỗi, thể hiện được sự tương quan của dữ liệu được áp dụng thành công vào nhiều bài toán phân tích và dự báo chuỗi thời gian. Điều này thúc đẩy chúng tôi sử dụng kiến trúc mạng nơ-ron học sâu LSTM để thực hiện nghiên cứu này.

Chương 4. PHƯƠNG PHÁP GIẢI QUYẾT VẤN ĐỀ

Ở chương này chúng tôi trình bày quá trình xử lý dữ liệu, phân tích dữ liệu và mô hình dự báo tỷ giá ngoại tệ đề xuất.

4.1 Phân tích dữ liệu

Chúng tôi tiến hành thí nghiệm trên 4 bộ dữ liệu là tỷ giá giữa đồng đô-la Úc và đô-la Mỹ (AUD/USD), tỷ giá đồng Euro và đô-la Mỹ (EUR/USD), tỷ giá đồng bảng Anh và đô-la Mỹ (GBP/USD), tỷ giá đồng đô-la Mỹ và đồng Yên Nhật Bản (USD/JPY).


Chúng tôi sử dụng dữ liệu giao dịch mỗi ngày của tập AUD/USD, EUR/USD từ năm 1990 đến năm 2019, còn đối với tập GBP/USD và USD/JPY thì được lấy từ năm 2000 đến năm 2023.

Bốn tập dữ liệu được chọn có số lượng từ khoảng 6000 đến 8000 (ngày), được lấy từ trang web: <https://www.investing.com/currencies/>. Giá trị tỷ giá của các tập dữ liệu dao động từ khoảng 0-2.


Riêng tập dữ liệu tỷ giá đồng đô-la Mỹ và đồng Yên (USD/JPY) có sự khác biệt do giá trị tỷ giá dao động từ 70 đến 150 như hình 4.1, thuộc đơn vị hàng trăm. Do đó trước khi trực quan hóa tập USD/JPY chúng tôi đã tiến hành thu nhỏ giá trị 100 lần so với giá trị ban đầu (hình 4.2) để có thể quan sát chung cùng với các tập dữ liệu còn lại như hình 4.3.

Từ hình 4.3, ta thấy các chuỗi dữ liệu *không có tính dừng* (non-stationary) được thể hiện thông qua kỳ vọng *trung bình* (mean) và *độ lệch chuẩn* (standard deviation) thay đổi theo thời gian. Chính vì thế chúng tôi quyết định sử dụng mô hình học sâu LSTM do mô hình có khả năng xử lý chuỗi dữ liệu không có tính dừng và tìm ra mối tương quan giữa các điểm giá trị.


Sau đó chúng tôi trực quan sự phân bố giá trị tỷ giá của các tập dữ liệu bằng các boxplot và histogram như trong hình 4.4, 4.5, 4.6, 4.7.




Hình 4. 1: Dữ liệu USD/JPY chưa được xử lý




Hình 4. 2: Dữ liệu USD/JPY sau khi xử lý




Hình 4. 3: Đường biểu diễn của 4 tập dữ liệu tỷ giá ngoại tệ




Hình 4. 4: Histogram, Boxplot của AUD/USD



Hình 4. 5: Histogram, Boxplot của EUR/USD



Hình 4. 6: Histogram, Boxplot của GBP/USD



Hình 4. 7: Histogram, Boxplot của USD/JPY

Từ các biểu đồ trên ta thấy được khoảng dao động của đồng đô-la Mỹ với từng ngoại tệ: Với đồng Úc 0.7-0.8, với đồng Euro 1.1-1.3, với đồng bảng Anh 1.4-1.6 và với đồng Yên 1.0-1.2. Ta thấy rõ ràng rằng nếu xét lâu dài thì đồng bảng Anh có tỷ giá cao nhất so với các ngoại tệ còn lại, tiếp đến là đồng Euro. Đồng Úc và đồng Yên thì chỉ có những giá trị ngoại lệ là cao, khoảng dao động trung bình đều có xu hướng thấp hơn đồng đô-la Mỹ.

4.2 Đề xuất mô hình

Chúng tôi chọn mô hình mạng nơ-ron học sâu *LSTM* (Long Short-Term Memory) để dự báo tỷ giá ngoại tệ dựa trên vài lý do chính:


- *Xử lý dữ liệu chuỗi thời gian*: Tính chất chuỗi thời gian của dữ liệu tỷ giá ngoại tệ đặt ra một thách thức đối với các mô hình dự báo. Mạng LSTM được thiết kế đặc biệt để xử lý và học được các mẫu trong dữ liệu chuỗi thời gian. Điều này giúp mô hình LSTM có khả năng nắm bắt được cả các mối quan hệ dài hạn và ngắn hạn giữa các giá trị tỷ giá.
- *Xử lý các tính chất phi tuyến*: Tỷ giá ngoại tệ thường có các tính chất phi tuyến, có thể bị ảnh hưởng bởi nhiều yếu tố phức tạp như chính sách tài chính, sự

biến động trong thị trường và kinh tế toàn cầu. Mạng LSTM có khả năng học được các mẫu phi tuyến từ dữ liệu, giúp nắm bắt được các biến động không đồng đều và không lặp lại của tỷ giá ngoại tệ.

- *Xử lý đặc điểm lặp lại và quan hệ dài hạn*: Trong việc dự báo tỷ giá ngoại tệ, thông tin từ các quan sát trước đó có thể cực kỳ quan trọng để đưa ra dự báo chính xác. Mạng LSTM sử dụng các cơ chế cập nhật và lưu trữ thông tin *dài hạn* (long-term memory) và *ngắn hạn* (short-term memory) cho phép nắm bắt được các mẫu lặp lại trong dữ liệu và học được các phụ thuộc dài hạn quan trọng.

Mặc dù mô hình ANN (Artificial Neural Network) cũng có khả năng học được các mẫu phức tạp từ dữ liệu, nhưng nó thường gặp khó khăn trong việc xử lý dữ liệu chuỗi thời gian và các mối quan hệ dài hạn trong dữ liệu. Mô hình LSTM được coi là một cải tiến so với ANN trong việc dự báo tỷ giá ngoại tệ, vì nó có khả năng xử lý dữ liệu chuỗi thời gian và nắm bắt được các mối quan hệ dài hạn và ngắn hạn một cách hiệu quả hơn.


Vì vậy, so sánh mô hình mạng LSTM với phương pháp truyền thống ANN là cần thiết để đánh giá hiệu suất và khả năng dự báo của mô hình LSTM đối với dữ liệu tỷ giá ngoại tệ. Hình 4.8 dưới đây sẽ mô tả tiến trình dự báo tỷ giá ngoại tệ bằng mạng LSTM và mạng ANN của chúng tôi.



Hình 4. 8: Sơ đồ tiến trình để dự báo tỷ giá ngoại tệ dựa vào mạng LSTM và mạng ANN

4.3 Phương pháp xác định siêu tham số của mạng LSTM với giải thuật Grid Search

Trong bài báo [16], Abbasimehr và các cộng sự đã đề xuất phương pháp dự báo nhu cầu tiêu thụ đồ nội thất sử dụng phương pháp mạng nơron học sâu với mô hình LSTM nhiều tầng. Các tác giả đề xuất phương pháp Grid Search để xác định siêu tham số cho mô hình LSTM.



Hình 4. 9: Hình ảnh minh họa giải thuật Grid Search

Các siêu tham số cho mô hình LSTM gồm bảy siêu tham số: kích thước biến độ trễ (còn được gọi là kích thước cửa sổ trượt), số tầng ẩn, số lượng nơron, tỉ lệ dropout, hệ số học, kích thước batch, số kỉ nguyên (số lượt lặp). Các giá trị của mỗi siêu tham số được định nghĩa với các giá trị xác định cho trước, một danh sách mỗi sự kết hợp các giá trị của siêu tham số được tạo ra. Đối với mỗi sự kết hợp các giá trị siêu tham số tạo ra, một mô hình mạng học sâu LSTM được tạo ra và huấn luyện cho mỗi trường hợp. Để đánh giá hiệu suất của mỗi mô hình, các tác giả sử dụng độ đo RMSE, với các giá trị được tính toán dựa trên đầu vào và đầu ra dự báo đã được giải chuẩn hóa. Dựa vào kết quả đánh giá, mô hình đem lại hiệu quả dự báo tốt nhất là mô hình được chọn.

Trong giải thuật Grid Search, mỗi chiều của lưới tương ứng với một siêu tham số được thể hiện như trong hình 4.8. Trong đó mỗi điểm của lưới là một bộ giá trị tương ứng với mỗi tập siêu tham số. Với mỗi điểm trong mắt lưới, một cấu hình huấn luyện được thực hiện và đánh giá.

4.4 Kỹ thuật Dropout để giảm thiểu vấn đề quá khớp của mạng nơ-ron

Mạng nơ-ron học sâu với số lượng thông số khá lớn là những hệ thống học máy rất mạnh. Tuy nhiên, *quá khớp* (overfitting) là một vấn đề quan trọng hay xảy ra với loại mạng như vậy. Kỹ thuật *dropout* là một kỹ thuật nhằm giải quyết vấn đề quá khớp này. Ý tưởng chính của kỹ thuật này là *gỡ bỏ* (drop) một cách ngẫu nhiên một số đơn vị (cùng với những đường nối của chúng) ra khỏi mạng nơ-ron trong quá trình huấn luyện mạng. Điều này giúp cho các đơn vị không phải *đồng thích nghi* (co-adapting) với nhau quá nhiều. Trong quá trình huấn luyện, kỹ thuật dropout lấy mẫu một số lượng lớn những mạng “nhỏ hơn” (thinned network) khác biệt nhau. Đến quá trình thử, rất dễ để xấp xỉ tác dụng của việc lấy trung bình những giá trị dự báo của tất cả các mạng “nhỏ hơn” này bằng cách chỉ sử dụng một mạng *không bị tháo gỡ* (unthinned network) đơn giản mà có những trọng số nhỏ hơn. Kỹ thuật *dropout* giúp giảm thiểu vấn đề quá khớp rất nhiều và đem lại một sự cải thiện hơn cả các kỹ thuật *chính quy hóa* (regularization) khác.

Kỹ thuật *dropout* được đề xuất bởi Srivastava và các cộng sự năm 2014 [17]. Qua thực nghiệm, các tác giả cũng đã cho thấy kỹ thuật *dropout* cải thiện hiệu quả của mạng nơ-ron trong các bài toán học có giám sát như thị giác máy tính, nhận dạng giọng nói, phân loại tài liệu và sinh tin học, đem lại những kết quả nổi bật trên các bộ dữ liệu chuẩn.

Chương 5. HIỆN THỰC VÀ KẾT QUẢ THỰC NGHIỆM

Chương này trình bày các tiêu chí đánh giá, quá trình hiện thực các thực nghiệm cho mô hình đề xuất và mô hình so sánh cùng với phân tích kết quả thực nghiệm.

Môi trường thực nghiệm:

- Google Compute Engine backend (Google Colab)
- Ngôn ngữ: Python 3
- Framework: keras, tensorflow và các thư viện như numpy, pandas, matplotlib, sklearn, scikeras

Cấu hình máy tính:

- Processor: Intel(R) Core(TM) i5-1035G1 CPU @ 1.00GHz 1.19 GHz
- RAM: 8.00 GB (7.77 GB usable)
- System: 64-bit operating system, x64-based processor

Trong đề tài này, chúng tôi tập trung vào *dự báo một bước* (one-step-ahead prediction) với dữ liệu tỷ giá ngoại tệ.

5.1 Giới thiệu về thư viện Keras và Tensorflow

Keras là một thư viện mạng nơ-ron bằng python năm 2015 bởi một kỹ sư về học sâu của Google [18]. Ta có thể kết hợp keras với các thư viện học sâu (thông thường là Tensorflow). Một số ưu điểm của Keras như:

- Dễ sử dụng, dùng đơn giản hơn Tensor, xây dựng mô hình nhanh, thực thi được trên cả CPU và GPU. Hỗ trợ xây dựng CNN, RNN hoặc cả hai.
- Với những người mới tiếp cận đến học sâu thì chọn sử dụng Keras để xây dựng mô hình vì nó đơn giản, dễ nắm bắt hơn các thư viện khác.

Với sự bùng nổ của lĩnh vực *Trí tuệ nhân tạo* (AI) trong thập kỷ vừa qua, học máy và học sâu rõ ràng cũng phát triển theo cùng. Và ở thời điểm hiện tại, TensorFlow chính là thư viện mã nguồn mở cho học máy nổi tiếng nhất thế giới, được phát triển

bởi các nhà nghiên cứu từ Google. Việc hỗ trợ mạnh mẽ các phép toán học để tính toán trong học máy và học sâu đã giúp việc tiếp cận các bài toán trở nên đơn giản, nhanh chóng và tiện lợi hơn nhiều. Các hàm được dựng sẵn trong thư viện cho từng bài toán cho phép Tensorflow xây dựng được nhiều mạng nơ-ron. Nó còn cho phép tính toán song song trên nhiều máy tính khác nhau, thậm chí trên nhiều CPU, GPU trong cùng một máy hay tạo ra các đồ thị luồng dữ liệu để dựng nên các mô hình.

5.2 Tiêu chí đánh giá hiệu quả dự báo

Kết quả dự báo của mô hình sẽ được đo đạc và so sánh dựa trên hai độ đo là *sai số bình phương trung bình* (mean square error - MSE) và *sai số phần trăm tuyệt đối trung bình* (mean absolute percentage error - MAPE).

Mean Squared Error (MSE):

- Công thức tính MSE cho một tập dữ liệu có n giá trị là:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (19)$$

- Trong đó:
 - y_i là giá trị thực tế.
 - $\hat{y}_i$ là giá trị dự báo.
 - n là số lượng mẫu trong tập dữ liệu.
- MSE đo lường độ lớn của sai số bằng cách lấy trung bình của bình phương của tất cả các sai số giữa giá trị dự báo và giá trị thực tế.

Mean Absolute Percentage Error (MAPE):

- Công thức tính MAPE cho một tập dữ liệu có n giá trị là:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (20)$$

- Trong đó:
 - y_i là giá trị thực tế.


- $\hat{y}_i$ là giá trị dự báo.
- n là số lượng mẫu trong tập dữ liệu.
- MAPE đo lường độ lớn của sai số dưới dạng phần trăm trung bình so với giá trị thực tế.

Cả 2 độ đo đều là điểm số định hướng tiêu cực, có nghĩa là giá trị thấp hơn là tốt hơn. Tuy nhiên, độ đo MSE không thể nói lên điều gì, ví dụ $MSE = 1.3$ ta không thể rút ra kết luận gì ngay, cho nên độ đo MSE của một mô hình cần phải được so sánh với MSE của nhiều mô hình khác, để xem cái nào nhỏ nhất. Còn đối với MAPE thì nó thể hiện rõ phần trăm sai số trong dự báo, ví dụ nếu $MAPE = 2.56$ thì ta biết được 2.56% kết quả dự báo sai so với giá trị thực.


Tóm lại, MSE và MAPE đều là các độ đo thường được sử dụng để đánh giá hiệu suất của mô hình dự báo. MSE tập trung vào đo lường sai số trung bình bằng cách lấy trung bình của bình phương sai số, trong khi MAPE tập trung vào đo lường sai số dưới dạng phần trăm trung bình.

5.3 Xác định kiến trúc và siêu tham số của ANN và LSTM


. Các tập dữ liệu khi đưa vào quá trình học máy sẽ được chia thành hai phần *huấn luyện* (training) và *thử* (testing) với tỉ lệ lần lượt là 80%, 20% (thể hiện qua hình 5.1, 5.2, 5.3, 5.4).




Hình 5. 1: Tập AUD/USD được chia với tỉ lệ 80/20



Hình 5. 2: Tập EUR/USD được chia với tỉ lệ 80/20



Hình 5. 3: Tập GBP/USD được chia với tỉ lệ 80/20



Hình 5. 4: Tập USD/JPY được chia với tỉ lệ 80/20

Ở mỗi loại mạng nơ-ron chúng tôi tiến hành giải thuật *tìm kiếm lưới* (GridSearch) để tìm các kiến trúc và các siêu tham số phù hợp với tập dữ liệu bằng cách dùng một lượng ngày nhất định ở quá khứ để dự báo tương lai (windown size). Dưới đây là kiến trúc chung của mạng ANN, LSTM được xác định dựa vào giải thuật GridSearch được thể hiện qua hình 5.5 và 5.6:

Cấu hình chung của mô hình ANN:

- Mô hình ANN này sẽ có một tầng ẩn.
- Hàm kích hoạt (activation) cho tầng ẩn là hàm *Rectified Linear Unit* (ReLU).
- Giải thuật huấn luyện (solver) là giải thuật *suy giảm độ dốc xác suất* (Stochastic Gradient Descent – SGD).
- Siêu tham số cần được xác định bằng GridSearch ở đây là số nơ-ron, với khoảng tìm kiếm từ 50 cho đến 200, bước nhảy là 50. Như vậy GridSearch sẽ được thực hiện với bốn giá trị: 50, 100, 150 và 200.

```
ann_model = MLPRegressor(activation = 'relu', solver = 'sgd')
ann_param_grid = {
    'hidden_layer_sizes': [(i, ) for i in range(50, 201, 50)],
}
```

Hình 5. 5: Kiến trúc chung của mạng ANN được dùng trong GridSearch

Cấu trúc chung của mô hình LSTM:

- Mô hình LSTM này sẽ có hai tầng ẩn, với tầng ẩn thứ hai sẽ có số nơ-ron bằng một nửa tầng ẩn đầu tiên. Tham số `return_sequences = True` ở tầng ẩn đầu tiên để đảm bảo rằng tầng này trả về toàn bộ chuỗi đầu ra cho tầng ẩn thứ hai.
- Kích thước của tầng nhập (Input) là $(w, 1)$ với w là kích thước của sổ trượt và 1 là số bước dự báo.
- Sau hai tầng ẩn ta sẽ có một tầng Dropout (giải thích tại mục 4.4) với tham số là 0.2 với ý nghĩa gỡ bỏ ngẫu nhiên 20% nơ-ron của mô hình để tránh trường hợp *quá khớp* (overfitting).

- Cuối cùng là một tầng dày đặc với tham số là 1 với ý nghĩa đây là tầng xuất của mô hình.
- Hàm kích hoạt (activation) cho cả hai tầng ẩn là hàm *Rectified Linear Unit* (ReLU).
- Giải thuật huấn luyện (optimizer) là giải thuật Adam.
- Hàm mất mát (loss) được dùng trong quá trình huấn luyện là hàm *Mean Squared Error* (MSE).
- Siêu tham số cần được xác định bằng GridSearch là số nơ-ron, với hai giá trị là 50 và 100.

```
def create_lstm_model(units):
    global window_size
    model = Sequential()
    model.add(Input(shape = (w, 1)))
    model.add(LSTM(units, activation = 'relu', return_sequences = True))
    model.add(LSTM(int(units/2), activation = 'relu'))
    model.add(Dropout(0.2))
    model.add(Dense(1))
    model.compile(optimizer = "adam", loss='mse')
    return model

lstm_param_grid = {
    'units': [50, 100],
}
```

Hình 5. 6: Kiến trúc chung của mạng LSTM được dùng trong GridSearch

Dưới đây là hai bảng 5.1, 5.2 với kết quả GridSearch của mạng ANN và LSTM cho từng tập dữ liệu:

Dataset	window_size	Kiến trúc mạng tốt nhất
AUD/USD	11	hidden_layer_sizes=(150,)
EUR/USD		hidden_layer_sizes=(150,)
GBP/USD		hidden_layer_sizes=(200,)
USD/JPY		hidden_layer_sizes=(150,)

Bảng 5. 1: Kết quả GridSearch cho mạng ANN

Dataset	window_size	Kiến trúc mạng tốt nhất
AUD/USD	11	units=100 (Tầng ẩn đầu có 100 đơn vị, tầng ẩn thứ hai có 50 đơn vị)
EUR/USD	11	
GBP/USD	22	
USD/JPY	11	

Bảng 5. 2: Kết quả GridSearch cho mạng LSTM

Cả hai mô hình ANN và LSTM đều được xây dựng với sự hỗ trợ của thư viện Keras và Tensorflow.

Đối với mạng ANN, window_size tốt nhất của cả bốn tập dữ liệu là 11, trong khi kiến trúc mạng của mỗi mô hình ở bốn tập dữ liệu trả về là khác nhau. Còn đối với mạng LSTM thì ngược lại, window_size khác nhau nhưng lại có chung một kiến trúc mạng là: tầng ẩn thứ nhất 100 đơn vị, tầng ẩn thứ hai 50 đơn vị.


5.4 Kết quả thực nghiệm

		AUD/USD	EUR/USD	GBP/USD	USD/JPY
MSE	ANN	0.0003	0.0003	0.0016	0.0002
	LSTM	3.6495e-05	7.1797e-05	0.0003	8.6472e-05
MAPE	ANN	1.8%	1.34%	2.8%	0.85%
	LSTM	0.6%	0.58%	0.82%	0.6%


Bảng 5. 3: Độ đo MSE và MAPE của 4 tập dữ liệu

Qua kết quả độ đo MSE và MAPE được trình bày ở bảng 5.3, ta thấy đa phần mô hình LSTM đều cho về độ đo sai số dự báo nhỏ hơn so với mô hình ANN. Dưới đây là kết quả dự báo được trực quan hóa, chúng tôi sẽ trình bày kết quả trên tập thử (20% dữ liệu ban đầu) và kết quả chi tiết là một trăm điểm đầu tiên của tập thử.


Từ hình 5.7 đến hình 5.22, có thể kết luận rằng kết quả dự báo của mô hình LSTM so với kết quả dự báo của mô hình ANN có xu hướng chung là bám sát với dữ liệu thực hơn.




Hình 5. 7: Kết quả dự báo bằng ANN trên tập thử của AUD/USD




Hình 5. 8; Chi tiết kết quả dự báo bằng ANN trên tập thử của AUD/USD




Hình 5. 9: Kết quả dự báo bằng LSTM trên tập thử của AUD/USD




Hình 5. 10: Chi tiết kết quả dự báo bằng LSTM trên tập thử của AUD/USD




Hình 5. 11: Kết quả dự báo bằng ANN trên tập thử của EUR/USD




Hình 5. 12: Chi tiết kết quả dự báo bằng ANN trên tập thử của EUR/USD




Hình 5. 13: Kết quả dự báo bằng LSTM trên tập thử của EUR/USD




Hình 5. 14: Chi tiết kết quả dự báo bằng LSTM trên tập thử của EUR/USD




Hình 5. 15: Kết quả dự báo bằng ANN trên tập thử của GBP/USD




Hình 5. 16: Chi tiết kết quả dự báo bằng ANN trên tập thử của GBP/USD




Hình 5. 17: Kết quả dự báo bằng LSTM trên tập thử của GBP/USD




Hình 5. 18: Chi tiết kết quả dự báo bằng LSTM trên tập thử của GBP/USD




Hình 5. 19: Kết quả dự báo bằng ANN trên tập thử của USD/JPY



Hình 5. 20: Chi tiết kết quả dự báo bằng ANN trên tập thử của USD/JPY



Hình 5. 21: Kết quả dự báo bằng LSTM trên tập thử của USD/JPY



Hình 5. 22: Chi tiết kết quả dự báo bằng LSTM trên tập thử của USD/JPY

Chương 6. KẾT LUẬN

Trong chương này, chúng tôi trình bày những kết quả đạt được của quá trình nghiên cứu và thực nghiệm công tác dự báo tỷ giá ngoại tệ và đề xuất các hướng phát triển trong tương lai của đề tài.

6.1 Kết quả đạt được

Sau quá trình nghiên cứu và thử nghiệm, chúng tôi đã thu được kết quả đáng chú ý về hiệu suất dự báo của mạng học sâu LSTM so với mạng ANN trong việc dự báo tỷ giá ngoại tệ.

Kết quả thực nghiệm trên 4 bộ dữ liệu tỷ giá ngoại tệ AUD/USD, EUR/USD, GBP/USD và USD/JPY của chúng tôi cho thấy rằng mạng LSTM đã đạt được hiệu suất tốt hơn đáng kể so với mạng ANN trong việc dự báo tỷ giá ngoại tệ. Cụ thể, chúng tôi đã quan sát được các chỉ số đánh giá như *Mean Squared Error* (MSE) và *Mean Absolute Percentage Error* (MAPE) của mạng LSTM thường thấp hơn so với mạng ANN.

Ngoài ra, chúng tôi đã tiến hành kiểm định thống kê và xác nhận rằng sự khác biệt giữa hiệu suất của mạng LSTM và mạng ANN là có ý nghĩa thống kê, với mạng LSTM thường cho ra các dự báo chính xác hơn và ổn định hơn so với mạng ANN.

Tóm lại, kết quả của chúng tôi đề xuất rằng mạng LSTM là một lựa chọn ưu việt hơn so với mạng ANN trong việc dự báo tỷ giá ngoại tệ, với khả năng dự báo chính xác cao hơn và giảm thiểu sai số dự báo một cách đáng kể.

6.2 Hướng nghiên cứu tiếp theo

Tiếp tục từ nghiên cứu này, mục tiêu của chúng tôi là tích hợp nhiều loại mạng nơ-ron học sâu khác nhau và áp dụng chúng cho dữ liệu thực từ các thị trường tỷ giá ngoại tệ. Chúng tôi hy vọng rằng việc này sẽ giúp cải thiện hiệu suất và độ chính xác của các mô hình dự báo tỷ giá ngoại tệ, đồng thời đưa ra những kiến thức quý báu cho cộng đồng nghiên cứu trong lĩnh vực này.

Mục tiêu kế tiếp của chúng tôi là sử dụng mô hình học sâu LSTM, mô hình không sâu ANN và mô hình ARIMA để so sánh hiệu quả dự báo của cả ba mô hình.

Và chúng tôi cũng mong rằng có thể sử dụng mạng LSTM để dự báo tỷ giá ngoại tệ với tầm *dự báo nhiều bước* (multi-steps-ahead prediction). Hiện tại thì mô hình của chúng tôi mới chỉ dự báo một bước (1 ngày), chúng tôi hi vọng có thể tiếp tục phát triển mô hình để dự báo chính xác cho ba bước (3 ngày), năm bước (5 ngày),...

Cuối cùng, chúng tôi hi vọng có thể thử nghiệm mô hình trên dữ liệu thực, sử dụng mô hình dự báo nhiều bước để dự báo cho N ngày nhất định và so sánh dữ liệu dự báo với dữ liệu thực tế của chính N ngày đó.

TÀI LIỆU THAM KHẢO

- [1] Dương Tuấn Anh, "Phân lớp," Môn học Trí Tuệ Nhân Tạo, Khoa Công Nghệ Thông Tin, Trường Đại Học Ngoại Ngữ-Tin Học Tp. Hồ Chí Minh, 2023.
- [2] Dương Tuấn Anh, "Mạng nơ ron học sâu," Môn cao học Học Máy và Ứng Dụng, Khoa Khoa Học và Kỹ Thuật Máy Tính, Trường Đại Học Bách Khoa Tp. Hồ Chí Minh, 2022.
- [3] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [4] Y. S. Abu-Mostafa and A. F. Atiya, "Introduction to financial forecasting," *Applied Intelligence*, vol. 6, no. 3, pp. 205–213, Jul 1996.
- [5] P. Maniatis, "Forecasting the exchange rate between euro and usd: Probabilistic approach versus arima and exponential smoothing techniques," *Journal of Applied Business Research (JABR)*, vol. 28, no. 2, pp. 171–192, 2012.
- [6] D.-Z. Cao, S.-L. Pang, and Y.-H. Bai, "Forecasting exchange rate using support vector machines," in *2005 International Conference on Machine Learning and Cybernetics*, vol. 6, pp. 3448–3452, IEEE, 2005.
- [7] Z. Tang and P. A. Fishwick, "Back-propagation neural nets as models for time series forecasting," *ORSA Journal on Computing*, vol. 5, no. 4, pp. 374–385, 1993.
- [8] J.-H. Wang and J.-Y. Leu, "Stock market trend prediction using arima-based neural networks," in *Proceedings of International Conference on Neural Networks (ICNN'96)*, vol. 4, pp. 2160–2165, IEEE, 1996.
- [9] C. L. Dunis and M. Williams, "Applications of advanced regression analysis for trading and investment," *Applied Quantitative Methods for Trading and Investment*, pp. 1–40, 2003.
- [10] H. Thinyane and J. Millin, "An investigation into the use of intelligent systems for currency trading," *Computational Economics*, vol. 37, no. 4, pp. 363–374, 2011.

- [11] A. K. Nag and A. Mitra, "Forecasting daily foreign exchange rates using genetically optimized neural networks," *Journal of Forecasting*, vol. 21, no. 7, pp. 501–511, 2002.
- [12] G. E. Hinton, S. Osindero, and Y.-W. Teh, "A fast learning algorithm for deep belief nets," *Neural Computation*, vol. 18, no. 7, pp. 1527–1554, 2006.
- [13] J. Chao, F. Shen, and J. Zhao, "Forecasting exchange rate with deep belief networks," in *The 2011 International Joint Conference on Neural Networks*, pp. 1259–1266, IEEE, 2011.
- [14] S. Galeshchuk and S. Mukherjee, "Deep networks for predicting direction of change in foreign exchange rates," *Intelligent Systems in Accounting, Finance and Management*, vol. 24, no. 4, pp. 100–110, 2017.
- [15] P. Escudero, W. Alcocer, and J. Paredes, "Recurrent Neural Networks and ARIMA Models for Euro/Dollar Exchange Rate Forecasting," *Applied Sciences*, vol. 11, no. 2021, 2021.
- [16] H. Abbasimehr, M. Shabani, and M. Yousefi, "An optimized model using LSTM network for demand forecasting," *Computers & Industrial Engineering*, vol. 143, p. 106435, 2020.
- [17] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.
- [18] F. Chollet, "Keras," Available at: <http://keras.io>, (last access: January 2024).