

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

— * —



TRẦN VĂN HÒA

DỰ BÁO TỶ GIÁ NGOẠI TỆ BẰNG
MẠNG NƠ-RON HỌC SÂU

CHUYÊN NGÀNH : KHOA HỌC MÁY TÍNH

MÃ NGÀNH: 60.48.01.01

LUẬN VĂN THẠC SĨ

PGS.TS DƯƠNG TUẤN ANH

TP Hồ Chí Minh, tháng 12 năm 2020

Lời Cảm Ơn

Lời đầu tiên, tôi muốn gửi lời cảm ơn chân thành đến thầy PGS.TS Dương Tuấn Anh, trong thời gian qua, đã hướng dẫn và giúp đỡ tôi trong quá trình thực hiện luận văn tốt nghiệp. Những lời nhận xét, góp ý và hướng dẫn của Thầy đã giúp tôi có hướng đi đúng trong quá trình thực hiện đề tài, giúp chúng tôi thấy được những thuận lợi và hạn chế của các phương pháp tiếp cận khác nhau và từng bước khắc phục để ngày một tốt hơn.

Cám ơn TS. Dương Ngọc Hiếu đã góp ý và sửa chữa cách trình bày, văn phong trong quá trình hoàn thành bài báo khoa học.

Đồng thời tôi cũng muốn gửi lời cảm ơn sâu sắc đến gia đình và bạn bè đã động viên, cổ vũ tinh thần và góp ý trong suốt quá trình học tập và thực hiện đề tài, đặc biệt là gia đình đã chăm lo và hy sinh rất nhiều để tôi có thể chuyên tâm học tập.

Sau cùng, tôi xin kính chúc quý Thầy Cô trong khoa Khoa Học và Kỹ Thuật Máy Tính thật dồi dào sức khỏe, niềm tin để tiếp tục thực hiện sứ mệnh cao đẹp của mình là truyền đạt kiến thức cho thế hệ mai sau.

Thành phố Hồ Chí Minh, 12/2020

Trần Văn Hòa

Tóm Tắt

Bài toán dự báo tỉ giá ngoại tệ là bài toán được nhiều nhà nghiên cứu trong cộng đồng dữ liệu quan tâm. Tỉ giá thay đổi theo từng giờ, thậm chí là từng giây, vì vậy, tạo thành một chuỗi thời gian có mối tương quan với nhau. Để có thể dự báo chính xác với dữ liệu chuỗi thời gian tương quan với nhau, nghiên cứu này đề xuất một mô hình nơ-ron học sâu bằng cách kết hợp 2 phương pháp: auto-encoder và mạng nơ-ron Long Short-time Memory (LSTM). Mô hình này sử dụng auto-encoder dựa trên LSTM để trích xuất thông tin từ dữ liệu đầu vào một mô hình LSTM khác đóng vai trò mô hình dự báo giúp dự đoán kết quả một cách chính xác. Ngoài ra, để nâng khả năng dự báo của mô hình, lý thuyết hỗn loạn được sử dụng để phân tích dữ liệu và tìm các phi tham số một cách hiệu quả. Kết quả thí nghiệm trên 7 tập tỉ giá ngoại tệ cho thấy mô hình chúng tôi đề xuất là hiệu quả và vượt qua được các phương pháp như: mạng nơ-ron cận (ANN), deep belief network (DBN), mạng nơ-ron tích chập (CNN), LSTM và phương pháp kết hợp auto-encoder và LSTM khác với 6/7 tập dữ liệu.

Abstract

Predicting foreign currency exchange rate is the problem in which many researchers in forecasting community have been interested. The exchange rate changes occur hourly, even seconds, thus producing correlated time series. To enable accurate forecasting on such correlated time series data, this work proposes a deep learning model which combines two approaches: autoencoder and Long Short-Term Memory (LSTM) network. The model employs an LSTM-based autoencoder in order to extract features from input dataset well. The model also uses LSTM-based network as a forecaster, which provides accurate and robust forecasting. In addition, to increase the predictability of the model, chaos theory is used to analyze data and find some hyperparameters efficiently. Experimental results on seven exchange rate datasets suggest that the proposed model is effective and outperforms five other comparative methods: shallow neural network (ANN), deep belief network (DBN), convolutional neural network (CNN), LSTM network and another form of combining autoencoder and LSTM network on six out of 7 datasets.

Lời cam đoan

Tôi là Trần Văn Hòa học viên cao học khoa Khoa Học và Kỹ Thuật Máy Tính, Đại học Bách Khoa TP. HCM, MSHV 1870405. Tôi xin cam đoan rằng luận văn thạc sĩ "Dự báo tỷ giá ngoại tệ bằng mạng nơ-ron học sâu" là kết quả tìm hiểu, nghiên cứu độc lập của chính bản thân. Tôi xin cam đoan:

1. Luận văn được thực hiện cho mục đích tìm hiểu và nghiên cứu ở bậc cao học
2. Các công trình, bài báo tham khảo để xây dựng nên luận văn này đều được trích dẫn, tham khảo. Tất cả các tài liệu được trích dẫn và có tính kế thừa từ các tạp chí và các công trình nghiên cứu đã được công bố
3. Những công cụ, phần mềm cho quá trình thực hiện luận văn đều là phần mềm mã nguồn mở
4. Hình ảnh và số liệu được trích dẫn nguồn tham khảo rõ ràng
5. Kết quả nghiên cứu được trình bày trung thực dựa trên số liệu thực tế khi chạy chương trình

Mục lục

1	Giới thiệu vấn đề	1
1.1	Mục tiêu nghiên cứu	1
1.2	Kết quả đạt được	3
1.3	Cấu trúc của luận văn	3
2	Các công trình nghiên cứu liên quan	5
2.1	Phương pháp truyền thống	5
2.2	Phương pháp học máy	6
2.3	Phương pháp học sâu	7
2.4	Kết luận	12
3	Cơ sở lý thuyết	14
3.1	Chuỗi thời gian và dự báo chuỗi thời gian	14
3.2	Mạng nơ-ron nhân tạo (Artificial neural network - ANN):	15
3.3	Deep belief network (DBN)	20
3.3.1	Belief network:	20
3.3.2	Máy Boltzmann giới hạn (Restricted Boltzmann Machine - RBM):	21
3.3.3	Cách thức hoạt động của DBN:	21
3.4	Mạng nơ-ron tích chập - (Convolutional neural network - CNN):	23
3.4.1	Lớp tích chập (convolutional layer):	24
3.4.2	Lớp tổng hợp (pooling layer);	25
3.4.3	Lớp kết nối đầy đủ (Fully-connected layer):	26
3.5	Mạng nơ-ron hồi quy (Recurrent Neural Network - RNN) và Long Short-term memory (LSTM):	27

3.5.1	Mạng nơ-ron hồi quy:	27
3.5.2	Vấn đề của RNN:	28
3.5.3	Long short term memory (LSTM):	29
3.6	Auto-Encoder và mạng nơ-ron Auto-Encoder xếp chồng	31
3.7	Lý thuyết hỗn loạn	33
4	Phương pháp giải quyết vấn đề	36
4.1	Phân tích dữ liệu	36
4.2	Đề xuất mô hình	41
5	Kết quả thực nghiệm	44
5.1	Tiêu chí đánh giá	44
5.2	Thực nghiệm	46
5.3	Kết quả thực nghiệm	50
6	Kết luận	58
6.1	Kết quả đạt được	58
6.2	Hướng nghiên cứu tiếp theo	59
A	Bảng đối chiếu thuật ngữ Anh - Việt	65

Danh sách hình vẽ

2.1	Các bước thực hiện trong nghiên cứu [5]	9
2.2	Dữ liệu được tiền xử lý thành hình ảnh trong nghiên cứu [5] . . .	10
2.3	Kiến trúc mạng CNN được sử dụng trong nghiên cứu [5]	10
2.4	Kiến trúc mô hình ALSTM-FCN [19]	11
2.5	Kiến trúc mô hình SAE-LSTM	13
3.1	Mô hình mạng MLP với một lớp ẩn	16
3.2	Mô hình mạng MLP với hai lớp ẩn	17
3.3	Quy ước đánh chỉ số các trọng số ghép nối giữa cá neuron	18
3.4	Cấu trúc mạng MLP với một lớp vào, một lớp ẩn và một lớp ra .	18
3.5	Mô hình belief network	21
3.6	Mô hình restricted boltzmann machine	21
3.7	Kiến trúc mô hình DBN [30]	22
3.8	Cách tổ chức nơ-rôn của mạng CNN	24
3.9	Minh họa phép tích chập của một bộ lọc 3x3	24
3.10	Một ví dụ của tác vụ tổng hợp trên ảnh 4x4 3 channel: (i),(ii),(iii): max pooling với $W = S = 2$, (iv) max pooling với $W = 3, S = 2$. .	26
3.11	Cấu trúc mạng RNN	27
3.12	Trạng thái khối của LSTM [23]	31
3.13	Kiến trúc mô hình mạng LSTM	31
3.14	Các thành phần của mạng auto-encoder [24]	32
3.15	Cấu trúc của mạng auto-encoder xếp chồng [24]	33
4.1	Phân bố dữ liệu của tỉ giá AUD/USD theo năm	37
4.2	Phân bố dữ liệu của tỉ giá EUR/USD theo năm	38

4.3	Phân bố dữ liệu của tỉ giá NZD/USD theo năm	38
4.4	Phân bố dữ liệu của tỉ giá USD/CAD theo năm	39
4.5	Phân bố dữ liệu của tỉ giá CHF/JPY theo năm	39
4.6	Phân bố dữ liệu của tỉ giá GBP/USD theo năm	40
4.7	Phân bố dữ liệu của tỉ giá USD/JPY theo năm	40
4.8	Kiến trúc mô hình đề xuất	43
5.1	Phân chia tập dữ liệu AUD/USD thành các phần huấn luyện, kiểm định, thử.	46
5.2	Phân chia tập dữ liệu EUR/USD thành các phần huấn luyện, kiểm định, thử.	47
5.3	Phân chia tập dữ liệu NZD/USD thành các phần huấn luyện, kiểm định, thử.	47
5.4	Phân chia tập dữ liệu USD/CAD thành các phần huấn luyện, kiểm định, thử.	48
5.5	Phân chia tập dữ liệu CHF/JPY thành các phần huấn luyện, kiểm định, thử.	48
5.6	Phân chia tập dữ liệu GBP/USD thành các phần huấn luyện, kiểm định, thử.	49
5.7	Phân chia tập dữ liệu USD/JPY thành các phần huấn luyện, kiểm định, thử.	49
5.8	Kết quả dự báo của tỉ giá AUD/USD bằng mô hình AELSTM . .	54
5.9	Kết quả dự báo của tỉ giá EUR/USD bằng mô hình AELSTM . .	55
5.10	Kết quả dự báo của tỉ giá NZD/USD bằng mô hình AELSTM . .	55
5.11	Kết quả dự báo của tỉ giá USD/CAD bằng mô hình AELSTM . .	56
5.12	Kết quả dự báo của tỉ giá CHF/JPY bằng mô hình AELSTM . .	56
5.13	Kết quả dự báo của tỉ giá GBP/USD bằng mô hình AELSTM . .	57
5.14	Kết quả dự báo của tỉ giá USD/JPY bằng mô hình AELSTM . .	57

Danh sách bảng

5.1	Kiến trúc của các mô hình tương ứng với từng bộ dữ liệu thực nghiệm.	50
5.2	Tham số của các tập dữ liệu tỉ giá ngoại tệ có tính chất hỗn loạn	50
5.3	Độ lỗi MAE của 7 bộ dữ liệu khi $k=1$	51
5.4	Độ lỗi RMSE của 7 bộ dữ liệu khi $k=1$	51
5.5	Độ lỗi MAPE của 7 bộ dữ liệu khi $k=1$	52
5.6	Độ lỗi MAE của 4 bộ dữ liệu khi $k=7$	53
5.7	Độ lỗi RMSE của 4 bộ dữ liệu khi $k=7$	53
5.8	Độ lỗi MAPE của 4 bộ dữ liệu khi $k=7$	54

Chương 1

Giới thiệu vấn đề

1.1 Mục tiêu nghiên cứu

Trên thế giới, thị trường ngoại hối là thị trường tài chính lớn nhất, với doanh thu mỗi ngày hơn 5 tỷ đô la, nó là xương sống của thị trường mại quốc tế [6]. Tỷ giá tiền tệ được xác định dựa trên một cặp tiền tệ cơ sở, nó thể hiện cho số đơn vị tiền tệ được trao đổi cho mỗi đơn vị tiền tệ cơ sở. Đối với các cá nhân, tổ chức thực hiện các giao dịch bằng ngoại tệ, *tỷ giá hối đoái* (exchange rate) góp phần lớn vào doanh thu của họ. Đối với mỗi quốc gia, tỷ giá tiền tệ liên quan mật thiết với an ninh quốc gia. Để ổn định nền kinh tế trong nước, chính phủ phải đảm bảo giữ tỷ giá tiền tệ ở mức hợp lý. Bởi vì nếu đồng nội tệ mất giá thì lạm phát sẽ tăng. Ngược lại, nếu nội tệ lên giá thì sản xuất trong nước sẽ giảm do người dân sẽ sử dụng sản phẩm nhập khẩu với giá thấp hơn dẫn tới tình trạng thu hẹp sản xuất, người dân thất nghiệp. Với bất kỳ mục tiêu nào, dự báo chính xác xu hướng tỷ giá ngoại hối là một yếu tố quan trọng của bất kỳ chiến lược kinh doanh hiệu quả nào trên thị trường ngoại hối để thực hiện giao dịch [27].

Với những đặc tính phức tạp và hỗn loạn của thị trường hối đoái nên dự đoán tỷ giá ngoại hối được biết đến là một bài toán khó. Các mô hình kinh tế truyền thống dùng để dự báo xu hướng tỷ giá ngoại hối cũng đã đạt được sự chính xác còn giới hạn. Bởi vì, tỷ giá thay đổi ngoại hối bị ảnh hưởng bởi nhiều yếu tố có liên quan mật thiết với nhau. Những yếu tố này có thể là kinh tế, chính trị, ... Vì vậy, những phương pháp truyền thống phân tích chỉ dựa trên lĩnh vực tài chính

sẽ không cho độ chính xác cao. Trong thập niên qua, với sự phát triển mạnh mẽ của học máy, những phương pháp tiên tiến chẳng hạn như mạng nơ-ron nhân tạo có thể dự đoán chính xác hơn, nhưng phụ thuộc nhiều vào dữ liệu để huấn luyện mô hình. Vì vậy, phương pháp này thường tốn rất nhiều chi phí để làm dữ liệu, bởi vì phải cần nhiều chuyên gia trong lĩnh vực này.

Gần đây, trong các phương pháp học máy, *mạng nơ-ron học sâu* (deep neural network - DNN) đã chứng minh được tính hiệu quả trong việc dự báo nhiều vấn đề phức tạp ở nhiều lĩnh vực khác nhau. Đặc điểm của những mô hình này là khả năng học được những *đặc trưng trừu tượng* (abstract feature) của dữ liệu [21]. Các *mạng nơ-ron tích chập* - CNN (convolutional neural network) có thể đạt được độ chính xác tới 70% [13]. Mạng học sâu đã vượt qua có cách phương pháp học máy truyền thống trước đây như SVM, mạng nơ-ron nhân tạo nông.

Các mạng nơ-ron kể trên có điểm yếu là không có khả năng ghi nhớ những ngữ cảnh trước đó. Ví dụ, khi dịch từ trong câu, để có thể dịch chính xác mô hình cần biết được ngữ cảnh của các từ trước đó. Đây có thể coi là khuyết điểm chính của mạng nơ-ron truyền thống. *Mạng nơ-ron hồi quy* (Recurrent neural network - RNN) sinh ra để giải quyết vấn đề đó [28]. Mạng này chứa các vòng lặp bên trong cho phép thông tin có thể lưu lại được. Dữ liệu của bài toán dự báo tỷ giá ngoại hối là dạng dữ liệu chuỗi thời gian, xu hướng của tăng giảm của tỷ giá phụ thuộc và tình trạng của thị trường trước đó. Đây chính là động lực để chúng tôi nghiên cứu sự hiệu quả của các kiến trúc mạng học sâu, đặc biệt là mạng hồi quy và các cải tiến của mạng này trong dự đoán xu hướng của tỷ giá ngoại hối. Tuy nhiên, RNN có nhược điểm là không thể ghi nhớ được nhiều thông tin ở xa phía trước đó vì lý do bùng nổ gradient hay triệt tiêu gradient. Do đó, mạng LSTM được sử dụng để giải quyết những vấn đề của RNN. Bên cạnh đó, auto-encoder cũng được nhiều nhà khoa học sử dụng như là một phương pháp trích xuất thông tin hiệu quả và kết hợp với LSTM trong dự báo chuỗi thời gian [3], [23].

1.2 Kết quả đạt được

Trong nghiên cứu này, chúng tôi đề xuất một phương pháp học sâu để dự báo giá trị đóng phiên giao dịch của những ngày trong tương lai dựa trên những thông tin trong quá khứ như giá trị cao nhất, thấp nhất, đóng phiên và mở phiên của các phiên giao dịch trong ngày. Phương pháp chúng tôi đề xuất là mô hình kết hợp giữa một mô hình dữ báo có kiến trúc LSTM với một mô hình auto-encoder dựa trên LSTM để tận dụng khả năng ghi nhớ thông tin của LSTM với dữ liệu chuỗi thời gian và khả năng trích thông tin của auto-encoder. Ngoài ra, chúng tôi sử dụng *lý thuyết hỗn loạn* (chaos theory) để phân tích dữ liệu và nâng cao khả năng dự báo của mô hình. Trong thực nghiệm, chúng tôi sử dụng bộ dữ liệu tỉ giá giữa đồng E-rô và đô-la Mỹ (EUR/USD), đồng Úc và đồng đô-la Mỹ (AUD/USD), đồng New Zealand và đồng đô-la Mỹ (NZD/USD), đồng đô-la Mỹ và Canada (USD/CAD), đồng Thụy Sĩ và đồng Yên (CHF/JPY), đồng đô-la Mỹ và Yên (USD/JPY), đồng bảng Anh và đô-la Mỹ (GBP/USD), và 3 thước đo để đánh giá hiệu quả của mô hình. Kết quả thực nghiệm cho thấy phương pháp chúng tôi đề xuất hiệu quả và vượt qua được những mô hình khác như: ANN, deep belief network (DBN), mạng nơ-ron tích chập (CNN), LSTM và phương pháp kết hợp giữa LSTM với auto-encoder khác.

1.3 Cấu trúc của luận văn

Cấu trúc của báo cáo được tổ chức như sau:

- Chương 1 - Giới thiệu vấn đề: nhằm giới thiệu tổng quan về bài toán dự báo tỉ giá ngoại tệ và phương pháp giải quyết.
- Chương 2 - Các nghiên cứu liên quan: bao gồm các công trình nghiên cứu liên quan đến bài toán dự báo chuỗi thời gian nói chung và dự báo tỉ giá ngoại tệ nói riêng.
- Chương 3 - Cơ sở lý thuyết: trình bày những lý thuyết liên quan được sử dụng trong bài nghiên cứu

- Chương 4 - Phương pháp nghiên cứu: phân tích đặc điểm của dữ liệu và trình cụ thể mô hình đề xuất và cách thức mô hình hoạt động
- Chương 5 - Kết quả thực nghiệm: là kết quả đánh giá của phương pháp đề xuất và so sánh với các phương pháp khác
- Chương 6 - Kết luận: nêu ra các kết luận đúc kết được trong quá trình nghiên cứu và hướng phát triển tiếp theo trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Chương này trình bày các công trình liên quan được chúng tôi tìm hiểu trong quá trình nghiên cứu thực hiện đề tài. Dựa vào các kỹ thuật giải quyết bài toán khác nhau, có thể chia các công trình đã thực hiện thành các nhóm:

- Phương pháp truyền thống
- Phương pháp học máy
- Phương pháp học sâu

Dự đoán giá trị tỉ giá ngoại hối là một bài toán đầy thách thức bởi vì tỉ giá tiền tệ không ổn định, hỗn loạn, có nhiều nhiễu [2] và đặc biệt là một hệ thống phi tuyến với sự tương hỗ phức tạp giữa các nhân tố. Chính vì thế mà không có một thông tin đầy đủ nào có thể thể hiện mối quan hệ chính xác giữa giá trị ở tương lai và những hành vi xảy ra trong quá khứ. Một giả định thường được sử dụng khi giải quyết bài toán này là dữ liệu lịch sử có thể đại diện được cho tất cả các yếu tố tác động trong quá khứ.

2.1 Phương pháp truyền thống

Trong nhiều năm trước đây, các nhà nghiên cứu sử dụng các kỹ thuật tuyến tính để giải quyết bài toán dự đoán tỷ giá ngoại tệ, như kỹ thuật Auto-Regressive

Integrated Moving Average (ARIMA) [7] và *làm mịn mũ* (Exponential Smoothing - ES) [26]. Maniatis và các cộng sự [26] đã tiến hành dự báo tỉ giá giữa đồng E-rô và đô-la Mỹ sử dụng phương pháp ARIMA và ES. Các mô hình này cho kết quả còn hạn chế vì đơn giản chỉ là tính toán xác suất đối với những thay đổi ngắn hạn của tỉ giá hối đoái nằm trong các phạm vi cụ thể. Vì đơn giản và phổ biến nên phương pháp này được sử dụng rộng rãi để so sánh các mô hình hiện tại. Tuy nhiên, phương pháp này lại giả định dữ liệu chuỗi thời gian là tuyến tính và ổn định, vì vậy, nó không phù hợp với các bài toán với dữ liệu phi tuyến và hỗn loạn.

2.2 Phương pháp học máy

Nhiều phương pháp học máy cũng được áp dụng vào bài toán dự báo chuỗi thời gian nói riêng và dự báo tỉ giá ngoại tệ nói chung. Cao và các cộng sự [8] sử dụng phương pháp support vector machine (SVM) để dự báo giá trị đóng phiên giao dịch của tỉ giá đồng bảng Anh và đô-la Mỹ (GBP/USD). Để lựa chọn được các giá trị tham số phù hợp với mô hình, các tác giả tiến hành thực nghiệm với nhiều bộ tham số khác nhau và chọn bộ tham số cho kết quả tốt nhất. Kết quả của mô hình dự báo còn cách giá trị thực tế một khoảng cách lớn. Với đặc điểm có thể mô hình hóa các bài toán phi tuyến, artificial neural networks (ANN) được sử dụng phổ biến trong các bài toán dự báo chuỗi thời gian. Nhiều nghiên cứu đã chứng minh rằng ANN là một kỹ thuật hiệu quả trong bài toán dự báo dữ liệu tài chính. Tang và Fishwich [33], Wang và Leu [36] đã chỉ ra rằng ANN cho kết quả tốt hơn kỹ thuật ARIMA, đặc biệt với các dữ liệu không ổn định. Dunis [11] đã chứng minh với mạng ANN đơn giản gồm 12 nơđ đầu vào (input node), 7 nơđ ẩn (hidden node) và 1 nơđ kết quả dự đoán đầu ra (output node) cho kết quả dự đoán chính xác hơn các phương pháp truyền thống moving average convergence-divergence, autoregressive moving average (ARMA). Thinyane [34] và Millin chỉ ra rằng với kiến trúc ANN càng phức tạp thì kết quả dự đoán càng chính xác. Kết quả này nhờ vào khả năng biểu diễn xấp xỉ bất kỳ hàm liên tục nào và là mô hình *phi tham số* (non-parametric), không cần bất kỳ giả định nào về đặc tính của dữ liệu đầu vào. Nhưng vì kết nối giữa các lớp trong ANN

khá lớn dẫn đến trọng số của kiến trúc này nhiều. Vì thế, ANN không thể xây dựng được các mô hình phức tạp và dễ bị hiện tượng quá khớp mà không thể làm tốt với dữ liệu ngoài thực tế. Để giải quyết vấn đề này Nag và Mitra [29] đã sử dụng giải thuật di truyền để tìm kiếm các siêu tham số cho mô hình như giá trị của hệ số học (learning rate), giá trị *quán tính* (momentum), số lớp ẩn, số nơ-ron ở mỗi lớp, hàm kích hoạt.

2.3 Phương pháp học sâu

Với sự kết hợp giữa các lớp nơ-ron ẩn và mô hình xác suất *máy Boltzmann giới hạn* (restricted Boltzmann machine - RBM), Hinton và các cộng sự [15] đã phát minh ra kiến trúc Deep belief network (DBN). DBN đã chứng tỏ được sức mạnh của mình qua việc giải quyết tốt nhiều loại bài toán khác nhau như: phân lớp [22], thu giảm chiều [16], trích xuất thông tin [37]. Và DBN cũng được kiểm chứng trong lĩnh vực tài chính, Chao và các cộng sự [9] đã sử dụng phương DBN để giải quyết bài toán dự đoán tỉ giá ngoại tệ giữa đồng bản Anh và đồng đô-la Mỹ, giữa đồng Ấn Độ và đô-la Mỹ. Bằng phương pháp thực nghiệm, tác giả đã xây dựng kiến trúc 6-16-8-1 với 6 nơ-ron dữ liệu đầu vào, 16 nơ-ron ẩn ở lớp ẩn đầu tiên, và 1 nơ-ron đầu ra cho tập dữ liệu tỉ giá Anh và đô-la Mỹ và kiến trúc 10-3-3-1 cho tập dữ liệu tỉ giá Ấn Độ và đô-la Mỹ. Kết quả của thí nghiệm đã chứng minh DBN vượt trội hơn so với phương pháp mạng nơ-ron truyền thẳng thông thường.

Với sự phát triển của phần cứng trong những năm gần đây, những mô hình mạng học sâu như: *mạng nơ-ron tích chập* (convolutional neural network - CNN), *mạng nơ-ron hồi quy* (recurrent neural network - RNN) đã thể hiện được sự ưu việt của chúng trong nhiều bài toán phức tạp. CNN được biết nhiều đến với các bài toán về xử lý ảnh, với khả năng có thể phân loại ảnh có thể so sánh với khả năng con người. Không những thế CNN cũng đang dần được áp dụng vào các bài toán về phân tích và dự báo chuỗi thời gian. Galeshchuk và Mukherjee năm 2017 [13] đã áp dụng CNN để phân loại xu hướng của dữ liệu tỉ giá ngoại hối. Tỉ giá đóng cửa hằng ngày từ năm 2010 đến năm 2015 của đồng EURO và đồng đô-la Mỹ (EUR/USD), đồng bảng Anh và đô-la Mỹ (GBP/ USD), đồng đô-la

Mỹ và yên Nhật (USD/JPY) được sử dụng để phân tích với 1043 giá trị đóng cửa từ năm 2010 đến năm 2013 được sử dụng cho huấn luyện và 522 giá trị được sử dụng để đánh giá phương pháp. Chỉ bằng cách xây dựng mô hình CNN đơn giản với 4 lớp tích chập (convolutional layer) với tham số kernel của chiều rộng (width), chiều cao (height), chiều sâu (depth), bước dịch chuyển (stride), số ô được chèn thêm (padding) tương ứng lần lượt là 5, 1, 1, 2, 0, kết hợp với hàm tối ưu Adam, hàm kích hoạt softmax đã chứng minh rằng CNN cho kết quả tốt hơn đáng kể so với các phương pháp ARIMA, ANN. Điều này được lý giải bằng khả năng trích xuất thông tin tốt hơn từ dữ liệu của các kiến trúc mạng học sâu.


Bên cạnh đó để tận dụng khả năng ưu việt của CNN đối với dữ liệu dạng ảnh, Tsai và các cộng sự năm 2018 [35], Berat Sezer và các cộng sự năm 2019 [5] đã chuyển dữ liệu tỷ giá ngoại tệ thành dạng ảnh trước khi huấn luyện CNN. Trong nghiên cứu này, các tác giả thực hiện các bước sinh dữ liệu hình ảnh từ dữ liệu chứng khoán, gán nhãn cho ảnh vừa tạo ra và huấn luyện mô hình CNN như hình 2.1 để xác định "Buy", "Sell" hoặc "Hold" cổ phiếu. Dữ liệu cổ phiếu Dow Jones 30 trong thời gian 30 ngày sẽ được biểu diễn thành hình ảnh 2 chiều có kích thước 30x30 pixel với giá của cổ phiếu theo trục y và thời gian theo trục x. Từ đó, 2500 ảnh (1/1/1997 đến 12/31/2006), 3750 ảnh (1/1/1997 đến 12/31/2012) được sinh ra cho tập huấn luyện và khoảng 2500 ảnh (1/1/2007 đến 1/1/2017), 1250 ảnh (1/1/2012 đến 12/31/2017) cho tập đánh giá. Ở bước gán nhãn dữ liệu, mỗi hình sẽ được gán một trong 3 nhãn "Buy", "Sell", "Hold" để biểu diễn cho xu hướng của tương lai theo công thức 2.1. Dữ liệu đã được xử lý được mô tả qua hình 2.2

$$slopeRef[1..n] = \frac{value34 - value30}{day34 - day30}$$

$$slopeCurrent = \frac{value45 - value30}{day45 - day30}$$

$$\begin{cases} 1 = ('Buy'), & \text{if } slopeCurrent > slopeRef[3n/5] \\ 0 = ('Hold'), & \text{if } (slopeRef[2n/5] < slopeCurrent) \& \& (slopeRef[3n/5] > slopeCurrent) \\ 2 = ('Sell'), & \text{if } slopeCurrent < slopeRef[2n/5] \end{cases} \quad (2.1)$$

$$AR = \left(\left(\frac{totalMoney}{startMoney} \right)^{\frac{1}{numberOfYears}} - 1 \right) * 100 \quad (2.2)$$




Hình 2.1: Các bước thực hiện trong nghiên cứu [5]


Trong bước huấn luyện mạng CNN được xây dựng gồm 8 lớp như hình 2.3. Kết quả của mô hình đề xuất có thể tạo ra các kết quả nhìn chung nhất quán và có thể đánh bại chiến lược "Buy" and "Hold" (công thức 2.2) tùy thuộc vào điều kiện thị trường.

Tuy nhiên các mạng nơ-ron truyền thống nói chung và CNN nói riêng chỉ nhận dữ liệu đầu vào là các giá trị độc lập. Điều này làm cho mất đi mối tương quan quan trọng giữa các giá trị đầu vào với nhau.

RNN được biết đến như là công cụ để giải quyết các bài toán về các loại dữ liệu có mối quan hệ theo thời gian với nhau như: dịch máy, chuyển giọng nói



Hình 2.2: Dữ liệu được tiền xử lý thành hình ảnh trong nghiên cứu [5]




Hình 2.3: Kiến trúc mạng CNN được sử dụng trong nghiên cứu [5]

thành chữ và ngược lại,... Trong đó Long short time memory (LSTM) được sử dụng phổ biến vì nó giải quyết được vấn đề triệt tiêu và bùng nổ giá trị khi huấn luyện mô hình RNN truyền thống. Dữ liệu chuỗi thời gian nói chung và tỉ giá ngoại tệ nói riêng đều có sự tương hỗ giữa các giá trị theo thời gian. Vì thế, trong những năm gần đây, nhiều nhà nghiên cứu đã bắt đầu ứng dụng LSTM và trong các bài toán phân loại, dự đoán giá trị của chuỗi thời gian và đạt kết quả tốt so với các kỹ thuật khác [14, 25, 10]. Không những thế kết quả nghiên cứu còn có thể được sử dụng vào trong các ứng dụng thực tế của đời sống.

Karim và các cộng sự năm 2017 [19] đã sử dụng phương pháp kết hợp giữa mạng tích chập đầu đủ (fully convolutional network -FCN) và attention LSTM (ALSTM) để xây dựng mô hình dự báo ALSTM-FCN như hình 2.4. Dữ liệu sẽ

được truyền thẳng đồng thời qua mô hình FCN và ALSTM trước khi ghép để đi qua hàm kích hoạt softmax dự đoán kết quả cuối cùng. Ngoài ra để nâng cao độ chính xác của mô hình, Karim sử dụng thêm phương pháp huấn luyện tinh chỉnh (fine-tuning) mô hình qua 2 giai đoạn. Giai đoạn đầu tiên, mô hình khởi tạo (initial model) được huấn luyện với bộ siêu tham số tối ưu với tập dữ liệu. Giai đoạn thứ 2, fine-tuning được áp dụng cho mô hình khởi tạo ở bước 1 với cùng tập dữ liệu gốc. Ở mỗi bước lặp, mô hình được khởi tạo bằng trọng số của mô hình ở bước trước đó, tỉ lệ học (learning rate) và kích thước đầu vào (batch size) giảm một nửa so với bước lặp trước đó. Quá trình huấn luyện diễn ra qua 5 lần lặp như giải thuật. Kết quả mô hình được đánh giá trên tập dữ liệu của UCR với thang đo là độ lỗi trung bình trên mỗi lớp (Mean Per Class Error) với độ chính xác cao hơn các phương pháp tốt nhất ở thời điểm đó.



Hình 2.4: Kiến trúc mô hình ALSTM-FCN [19]


Jiang và các cộng sự năm 2018 [18] bằng cách xây dựng mô hình LSTM đơn giản với 3 lớp gồm lớp dữ liệu đầu vào, lớp ẩn và lớp dữ liệu đầu ra cũng cho kết quả dự đoán xu hướng khá khớp với tập dữ liệu chỉ số chứng khoán Dow Jones và Shanghai Composite. Cũng qua thí nghiệm này, tác giả đã chứng minh được rằng kiến trúc mạng LSTM cho kết quả chính xác hơn kiến trúc mạng RNN cho bài toán tài chính.

Bên cạnh đó, Li và các cộng sự năm 2018 [23] sử dụng kết hợp LSTM và auto-encoder để xây dựng mô hình dự đoán mô hình SAE-LSTM để dự đoán nồng độ

oxy hòa tan trong nước như hình 2.5. Mô hình gồm 2 thành phần: auto-encoder với kiến trúc MLP với thiết kế gồm 1 lớp với 100 nôt ẩn (hidden node) và tầng LSTM với 50 nôt ẩn được chồng lên trên tầng encoder của auto-encoder. Dữ liệu được thu thập 10 phút/lần trong 20 ngày liên tục tại một hồ tôm với các thông số như nhiệt độ nước, nồng độ oxy hòa tan, tốc độ gió, áp suất không khí, áp suất nhiệt độ, nồng độ pH, độ ẩm. Dữ liệu sẽ được tiền xử lý để nội suy những giá trị bị thiếu, và chuẩn hóa dữ liệu. Giai đoạn huấn luyện được thực hiện qua 2 bước. Bước đầu tiên, mô hình auto-encoder được huấn luyện với dữ liệu đã được chuẩn hóa. Bước tiếp theo, dữ liệu nhiều chiều từ lớp encoder của auto-encoder sau khi được huấn luyện ở bước 1 được dùng để huấn luyện mô hình LSTM dự đoán kết quả cuối cùng. Kết quả dự đoán của mô hình này vượt trội hơn so với kết quả từ các phương pháp LSTM, BPNN, SAE-BPNN.

2.4 Kết luận

Qua quá trình nghiên cứu tìm hiểu các công trình liên quan đến bài toán chuỗi thời gian nói chung và bài toán dự báo tỉ giá ngoại hối nói riêng, chúng tôi thấy rằng đây là lĩnh vực nhiều nhà nghiên cứu quan tâm và áp dụng nhiều phương pháp để giải quyết từ những phương pháp thống kê truyền thống cho đến những mô hình học sâu phức tạp. Với sự phát triển mạnh mẽ của phần cứng, các mô hình học sâu dễ dàng vượt qua được những phương pháp cổ điển hoặc mạng nơ-ron cạn. Mạng CNN đã cho thấy được sự vượt trội của nó với dữ liệu hình ảnh với khả năng trích xuất được nhiều thông tin hơn bằng kiến trúc sâu hơn so với ANN truyền thống. Trong khi đó RNN và LSTM với thiết kế để xử lý dữ liệu dạng chuỗi, thể hiện được sự tương hỗ của dữ liệu được áp dụng thành công vào nhiều bài toán như dịch máy, nhận diện giọng nói, chuyển đổi chữ thành giọng nói và ngược lại,... Điều này thúc đẩy chúng tôi sử dụng kiến trúc LSTM để thực hiện nghiên cứu này.



Hình 2.5: Kiến trúc mô hình SAE-LSTM

Chương 3

Cơ sở lý thuyết

Chương này sẽ giải thích về chuỗi thời gian ở mục 3.1, tiếp theo trình bày chi tiết về lý thuyết về các kiến trúc mạng nơ-ron được chúng tôi áp dụng để nghiên cứu cũng như xây dựng các mô hình đối sánh trong phần 3.2, 3.3, 3.4, 3.5, 3.6. Bên cạnh đó lý thuyết hỗn loạn và phương pháp xác định chuỗi thời gian hỗn loạn cũng được trình bày trong phần 3.7.

3.1 Chuỗi thời gian và dự báo chuỗi thời gian

Chuỗi thời gian (time series) có thể được định nghĩa như một chuỗi các giá trị được đo lường trong một khoảng thời gian đều đặn. Từ vào tần suất đo lường, một chuỗi thời gian có thể là hàng năm, hàng quý, hàng tháng,... Chuỗi thời gian tạo ra sự khác biệt so với bài toán hồi quy thông thường ở 2 điểm.

- Chuỗi thời gian có tính chất phụ thuộc vào thời gian.
- Trong mô hình hồi quy tuyến tính, các quan sát là độc lập nhưng trong trường hợp này, các quan sát phụ thuộc vào thời gian. Và có thể có xu hướng thời vụ trong chuỗi thời gian.

Chuỗi thời gian có thể có một hoặc nhiều biến thay đổi theo thời gian.

- *Chuỗi thời gian đơn biến* (Univariate time series) khi chỉ có một biến thay đổi theo thời gian.

- *Chuỗi thời gian đa biến* (Multivariate time series) khi có nhiều hơn một biến thay đổi theo thời gian.

Dự báo chuỗi thời gian (time series forecasting) là xây dựng một mô hình phù hợp với dữ liệu lịch sử và sử dụng chúng để dự báo giá trị quan sát được trong tương lai. Ở bước đầu tiên, các quan sát trong quá khứ được thu thập và phân tích để phát triển một mô hình toán học phù hợp nắm bắt quá trình tạo dữ liệu của chuỗi. Ở bước thứ hai, giá trị trong tương lai được dự báo mô hình. Cách tiếp cận này hiệu quả cả khi thiết mô hình thống kê giải thích. Đưa ra dự đoán về tương lai được gọi là ngoại suy trong việc xử lý thống kê cổ điển đối với dữ liệu chuỗi thời gian. Khả năng của mô hình dự báo chuỗi thời gian được xác định bởi hiệu suất dự đoán trong tương lai của nó. Dự báo chuỗi thời gian có những ứng dụng quan trọng trong các lĩnh vực khác nhau. Trong nhiều thập kỷ qua, các nhà nghiên cứu đã có nhiều nỗ lực nhằm phát triển và cải tiến các mô hình dự báo chuỗi thời gian phù hợp.

3.2 Mạng nơ-ron nhân tạo (Artificial neural network - ANN):


Qua quá trình nghiên cứu về bộ não , các nhà khoa học nhận thấy rằng: Hệ thần kinh con người được mô tả là một hệ thống gồm 3 phần tử chính bao gồm các đầu dây thần kinh cảm ứng (receptors), hệ thống thần kinh trung tâm.(brain, neuron nets) và hệ thống chấp hành (effectors). Các thần kinh cảm ứng thu thập các tác động từ môi trường bên ngoài, chuyển thành tín hiệu điện và chuyển về hệ thần kinh trung ương. Tại đây, các tín hiệu sẽ được não bộ phân tích, xử lý và đưa ra các quyết định điều khiển. Các tín hiệu điều khiển này sẽ được chuyển tới các cơ quan chấp hành để thực hiện. Trong đó, nơ-ron là phần tử cơ bản của hệ thần kinh.

ANN là mô hình tính toán được xây dựng dựa trên ý tưởng của nơ-ron sinh học. Nó gồm các nơ-ron nhân tạo nối với nhau, và xử lý thông tin bằng cách truyền theo các kết nối và tính giá trị mới tại các nơ-ron. Về mặt lý thuyết, ta có thể xây dựng một mạng với cách ghép nối tùy ý. Tuy nhiên phổ biến nhất là *mạng truyền thẳng* (multilayer perception - MLP). Mạng MLP là một mạng


truyền thẳng với các khối cơ bản là các neuron McCulloch-Pitts. Ngoài ra mạng MLP còn có một số yêu cầu sau về cấu trúc của mạng:

- Các nơ-ron được sắp xếp thành các lớp (layer), mạng gồm một lớp để nhận các tín hiệu đầu vào (input layer), một lớp gồm các tín hiệu đầu ra (output layer) và có thể gồm một số lớp trung gian gọi chung là các lớp ẩn (hidden layer).
- Không có các kết nối giữa các nơ-ron trên cùng một lớp mà chỉ có các kết nối giữa các nơ-ron của hai lớp liên tiếp. Các kết nối đều có chiều hướng đi từ đầu vào đến đầu ra (mạng truyền thẳng).
- Các nơ-ron trên cùng một lớp sẽ có cùng *hàm truyền* (transfer function).

Hình 3.1 và 3.2 là hai mô hình của mạng MLP:




Hình 3.1: Mô hình mạng MLP với một lớp ẩn



Hình 3.2: Mô hình mạng MLP với hai lớp ẩn


Về mặt lý thuyết, ta có thể xây dựng mạng MLP với số lượng lớp ẩn tùy ý, tuy nhiên các nghiên cứu đã chứng minh được rằng ta chỉ cần sử dụng tối đa hai lớp ẩn là có thể mô hình hóa một hàm phi tuyến với độ chính xác tùy chọn. Vì vậy trong thực tế ta thường chỉ các mạng không có hoặc có một hay hai lớp ẩn. Trong số đó phần lớn chỉ dùng mạng có một lớp ẩn do mạng không có lớp ẩn thì quá đơn giản, còn mạng có hai lớp ẩn trở nên lại quá phức tạp. Vì vậy trong các vấn đề được trình bày tiếp theo dưới đây sẽ sử dụng mạng có một lớp ẩn, các công thức cho mạng với cấu trúc khác có thể dễ dàng phát triển một cách tương tự.

Để thuận tiện cho việc theo dõi, trong các công thức của mạng MLP, ta có quy ước về đánh chỉ số các trọng số kết nối giữa các phần tử của mạng như hình 3.3: nếu phần tử ngọn có chỉ số là i và phần tử gốc có phần tử là j thì trọng số kết nối giữa hai phần tử đó sẽ có chỉ số là ij .



Hình 3.3: Quy ước đánh chỉ số các trọng số ghép nối giữa cá neuron

Cấu trúc một mạng MLP với một lớp ẩn, trong đó mạng có N đầu vào, M nơ-ron trên lớp ẩn và K đầu ra. Như hình 3.4, nếu ký hiệu chung các trọng số kết nối giữa lớp đầu vào và lớp ẩn là W_{ij} thì ta có $i = 1, 2, \dots, M; j = 0, 1, 2, \dots, N$. Nếu ký hiệu các trọng số kết nối giữa lớp ẩn và lớp đầu ra là V_{ij} thì ta có $i = 1, 2, \dots, K; j = 0, 1, 2, \dots, M$. Tổng hợp lại ta có các giá trị W_{ij} tạo thành $\mathbf{W} \in R^{M \times (N+1)}$ là ma trận các hệ số kết nối giữa lớp đầu vào là lớp ẩn, các giá trị V_{ij} tạo thành $\mathbf{V} \in R^{K \times (M+1)}$ là ma trận các hệ số kết nối giữa lớp ẩn và lớp đầu ra.



Hình 3.4: Cấu trúc mạng MLP với một lớp vào, một lớp ẩn và một lớp ra

Mạng MLP với một lớp ẩn có thể được đặc trưng bởi các thông số sau:

- Bộ ba (N, M, K) , trong đó N – số đầu vào, M – số nơ-ron thuộc lớp ẩn, K – số nơ-ron ở lớp đầu ra.
- Các hàm truyền đạt: f_1 của lớp ẩn và f_2 của lớp đầu ra.

- Ma trận trọng số $\mathbf{W}$ kết nối giữa lớp đầu vào và lớp ẩn, ma trận trọng số kết nối $\mathbf{V}$ giữa lớp ẩn và lớp đầu ra.

Khi đó, với véc tơ đầu vào $x = [x_1, x_2, \dots, x_N] \in R^N$ (đầu vào phân cực cố định $x_0 = 1$), ta có đầu ra được xác định tuần tự theo chiều *lan truyền thuận* (*forward propagation*) như sau:

1. Tính tổng các kích thích đầu vào của neuron ẩn thứ i (cho $i = 1, 2, \dots, M$):

$$u_i = \sum_{j=0}^N x_j W_{ij} \quad (3.1)$$

2. Tính đầu ra của neuron ẩn thứ i (cho $i = 1, 2, \dots, M$):

$$v_i = f_1(u_i) \quad (3.2)$$

3. Tính tổng kích thích đầu vào của neuron đầu ra thứ i (cho $i = 1, 2, \dots, K$):

$$g_i = \sum_{j=0}^M v_j V_{ij} \quad (3.3)$$

4. Và cuối cùng ta có đầu ra thứ i của mạng (cho $i = 1, 2, \dots, K$) sẽ bằng:

$$y_i = f_2(g_i) \quad (3.4)$$

Tổng hợp lại ta có hàm truyền đạt của mạng MLP là một hàm phi tuyến cho theo công thức phụ thuộc sau:

$$y_i = f_2(g_i) = f_2 \left(\sum_{j=0}^M v_j V_{ij} \right) = f_2 \left(\sum_{j=0}^M f_1(u_j) V_{ij} \right) = f_2 \left(\sum_{j=0}^M \left[f_1 \left(\sum_{k=0}^N x_k W_{jk} \right) V_{ij} \right] \right) \quad (3.5)$$

Quá trình điều chỉnh các thông số của mạng để thích nghi với bộ số liệu được gọi là *quá trình học* của mạng MLP hay còn được gọi là quá trình *huấn luyện* mạng MLP theo một bộ dữ liệu mẫu cho trước. Trong khi các thông số cấu trúc như số lớp nơ-ron, các hàm truyền đạt của mỗi lớp, số nơ-ron trên mỗi lớp

thường được chọn bằng thực nghiệm hoặc bằng phương pháp thử các giá trị rời rạc nhất định thì các thông số trọng số ghép nối giữa các neuron có thể được điều chỉnh bằng thuật toán lan truyền ngược (back propagation). Giải thuật này dựa trên lý lệ lỗi của hàm mất mát (loss function) có được trong bước lặp trước đó để tinh chỉnh trọng số của mô hình. Việc điều chỉnh trọng số sao cho tỷ lệ lỗi thấp hơn làm cho mô hình trở nên đáng tin cậy bằng cách tăng tính tổng quát của nó.


3.3 Deep belief network (DBN)

Deep belief network, là một loại thuộc mạng nơ-ron học sâu, bao gồm nhiều lớp (layer) đồ thị vô hướng và có hướng. Đó là sự kết hợp của nhiều lớp của các đơn vị ẩn (hidden unit), trong đó các đơn vị ẩn ở mỗi lớp không nối với nhau mà chỉ nối ở các lớp. DBN gồm hai thành phần chính:

3.3.1 Belief network:

Nó là một đồ thị một chiều gồm nhiều biến nhị phân ngẫu nhiên được sắp thành từng lớp, các biến ngẫu nhiên này sẽ có trạng thái là 0 hoặc 1 và xác suất mang giá trị 1 được xác định bởi trọng số từ cạnh nối với các biến khác như hình 3.5. Theo Geoffrey Hinton mạng deep belief net có hai đặc tính chất chính là:


- Các trọng số trong mạng có thể được học qua từng lớp một theo thứ tự từ trên xuống để xác định các biến ở lớp dưới phụ thuộc như thế nào với các biến ở lớp trên
- Sau quá trình huấn luyện, kết quả sẽ được mạng suy diễn ra từ dữ liệu đưa vào theo chiều ngược lại, từ dưới lên.



Hình 3.5: Mô hình belief network

3.3.2 Máy Boltzmann giới hạn (Restricted Boltzmann Machine - RBM):

Boltzmann Machine là *mạng nơ-ron hồi quy ngẫu nhiên* (stochastic recurrent neural network) với các đơn vị nhị phân ngẫu nhiên kết nối vô hướng với nhau. Bởi vì Boltzmann Machine có giới hạn quy mô nên RBM được ra đời như một cải tiến của Boltzmann Machine để việc huấn luyện được hiệu quả hơn. Đó là trong mỗi lớp, các đơn vị trong cùng một lớp không liên kết với nhau như hình 3.6.




Hình 3.6: Mô hình restricted boltzmann machine

3.3.3 Cách thức hoạt động của DBN:

DBN được xây dựng dựa trên chồng các lớp RBM với nhau, và tiếp theo là các lớp belief network. Lớp thấp nhất hay là các *đơn vị quan sát được* (visible units) sẽ nhận dữ liệu đầu vào ở dạng nhị phân hoặc số thực như hình 3.7

Quá trình huấn luyện DBN gồm có 2 bước là học không giám sát (unsupervised learning) và học có giám sát (supervised learning):



Hình 3.7: Kiến trúc mô hình DBN [30]

- Bước đầu tiên khi huấn luyện DBN là học lớp thấp nhất nhận dữ liệu đầu vào, sử dụng giải thuật *phân kỳ tương phản* (Contrastive Divergence). Sau đó, các đơn vị ẩn đã được học ở lớp trước sẽ được xem như là dữ liệu đầu vào để huấn luyện các đơn vị ẩn ở lớp tiếp theo. Quá trình sẽ được tiếp diễn cho đến lớp cuối cùng của mạng. Mỗi lớp sẽ học được cách biểu diễn đặc điểm của dữ liệu ở cấp độ cao hơn so với lớp dưới.
- Ở bước có giám sát, giải thuật lan truyền ngược được sử dụng để cập nhật các trọng số của mô hình sao cho tỷ lệ sai của kết quả đầu ra là thấp nhất.

3.4 Mạng nơ-ron tích chập - (Convolutional neural network - CNN):

Những năm gần đây, ta đã chứng kiến được nhiều thành tựu vượt bậc trong ngành Thị giác máy tính (Computer Vision). Các hệ thống xử lý ảnh lớn như Facebook, Google hay Amazon đã mang vào sản phẩm của mình những chức năng thông minh nhận diện khuôn mặt người dùng, phát triển xe hơi tự lái hay drone giao hàng tự động. *Mạng nơ-ron tích chập* là một trong những mô hình học sâu (deep learning) tiên tiến giúp cho chúng ta xây dựng được những hệ thống thông minh với độ chính xác cao như vậy.


Mô hình mạng nơ-ron tích chập được phát biểu lần đầu tiên vào năm 1988 bởi hai nhà nghiên cứu Yan-LeCun và Leon Bottou. Tác giả đã đưa ra một mô hình neural gọi là LeNet5 được dùng cho nhận dạng bộ chữ số viết tay MNIST và đã được độ chính xác ngạc nhiên vào thời điểm đó: 99.2%. Theo tác giả, mô hình mạng này lấy cảm hứng từ hệ thống neural sinh học, bắt chước cách bộ não của các động vật có vú nhận biết thế giới xung quanh chúng bằng việc các lớp kiến trúc neural đặc biệt. Kể từ đó đến nay đã có khá nhiều nghiên cứu về loại hình mạng này để áp dụng vào đời sống phục vụ con người như từ giả lập người chơi cờ vây (Go) để đánh bại kì thủ đến việc tạo ra ứng dụng phát hiện các bệnh nguy hiểm từ sớm, v.v..

Convolutional Neural Network, hay còn gọi là mạng tích chập, là một cách tổ chức khác của mạng nơ-ron được dùng trong thị giác máy tính. Cũng giống như mạng MLP, CNN cũng được tạo thành từ các nơ-ron được sắp xếp thành từng lớp, có các trọng số ghép nối và *hàm lỗi* (loss function). Và sử dụng giải thuật lan truyền ngược để huấn luyện mô hình.

Tuy nhiên, khác với MLP, ở CNN, các nơ-ron ở tầng trên chỉ kết nối với một số nơ-ron ở tầng dưới (receptive field). Vì đặc trưng của các mạng nơ-ron trong xử lý hình ảnh là dữ liệu đầu vào là các pixel của hình ảnh nên việc kết nối tất cả các nơ-ron tầng trên tới tầng dưới sẽ dẫn đến bùng nổ tham số. Hơn nữa, việc quá nhiều trọng số sẽ dễ gây ra tình trạng *quá khớp* (overfitting).

Một điểm khác nữa của CNN là việc tổ chức các nơ-ron. Do hình ảnh có các đặc trưng kích thước là chiều rộng (width), chiều cao (height), chiều sâu (depth)


nên các nơ-ron cũng sẽ được tổ chức một cách tương tự thành một khối 3D như hình 3.8.



Hình 3.8: Cách tổ chức nơ-ron của mạng CNN

3.4.1 Lớp tích chập (convolutional layer):

Lớp tích chập bao gồm một tập hợp các *bộ lọc* (filter) được áp lên dữ liệu đầu vào. Bộ lọc là thành phần chính mà các nơ-ron phải học. Sau khi áp lên dữ liệu đầu vào, bằng phép toán tích chập, bộ lọc sẽ lọc ra các đặc trưng có trong dữ liệu đó. Kích thước của bộ lọc thường nhỏ hơn kích thước ma trận biểu diễn dữ liệu đầu vào nên bộ lọc sẽ trượt trên ma trận đó để rút trích thông tin từ toàn bộ ma trận. Kết quả thu được sau khi áp tích chập giữa bộ lọc với ma trận đầu vào được là một *ma trận kích hoạt* (activations-map). Việc tích chập giữa ma trận đầu vào và bộ lọc được tiến hành bằng trích từ ma trận một khu vực (cửa sổ) các pixel có cùng kích thước với bộ lọc, sau đó thực hiện phép tích vô hướng giữa bộ lọc và cửa sổ đó. Kết quả thu được được ghi vào vị trí trung tâm của sổ trên ảnh đích. Cửa sổ sau đó sẽ được dịch chuyển một đoạn (gọi là stride) và quá trình được lặp lại cho đến khi toàn bộ ma trận được lọc như hình 3.9.




Hình 3.9: Minh họa phép tích chập của một bộ lọc 3x3

3.4.2 Lớp tổng hợp (pooling layer);

Dữ liệu sau khi được xử lý tính toán bởi các nơ-ron trong lớp tích chập sẽ sinh ra ma trận mới mới thông thường có số chiều lớn do đó phải cần chi phí lưu trữ tính toán rất lớn cho các ma trận trọng số.. Càng nhiều nơ-ron trong lớp tích chập thì lượng thông tin rút trích càng lớn nhưng số lượng tham số lưu trữ và khối lượng xử lý cũng tăng theo. Ngoài ra việc quá nhiều liên kết giữa các lớp sẽ dễ gây ra hiện tượng quá khớp, hiện tượng vượt quá điểm tối ưu của ma trận trọng số trong ANN. Để giải quyết các vấn đề trên, người ta thường sử dụng lớp tổng hợp sau các lớp tích chập. Lớp tổng hợp nhận đầu vào là dữ liệu sau khi được rút trích từ lớp tích chập, dữ liệu này nhiều lớp, mỗi lớp đại diện cho 1 đặc trưng khác nhau được rút trích từ dữ liệu đầu vào của bài toán như hình 3.10.

Lớp tổng hợp thực hiện giảm kích thước theo các chiều (trừ chiều sâu) một cách độc lập ở mỗi lớp. Việc giảm kích thước phụ thuộc vào kiểu gộp, các tham số như kích thước vùng giảm và độ dịch chuyển vùng giảm.

Lớp tổng hợp không có tham số như bộ lọc ở lớp tích chập. Thông số duy nhất của lớp này là kích thước của sổ và bước dịch chuyển. Kích thước cửa sổ (W) và bước dịch (S) thường dùng trong các mạng nơ-ron là $W = 2, S = 2$ hoặc $W = 3, S = 2$. Lớp tổng hợp không bắt buộc phải có trong CNN, nhiều công trình nghiên cứu đã tìm cách loại bỏ lớp tổng hợp trong mô hình vì cho rằng phép toán này sẽ phá hủy tính chất của dữ liệu.



Hình 3.10: Một ví dụ của tác vụ tổng hợp trên ảnh 4x4 3 channel: (i),(ii),(iii): max pooling với $W = S = 2$, (iv) max pooling với $W = 3, S = 2$

3.4.3 Lớp kết nối đầy đủ (Fully-connected layer):


Sau khi kết quả đã đạt đến kích thước là $1 \times 1 \times M$, nó sẽ được đưa qua lớp lớp kết nối đầy đủ để trích xuất thông tin. Cấu tạo và hoạt động của lớp này hoàn toàn tương tự như MLP. Ngoài ra để tránh hiện tượng quá khớp, người ta thường sử dụng phương pháp *dropout*, loại bỏ ngẫu nhiên 1 số cạnh kết nối giữa các lớp để giảm số lượng liên kết. Cuối cùng, kết quả của tầng kết nối đầy đủ này sẽ được truyền tiếp qua một lớp phân loại để được kết quả là xác suất cho mỗi lớp dự đoán. Lớp phân loại này thông thường là hàm *softmax*. Hàm softmax là một tổng của hàm logistic thành nhiều chiều. Nó được sử dụng trong hồi quy logistic đa thức và thường được sử dụng làm hàm kích hoạt cuối cùng của mạng nơ-ron để chuẩn hóa đầu ra của mạng thành phân phối xác suất của các lớp cần dự đoán.

3.5 Mạng nơ-ron hồi quy (Recurrent Neural Network - RNN) và Long Short-term memory (LSTM):

3.5.1 Mạng nơ-ron hồi quy:

RNN là một loại của mạng nơ-ron nhân tạo bao gồm các đơn vị được kết nối có hướng với nhau như một chuỗi. Trong thực tế có nhiều loại dữ liệu có sự tương hỗ ràng buộc với nhau theo thứ tự thời gian, nơi mà giá trị ở phía sau chuỗi thời gian phụ thuộc vào ngữ cảnh của một vài giá trị trước đó. Ví dụ khi chúng ta xem một bộ phim, để có thể hiểu được những diễn của bộ phim, chúng ta cần phải biết được những ngữ cảnh đã xảy ra trước đó để có thể liên kết thông tin. Điều này có nghĩa là chúng ta phải ghi nhớ được những thông tin xảy ra ở những khoảng thời gian trước đó. Với các kiến trúc mạng nơ-ron nhân tạo trước đây như CNN hay ANN, tất cả dữ liệu đầu vào là độc lập với nhau. Tuy nhiên, với thiết kế của mình, RNN có thể ghi nhớ được thông tin trước đó vì dữ liệu sẽ được đưa vào mạng theo trình tự thời gian của nó, vì vậy, RNN có thể thể hiện được mối liên hệ giữa các giá trị của dữ liệu đầu vào.

Để đạt được điều đó, RNN tạo một mạng với vòng lặp trong nó, điều này giúp nó lưu giữ các thông tin. Chúng ta có thể hình dung đây như là sao chép của cùng một mạng và nối chúng lại thành một chuỗi dài, thông tin sẽ được truyền theo thứ tự tới các mạng ở phía sau như hình 3.11.



Hình 3.11: Cấu trúc mạng RNN

Trong RNN, trạng thái ẩn (hidden state) tại mỗi bước sẽ được tính dựa trên dữ liệu đầu vào ở bước đó và thông tin thu được từ bước trước đó, giúp nó có khả năng ghi nhớ thông tin được tính toán ở những bước trước của mạng. Giải

sử $x = x_1, x_2, \dots, x_t$ đại diện một chuỗi có chiều dài là t , h_t là bộ nhớ (memory) tại thời gian t , thông tin củ mô hình RNN sẽ được cập nhật bằng công thức sau:

$$h_t = \sigma(W_x x_t + W_h h_{t-1} + b_t)$$

Trong đó σ là hàm phi tuyến tính như sigmoid, tanh,..., W_x và W_h là trọng số của ma trận, và b_t là bias

Trong những năm gần đây, RNN được sử dụng giải quyết thành công nhiều bài toán trong thực tế như: nhận diện giọng nói, dịch máy, chú thích hình ảnh,... Và phần lớn những thành công này được dựa vào một kiến trúc mạng được cải tiến từ những vấn đề tồn đọng của RNN, đó là *long short time memory* (LSTM). Vậy sự cải tiến đó là gì?

3.5.2 Vấn đề của RNN:

Ý tưởng của RNN là liên kết thông tin trước đó để biểu diễn giá trị hiện tại, ví dụ như ngữ cảnh của từ ngữ trước đó trong câu để hiểu nghĩa của từ ngữ hiện tại. Nhưng RNN không phải lúc nào cũng có thể ghi nhớ được toàn bộ thông tin.

Nếu chúng ta đang cố gắng dự đoán từ cuối trong câu "mặt trời mọc hướng đông", chúng ta sẽ không cần sử dụng nhiều ngữ cảnh của từ ngữ ở trước đó. Lúc này khoảng cách giữa ngữ cảnh và từ chúng ta cần dự đoán là không lớn, RNN có thể ghi nhớ được ngữ cảnh này. Tuy nhiên, xét câu sau "Tôi là công dân Việt Nam. Đó là đất nước tuyệt vời... Đất nước này thuộc châu Á." Rõ ràng có thể dự đoán được từ cuối cùng trong câu là châu Á, chúng ta cần phải nhớ được thông tin Việt Nam đã được nhắc đến từ lâu ở trước đó. Lúc này, khoảng cách giữa ngữ cảnh cần liên kết với từ cần dự đoán lớn, vì vậy RNN sẽ không thể lưu giữ thông tin của ngữ cảnh vì sau một chuỗi truyền thông tin dài qua các mạng, những thông tin ở xa trước đó sẽ bị triệt tiêu. Điều này đã được Bengio và các cộng sự của ông tìm ra và lý giải [4].

3.5.3 Long short term memory (LSTM):

LSTM, là một dạng đặc biệt của RNN, có khả năng học được những sự phụ thuộc trong một thời gian dài, được phát minh bởi Hochreiter và Schmidhuber [17]. LSTM được thiết kế để giải quyết vấn đề triệu tiêu thông tin của RNN. Mạng LSTM có thể gồm nhiều ô nhớ (memory cells) được kết nối với nhau đại diện thông tin theo thời gian như các nốt ẩn của RNN. Điểm chính của LSTM được gọi là *trạng thái khối* (cell state). LSTM có khả năng thêm hoặc xóa bớt thông tin của trạng thái khối thông qua các cổng. Cổng là cách để tùy chỉnh lượng thông tin được truyền trải qua. Nó kết hợp với hàm kích hoạt sigmoid, giá trị nằm giữa 0 và 1, sẽ biểu thị bao nhiêu thông tin được truyền tải qua. Khi sigmoid có giá trị 0 có nghĩa là không có chút thông tin nào được đi qua, trong khi giá trị 1 có nghĩa là tất cả thông tin được phép truyền đi tiếp. LSTM có tổng cộng 3 cổng, để điều khiển và bảo vệ trạng thái khối đó là *cổng bỏ thông tin* (forget gate), *cổng đầu vào* (input gate) và *cổng đầu ra* (output gate).

1. Cổng bỏ thông tin thực hiện nhiệm vụ xóa bỏ thông tin không cần thiết nhận được ở khối trước đó. Được biểu diễn bằng công thức 3.6. Trong đó f_t là đầu ra của cổng ở thời gian hiện tại, σ là hàm sigmoid, C_{t-1} và h_{t-1} tương ứng là trạng thái khối và đầu ra của lớp ẩn ở bước trước đó, W_f và b_f tương ứng là trọng số và bias từ lớp dữ liệu đầu vào.

$$f_t = \sigma(W_f[C_{t-1}, h_{t-1}, x_t] + b_f) \quad (3.6)$$

2. Cổng đầu vào giúp lựa chọn những thông tin cần thiết để thêm vào trạng thái khối. Cổng sẽ gồm 2 thành phần chính: lớp sigmoid và lớp tanh. Lớp sigmoid lọc những thông tin từ h_{t-1}, x_t, C_{t-1} . Lớp tanh sinh ra những giá trị sẽ được thêm vào ô nhớ LSTM. Đầu ra của 2 lớp này được tính theo công thức sau:

$$i_t = \sigma(W_i[C_{t-1}, h_{t-1}, x_t] + b_i) \quad (3.7)$$

$$\hat{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3.8)$$

Trong công thức 3.7, i_t là đầu ra của cổng đầu vào; W_i và b_i là trọng số và bias của cổng đầu vào. Và W_C , b_c trong công thức 3.8 là trọng số và bias của trạng thái khối. Trạng thái khối cũ C_{t-1} được sử dụng để cập nhật C_t . Được thực hiện bằng cách nhân trạng thái khối cũ với f_t và sau đó cộng $i_t * \hat{C}_t$ như công thức 3.9.

$$C_t = f_t * C_{t-1} + i_t * \hat{C}_t \quad (3.9)$$

3. Cổng đầu ra xác định thông tin của trạng thái khối hiện tại được sử dụng là dữ liệu đầu ra. Trong công thức 3.10 và 3.11, o_t là đầu ra của cổng đầu ra. W_o và b_o đại diện cho trọng số và bias của cổng đầu ra và h_t là đầu ra của lớp ẩn ở trạng thái hiện tại.


$$o_t = \sigma(W_o[C_t, h_{t-1}, x_t] + b_o) \quad (3.10)$$

$$h_t = o_t * \tanh(C_t) \quad (3.11)$$


Khối của LSTM được mô tả ở hình 3.12 Mạng nơ-ron LSTM sâu có nhiều hơn 1 lớp ẩn. Nó bao gồm nhiều khối LSTM với đầu ra của lớp trước là dữ liệu đầu vào của lớp tiếp theo. Kiến trúc của mạng nơ-ron LSTM được mô tả ở hình 3.13. Giả sử dữ liệu chuỗi thời gian là $x = \langle x_1, x_2, \dots, x_t \rangle$ là đầu vào của LSTM. Đầu ra của mạng LSTM tự động tính giá trị dự đoán ở bước thời gian tiếp theo sử dụng thông tin trước đó.

Mạng LSTM có thể được mở rộng cho chuỗi thời gian nhiều biến bằng cách thêm chiều ở tham số W và b .

Quá trình huấn luyện mạng RNN và LSTM cùng sử dụng giải thuật lan truyền ngược để cập nhật các trọng số của mô hình.



Hình 3.12: Trạng thái khối của LSTM [23]



Hình 3.13: Kiến trúc mô hình mạng LSTM

3.6 Auto-Encoder và mạng nơ-ron Auto-Encoder xếp chồng


Auto-Encoder (AE) là mạng nơ-ron với mục đích sao chép giá trị đầu ra sang giá trị đầu vào. Dữ liệu đầu vào sẽ được biểu diễn trong không gian tiềm ẩn (latent-space) và được phục hồi trở lại thành dữ liệu đầu ra. Kiến trúc của auto-encoder (như trong hình 3.14 sẽ gồm 2 thành phần:

1. **Encoder:** Là thành phần trích xuất và biểu diễn dữ liệu đầu vào thành giá trị trong không gian tiềm ẩn. Nó có thể được biểu diễn dưới dạng hàm:

$$h = f(x).$$

2. **Decoder:** Là thành phần khôi phục giá trị biểu diễn trong không gian tiềm ẩn trở lại giá trị đầu vào. Quá trình này có thể được biểu diễn dưới dạng:

$$r = g(h).$$



Hình 3.14: Các thành phần của mạng auto-encoder [24]


Từ đó, cả quá trình có thể được biểu diễn thành: $g(f(x)) = r$ sao cho r gần bằng giá trị dữ liệu đầu vào x . Giá trị h được kỳ vọng sẽ biểu diễn được những thông tin hữu ích cho dữ liệu đầu vào r .

AE thường được sử dụng để khử nhiễu dữ liệu và thu giảm số chiều. Với những ràng buộc số chiều của không gian tiềm ẩn hợp lý, AE có thể học cách biểu diễn dữ liệu tốt hơn các phương pháp truyền thống hoặc PCA.

Mạng nơ-ron auto-encoder xếp chồng (Stacked Auto-Encoder) là một mạng nơ-ron bao gồm nhiều lớp AE xếp chồng lên nhau với lớp đầu ra của mỗi lớp ẩn được kết nối tới lớp đầu vào của lớp ẩn kế tiếp.

Như hình 3.15 các lớp ẩn được huấn luyện bằng giải thuật học không giám sát và sau đó được tinh chỉnh bằng giải thuật có giám sát. Mạng auto-encoder xếp chồng gồm 3 bước chính:

- Huấn luyện auto-encoder sử dụng dữ liệu đầu vào và có được dữ liệu đầu ra.



Hình 3.15: Cấu trúc của mạng auto-encoder xếp chồng [24]

- Dữ liệu đầu ra từ lớp trước được sử dụng như là dữ liệu đầu vào cho lớp tiếp theo và quá trình này lặp lại đến lớp auto-encoder cuối cùng.
- Khi tất cả các lớp ẩn đã được huấn luyện, sử dụng giải thuật lan truyền ngược để tối ưu hàm chi phí và trọng số được cập nhật với tập dữ liệu huấn luyện để tiến hành quá trình tinh chỉnh.

3.7 Lý thuyết hỗn loạn

Dữ liệu chuỗi thời gian trong nhiều lĩnh vực như kinh tế, tài chính, khí tượng thủy văn, môi trường, thời tiết,... được xem như có tính chất hỗn loạn (chaotic time series). Chuỗi thời gian có tính hỗn loạn được giả định như sinh ra từ một hệ thống động tất định và phi tuyến. Dự báo dữ liệu chuỗi thời gian có tính hỗn loạn là một vấn đề đầy thách thức. Do đó để dự báo chuỗi thời gian có tính

hỗn loạn, chúng ta nên kết hợp mô hình dự báo với *lý thuyết hỗn loạn* (chaos theory). Giả sử x_t là chuỗi thời gian đơn biến, với $t = 1, 2, \dots, N$, không gian pha (phase-space) có thể được tái tạo bằng cách sử dụng phương pháp thời gian trễ [32]. Bản chất của phương pháp này là sự phát triển của bất kỳ biến đơn lẻ nào của hệ thống được xác định bởi các biến khác mà nó bị ảnh hưởng. Do đó, thông tin về các biến có liên quan được ẩn chứa trong lịch sử của bất kỳ biến đơn lẻ nào. Trên cơ sở ý tưởng này, một không gian pha tương đương có thể được xây dựng bằng cách gán một phần tử của chuỗi thời gian x_t và độ trễ liên tiếp của nó dưới dạng tọa độ của một véc-tơ mới.

$$X_t = \{x, x_{t+\tau}, x_{t+2\tau}, \dots, x_{t+(m-1)\tau}\} \quad (3.12)$$

Với X_t là những điểm trong không gian pha, τ là thời gian trễ (time delay) và m là số chiều nhúng (embedding dimension). Số chiều nhúng được cho rằng có khả năng khôi phục toàn bộ thông tin mà không bị sai lệch bất kỳ tính chất tô-pô nào của nó. Cả giá trị τ và m cần được xác định từ chuỗi thời gian.

Phương pháp thông tin hỗ tương (mutual information) do Fraser và Swinney [12] đề xuất như một công cụ hỗ tương để xác định thời gian trễ τ .

$$S = - \sum_{i,j} p_{ij}(\tau) \ln \frac{p_{ij}(\tau)}{p_i p_j} \quad (3.13)$$

Với p_i là xác suất tìm được một giá trị trong khoảng thời gian thứ i , và $p_{ij}(\tau)$ là xác suất chung để một giá trị tồn tại trong khoảng thời gian thứ i , và lần sau xuất hiện trong khoảng thời gian thứ j .

Một phương pháp để xác định số chiều nhúng được Kennel và các đồng sự [20] đề xuất. Nó được gọi là lân cận gần nhất giả (false nearest neighbor). Giả sử số chiều nhúng tối thiểu cho một chuỗi thời gian $\{x_i\}$ là m_0 . Với mỗi véc-tơ X_i trong chuỗi thời gian, chúng ta tìm lân cận gần nhất $\tilde{X}_i$ trong không gian trễ với m chiều. Chúng ta tính khoảng cách Euclid $d_m(X_i, \tilde{X}_i)$ giữa chúng trong không gian pha với m chiều. Một tiêu chí tự nhiên để bắt lỗi nhúng là sự gia tăng khoảng cách giữa X_i và $\tilde{X}_i$ lớn hơn khi đi từ chiều m sang chiều $m+1$. Sự gia tăng khoảng cách có thể được xác định bằng công thức.

$$R_i = \frac{|d_{m+1}(X_i, \tilde{X}_i) - d_m(X_i, \tilde{X}_i)|}{d_m(X_i, \tilde{X}_i)} \quad (3.14)$$

Nếu R_i với qua ngưỡng R_t thì điểm này được đánh dấu là có lân cận gần nhất giả.

Để kiểm tra một chuỗi thời là hỗn loạn hay không, số mũ Lyapunov cực đại (maximal Lyapunov exponent) cần được tính. Rosenstein và cộng sự [31] đã đề xuất phương pháp để tính số mũ cực đại Lyapunov từ chuỗi thời gian. Sau khi tái tạo lại không gian pha, một điểm x_{n0} được chọn và tất cả các điểm xung quanh x_n nhỏ hơn khoảng cách r được tìm ra và khoảng cách trung bình từ những điểm đó được tính. Quá trình này lặp lại cho N điểm theo quỹ đạo để tính đại lượng trung bình S được gọi là hệ số giãn.

$$S = \frac{1}{N} \sum_{n=n0}^N \left(\ln \frac{1}{|u_{x_{n0}}|} \sum |x_{n0} - x_n| \right) \quad (3.15)$$

Với $|u_{x_{n0}}|$ là số điểm được tìm thấy xung quanh điểm x_{n0} . Một đồ thị của hệ số kéo dài S so với số điểm N sẽ tạo ra một đường cong với sự gia tăng tuyến tính lúc đầu, tiếp theo là một vùng gần như phẳng. Một đường bình phương nhỏ nhất phù hợp với độ dốc của phần tuyến tính của đường cong sẽ giúp ước lượng về số mũ Lyapunov lớn nhất. Một chuỗi thời gian sẽ có tính hỗn loạn nếu số mũ Lyapunov cực đại của nó là một giá trị dương.

Chương 4

Phương pháp giải quyết vấn đề

Ở chương này chúng tôi trình bày phương pháp tiếp cận gồm quá trình xử lý dữ liệu, phân tích tính hỗn loạn của dữ liệu và mô hình đề xuất.

4.1 Phân tích dữ liệu

Các bộ dữ liệu thực nghiệm của bài toán dự báo này là tỉ giá giao dịch trong lịch sử, được tải từ trang web [1] của ngân hàng Dukascopy, một ngân hàng lớn của Thụy Sĩ. Tập dữ liệu này bao gồm giao dịch được thực hiện mỗi ngày và các giá trị lúc mở, đóng phiên giao dịch cũng như giá trị cao nhất và thấp nhất trong ngày. Giá trị đóng phiên giao dịch sẽ là mục tiêu dự đoán của mô hình được xây dựng. Vì vậy, bài toán này là bài toán dự báo chuỗi thời gian đa biến. Dữ liệu bài toán được mô tả như sau:

$$X = (x_L, x_H, x_O, x_C)$$

Với x_L , x_H , x_O , x_C tương ứng là giá trị tỉ giá cao nhất, thấp nhất, mở phiên và đóng phiên trong một ngày giao dịch. Từ đó, giá trị của n ngày giao dịch được biểu diễn:


$$x = \{x_j(i) \in R, i = 1, 2, \dots, n\} (j \in \{L, H, O, C\}).$$

Từ giá trị giao dịch của những ngày trong quá khứ, mục tiêu của đề tài nghiên cứu là dự báo giá trị đóng phiên của những ngày tiếp theo tức là:


$$x_C(t+s+1), x_C(t+s+2), \dots, x_C(t+s+k) = \hat{f}(x_j(t), x_j(t+1), \dots, x_j(t+s))$$

Với $j \in \{L, H, O, C\}$, $t = 1, 2, \dots, n - k - s$, s là số ngày trong quá khứ được sử dụng để dự báo kết quả trong tương lai, k là số ngày trong tương lai được dự báo.


Chúng tôi tiến hành thử nghiệm trên 7 bộ dữ liệu là tỉ giá giữa đồng Úc và đô-la Mỹ (AUD/USD), tỉ giá đồng e-rô và đô-la Mỹ (EUR/USD), tỉ giá đồng New Zealand và đô-la Mỹ (NZD/USD), tỉ giá đồng đô-la Mỹ và Canada, tỉ giá đồng Thụy Sĩ và Yên (CHF/JPY), tỉ giá đồng bảng Anh và đô-la Mỹ (GBP/USD), tỉ giá đồng đô-la Mỹ và Yên (USD/JPY). Phân bố giá trị đóng cửa của các tập dữ liệu được thể hiện qua các boxplot như trong hình 4.1, 4.2, 4.3, 4.4, 4.5, 4.6, 4.7:




Hình 4.1: Phân bố dữ liệu của tỉ giá AUD/USD theo năm




Hình 4.2: Phân bố dữ liệu của tỉ giá EUR/USD theo năm




Hình 4.3: Phân bố dữ liệu của tỉ giá NZD/USD theo năm




Hình 4.4: Phân bố dữ liệu của tỉ giá USD/CAD theo năm



Hình 4.5: Phân bố dữ liệu của tỉ giá CHF/JPY theo năm



Hình 4.6: Phân bố dữ liệu của tỉ giá GBP/USD theo năm



Hình 4.7: Phân bố dữ liệu của tỉ giá USD/JPY theo năm

Từ các biểu đồ, chúng tôi thấy rằng các tập dữ liệu tỉ giá biến động phức tạp qua từng năm, đặc biệt các tập CHF/JPY, GBP/USD, USD/JPY có những thời gian tỉ quá biến động rất mạnh. Chẳng hạn như, USD/JPY trong thời gian từ năm 2012 đến năm 2015 tỉ giá tăng mức trung bình năm 2012 là 80 lên đến 120 vào năm 2015, tức là tăng khoảng 50%. Tương tự, tỉ giá CHF/JPY cũng tăng

đáng kể từ năm 2012 đến năm 2015. Trong khi đó, tỉ giá GBP/USD giảm mạnh vào năm 2009, với mức giảm hơn 21% từ giá trị trung bình năm 2008 khoảng 1.95 xuống 1.6 vào năm 2009. Bên cạnh đó, các tỉ giá AUD/USD, EUR/USD, NZD/USD có xu hướng ổn định hơn với mức độ tăng giảm nhỏ và ít có những năm biến động đột biến.

Xét về các giá trị dữ liệu bất thường ở mỗi năm, giá trị vượt quá 1,5 lần so với giá trị 2 giá trị một phần tư trong năm (IQR), các tập dữ liệu AUD/USD, EUR/USD, NZD/USD, GBP/USD ít hơn đáng kể so với 3 tập dữ liệu còn lại. Tập dữ liệu GPB/USD, NZD/USD tỉ lệ giá trị bất thường tương đối ít. Bên cạnh đó, tỉ giá USD/CAD có nhiều giá trị giao dịch cao hơn $1.5 \cdot \text{IQR}$ ở các năm 2008 và năm 2016. Tỉ giá USD/JPY, giá trị bất thường xuất hiện nhiều ở các năm 2014, 2013. Và tỉ giá CHF/JPY, các năm 2006, 2014, 2017 đóng phiên giao dịch với nhiều giá trị bất thường.

Ngoài ra, dữ liệu báo tỉ giá ngoại tệ thường khó khăn vì dữ liệu thường có tính hỗn loạn (chaos). Vì vậy, chúng tôi áp dụng lý thuyết hỗn loạn (chaos theory) vào phân tích dữ liệu. Chúng tôi sử dụng kỹ thuật thông tin hỗ tương (mutual information) để xác định giá trị thời gian trễ τ . Theo công thức 3.13, giá trị nhỏ nhất của mutual information giúp xác định τ . Để xác định số chiều nhúng m , kỹ thuật false nearest neighbor được áp dụng. Và để kiểm tra dữ liệu có hỗn loạn hay không, chúng tôi sử dụng số mũ Lyapunov cực đại để phân tích. Và kết quả, chúng tôi phát hiện 3 tập dữ liệu GPB/USD, CHF/JPY, USD/JPY có tính chất của chuỗi thời gian hỗn loạn với số mũ Lyapunov cực đại dương. Do đó, khi áp dụng lý thuyết hỗn loạn vào dự báo thì dữ liệu đầu vào và đầu ra được biểu diễn như sau:

$$x_C(t+1) = \hat{f}(x_j(t), x_j(t-\tau), \dots, x_j(t-(m-1)\tau))$$

Với $j \in \{L, H, O, C\}, t = 1, 2, \dots, n - (m-1)\tau$.

4.2 Đề xuất mô hình

Mạng LSTM có khả năng học sự phụ thuộc giá trị theo một chuỗi thời gian và xử lý tốt những vấn đề bùng nổ và triệt tiêu gradient nên phù hợp xử lý cho


bài toán chuỗi thời gian. Bên cạnh đó, autoencoder là một cách học với mục tiêu giá trị đầu ra bằng giá trị đầu vào. Tức là, autoencoder có khả năng lọc và giữ những thông tin cần thiết của dữ liệu đầu vào, vì vậy nó có thể tái tạo lại giá trị đầu ra giống với dữ liệu đầu vào.

Hai ý tưởng trên thúc đẩy chúng tôi xây dựng một mô hình kết hợp ưu điểm của hai mạng nơ-ron sâu: autoencoder và LSTM để dự báo tỉ giá ngoại tệ như sau. Mô hình đầu tiên sử dụng autoencoder với kiến trúc LSTM để tự động trích xuất thông tin và sau đó sử dụng mô hình LSTM để dự báo giá trị đóng phiên giao dịch trong tương lai. Mô hình autoencoder sẽ được cất ở phần code và mô hình dự báo LSTM được chồng lên. Chúng tôi gọi mô hình này là AELSTM (Autoencoder combined with LSTM network).

Cụ thể là, mô hình LSTM của chúng tôi được xây dựng đơn giản với encoder là một lớp LSTM kết hợp với một lớp LSTM đóng vai trò decoder. Mỗi lớp encoder và decoder bao gồm nhiều khối LSTM liên kết với nhau. Mô hình autoencoder dựa trên LSTM được sử dụng để học những đặc trưng và loại bỏ những thông tin nhiễu để xây dựng lại dữ liệu đầu vào, vì vậy dữ liệu đầu ra mong muốn chính là dữ liệu đầu vào ban đầu. Mô hình dự báo dựa trên LSTM là một mạng nơ-ron gồm 2 lớp LSTM đóng vai trò trích xuất thông tin và 2 lớp fully-connected ở phía sau có nhiệm vụ dự báo giá trị tiếp theo. Đặc trưng được trích xuất từ lớp encoder của mô hình autoencoder được kết hợp với dữ liệu ban đầu trước khi đưa vào mô hình dự báo như hình 4.8. Chúng tôi sử dụng kỹ thuật này bởi vì kết hợp thông tin trích xuất và dữ liệu gốc sẽ giúp cho dữ liệu đưa vào mô hình dự báo được đa dạng và đảm bảo không bị mất thông tin.

Phương pháp chúng tôi đề xuất AELSTM giống một phần nào đó với tinh thần của phương pháp SAE-LSTM được đề xuất bởi Li và các cộng sự năm 2018 [23] và Bao [3]. Tuy nhiên có 2 điểm chính trong nghiên cứu của chúng tôi khác với những công trình trước đó.

1. SAE-LSTM sử dụng autoencoder có kiến trúc là những mạng nơ-ron MLP truyền thống, trong khi đó, AELSTM sử dụng các khối LSTM.
2. Trong mô hình chúng tôi đề xuất, thông tin được trích xuất từ encoder được ghép với đặc điểm của dữ liệu gốc trước khi đi qua mô hình dự đoán LSTM kết quả tiếp theo.



Hình 4.8: Kiến trúc mô hình đề xuất

Ngoài ra chúng tôi kết hợp thêm lý thuyết hỗn loạn vào phân tích dữ liệu và huấn luyện mô hình AELSTM. Phương pháp này được ký hiệu là tAELSTM.

Chương 5

Kết quả thực nghiệm

Chương này trình bày các tiêu chí đánh giá, quá trình hiện thực các thực nghiệm cho mô hình đề xuất và các mô hình đối sánh cũng như phân tích kết quả thực nghiệm đạt được.

Môi trường thực nghiệm:

- Hệ điều hành: Ubuntu 18.04
- Ngôn ngữ: Python3
- Framework: Keras 2.2.4 với nhân là Tensorflow và các thư viện như: numpy, pandas, sklearn
- Cấu hình máy tính: Intel(R) Core(TM) i5-8365U CPU @ 1.60GHz

5.1 Tiêu chí đánh giá

Kết quả dự đoán của mô hình sẽ được đo và so sánh dựa trên ba độ lỗi là *sai số tuyệt đối trung bình* (mean absolute error - MAE), *sai số bình phương trung bình* (mean square error - MSE) và *sai số phần trăm tuyệt đối trung bình* (mean absolute percentage error - MAPE).

Mean absolute error: Là thước đo mức độ sai lệch của dự báo mà không xem xét tới hướng của chúng. Được tính trung bình sự khác biệt tuyệt đối giữa giá trị dự báo và giá trị quan sát thực tế của các mẫu thử nghiệm trong đó tất cả các khác biệt có trọng số bằng nhau.

$$\mathbf{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad (5.1)$$

Root mean squared error: Cũng là một thước đo mức độ sai số của kết quả dự báo. Mức độ sai lệch bằng căn bậc hai của trung bình tổng bình phương sự khác biệt giữa dự đoán và thực tế.

$$\mathbf{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (5.2)$$

Mean absolute percentage error: Đo độ chính xác theo phần trăm và được tính bằng phần trăm của trung bình tổng sai số tuyệt đối giữa giá trị dự đoán và giá trị thực tế chia cho giá trị thực.


$$\mathbf{MAPE} = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (5.3)$$

Trong công thức 5.1, 5.2, 5.3, y_t là giá trị thực và $\hat{y}_t$ là giá trị dự báo.


Cả 3 độ đo đều là điểm số định hướng tiêu cực, có nghĩa là giá trị thấp hơn là tốt hơn. Trong đó, MAE chỉ đơn thuần là thể hiện sự sai số của giá trị dự đoán so với giá trị thực. Và RMSE với việc bình phương độ lỗi trước khi trung bình, giúp cho độ đo này có trọng số lớn đối với những sai lệch lớn. Tức là chỉ với một vài giá trị dự đoán sai lệch lớn so với giá trị thực tế cũng có thể làm cho độ lỗi RMSE lớn mặc dù những giá trị khác được dự đoán khớp với giá trị thực. Tuy nhiên, cả hai thước đo MAE và RMSE trong nhiều trường hợp có thể lớn mà không nói lên được ý nghĩa mô hình là tốt hay xấu. Ví dụ, giá trị của MAE là 10 có nghĩa là gì? Điều này tốt hay xấu? Để biết được điều này chúng ta cần phải so sánh nó với mô hình khác. Không những thế, cả hai độ đo này còn phụ thuộc vào độ lớn của tập dữ liệu, vì nó dựa trên sự khác biệt giữa giá trị dự đoán và giá trị thực. Ví dụ, nếu chúng ta xây dựng mô hình cho công ty tỷ đô thì độ lỗi của mô hình sẽ lớn rất nhiều so với mô hình được xây dựng cho công ty triệu đô. Trong những trường hợp này, độ đo MAPE có thể được sử dụng bởi vì độ đo này thể hiện phần trăm của độ lỗi so với giá trị thực.

5.2 Thực nghiệm


Trong thực nghiệm, chúng tôi sử dụng dữ liệu giao dịch hằng ngày từ năm 1999 đến năm 2019, riêng tập dữ liệu CHF/JPY là từ năm 2003 đến năm 2019. Tập dữ liệu được chia thành các phần huấn luyện (training), kiểm định (validation), thử (testing) với tỉ lệ lần lượt là 80%, 10%, 10%. Hình 5.1, 5.2, 5.3, 5.4, 5.5, 5.6, 5.7 thể hiện giá trị đóng cửa của mỗi tập dữ liệu, và 3 màu khác nhau trên hình vẽ chỉ 3 phần dữ liệu được chia thành: huấn luyện, kiểm định, thử.




Hình 5.1: Phân chia tập dữ liệu AUD/USD thành các phần huấn luyện, kiểm định, thử.




Hình 5.2: Phân chia tập dữ liệu EUR/USD thành các phần huấn luyện, kiểm định, thử.




Hình 5.3: Phân chia tập dữ liệu NZD/USD thành các phần huấn luyện, kiểm định, thử.




Hình 5.4: Phân chia tập dữ liệu USD/CAD thành các phần huấn luyện, kiểm định, thử.



Hình 5.5: Phân chia tập dữ liệu CHF/JPY thành các phần huấn luyện, kiểm định, thử.



Hình 5.6: Phân chia tập dữ liệu GBP/USD thành các phần huấn luyện, kiểm định, thử.



Hình 5.7: Phân chia tập dữ liệu USD/JPY thành các phần huấn luyện, kiểm định, thử.

Ngoài thực hiện phương pháp đề xuất AELSTM, chúng tôi còn tiến hành hiện thực các kiến trúc mạng DBN, ANN, CNN, LSTM, SAELSTM [23] để so sánh với phương pháp đề xuất. Ở mỗi phương pháp chúng tôi tiến hành tìm các kiến trúc và các siêu tham số phù hợp với tập dữ liệu bằng phương pháp thử

sai như số ngày trong quá khứ được sử dụng để dự đoán giá trị trong tương lai (windown size), hệ số học (learning rate),.... Ngoài ra, với các tập dữ liệu có tính chất hỗn loạn, chúng tôi sử dụng thông số thời gian trễ τ và số chiều nhúng m để khởi tạo không gian dữ liệu trước khi đưa vào mô hình và được ký hiệu là tAELSTM, như bảng 5.2. Trong quá trình huấn luyện chúng tôi sử dụng hàm tối ưu Adam với learning rate là $5e-4$. Kiến trúc của các mô hình thực nghiệm như bảng 5.1, với ký hiệu $L(n)$ có nghĩa là lớp L với n nốt. Ví dụ, LSTM(128) có nghĩa là lớp LSTM với 128 nốt:

	EUR/USD, AUD/USD, USD/CAD, NZD/USD	GBP/USD	USD/JPY	CHF/JPY
DBN	RBM(24) - RBM(12)	RBM(50) - RBM(22)	RBM(32) - RBM(16)	RBM(32) - RBM(12)
ANN	FC(12) - FC(12)	FC(64) - FC(32) - FC(16)	FC(32) - FC(16)	FC(24) - FC(12)
CNN	Conv(64) -	Conv(128) -	Conv(64) -	Conv(32) -
	MaxPooling -	MaxPooling -	MaxPooling -	MaxPooling -
	Dropout(0,2) -	Dropout(0,3) -	Dropout(0,2) -	Dropout(0,2) -
	Conv(16) -	Conv(64) -	Conv(32) -	Conv(16) -
	MaxPooling - FC(16) - FC(16)	MaxPooling - FC(32) - FC(16)	MaxPooling - FC(16) - FC(16)	MaxPooling - FC(16) - FC(16)
LSTM	LSTM(128) - LSTM(128) - FC(16)	LSTM(128) - LSTM(128) - FC(16) - FC(16)	LSTM(128) - LSTM(64) - FC(16)	LSTM(64) - LSTM(64) - FC(32)
SAE-LSTM	- AutoEncoder: FC(50) - FC(12)	- AutoEncoder: FC(50) - FC(12)	- AutoEncoder: FC(50) - FC(20)	- AutoEncoder: FC(50) - FC(12)
	- Forcaster: LSTM(128) - LSTM(32)	- Forcaster: LSTM(128) - LSTM(64)	- Forcaster: LSTM(128) - LSTM(32)	- Forcaster: LSTM(128) - LSTM(32)
	- AutoEncoder: LSTM(128) - LSTM(32)	- AutoEncoder: LSTM(128) - LSTM(32)	- AutoEncoder: LSTM(128) - LSTM(64)	- AutoEncoder: LSTM(128) - LSTM(32)
AELSTM	- Forcaster: LSTM(128) - LSTM(128) - FC(32) - FC(16)	- Forcaster: LSTM(128) - LSTM(64) - FC(32) - FC(16)	- Forcaster: LSTM(128) - LSTM(64) - FC(32) - FC(8)	- Forcaster: LSTM(64) - LSTM(128) - FC(32) - FC(8)

Bảng 5.1: Kiến trúc của các mô hình tương ứng với từng bộ dữ liệu thực nghiệm.

	USD/JPY	CHF/JPY	GBP/USD
τ	20	103	13
m	12	5	17

Bảng 5.2: Tham số của các tập dữ liệu tỉ giá ngoại tệ có tính chất hỗn loạn

5.3 Kết quả thực nghiệm

Kết quả của các mô hình khi dự báo đơn bước, tức là dự báo giá trị đóng phiên của 1 ngày tiếp theo ($k=1$) được thể hiện qua các bảng 5.3, 5.4, 5.5.

MAE	EUR/USD	AUD/USD	NZD/USD	USD/CAD	GBP/USD	USD/JPY	CHF/JPY
DBN	0.08064	0.06954	0.02714	0.02696	0.30939	4.20756	13.08751
ANN	0.11006	0.04222	0.08351	0.06029	0.04860	3.48454	10.92446
CNN	0.00904	0.04324	0.02874	0.04293	0.01396	5.96476	3.73773
LSTM	0.00623	0.00592	0.00499	0.00788	0.01150	2.10764	12.95697
SAE-LSTM	0.00677	0.00432	0.00487	0.00530	0.03412	0.61692	0.53780
AELSTM	0.00344	0.00276	0.00254	0.00426	0.03383	0.37870	0.46714
tAELSTM	-	-	-	-	0.01489	0.34110	0.34230

Bảng 5.3: Độ lỗi MAE của 7 bộ dữ liệu khi k=1

RMSE	EUR/USD	AUD/USD	NZD/USD	USD/CAD	GBP/USD	USD/JPY	CHF/JPY
DBN	0.08624	0.07424	0.03125	0.03130	0.31261	4.75298	13.25677
ANN	0.12979	0.05027	0.10115	0.06723	0.05806	4.00648	11.11678
CNN	0.01114	0.04425	0.03032	0.04455	0.01738	6.07523	3.90413
LSTM	0.00783	0.00730	0.00616	0.00969	0.01426	2.70316	13.11952
SAE-LSTM	0.00935	0.00613	0.00652	0.00785	0.04084	0.88800	0.76272
AELSTM	0.00464	0.00378	0.00350	0.00567	0.04272	0.50978	0.60669
tAELSTM	-	-	-	-	0.02028	0.45648	0.46305

Bảng 5.4: Độ lỗi RMSE của 7 bộ dữ liệu khi k=1

Với các tập dữ liệu không có tính chất hỗn loạn là EUR/USD, AUD/USD, NZD/USD, USD/CAD, các phương pháp sử dụng mô hình mạng nơ-ron học sâu cho kết quả chính xác hơn so với mô hình ANN truyền thống. Ngoại trừ tập AUD/USD, ANN cho kết quả tốt hơn phương pháp DBN với MAPE lần lượt là 5.92328 và 9.65140. Với khả năng ưu việt của mình đối với dữ liệu chuỗi thời gian, phương pháp LSTM cho kết quả vượt trội hơn hẳn so với các phương pháp DBN, ANN, CNN, điều đó được thể hiện rõ ở độ đo MAPE. Ví dụ như LSTM cho kết quả sai số 0.80995 so với 5.85975 của phương pháp CNN ở bộ dữ liệu AUD/USD. Khi kết hợp phương pháp auto-encoder, các mô hình SAE-LSTM và AELSTM cải thiện kết quả dự báo hơn so với những phương pháp còn lại. Tuy nhiên, phương pháp SAE-LSTM cho kết quả dự báo không quá chênh lệch so với phương pháp LSTM. Chẳng hạn như với bộ dữ liệu USD/CAD, SAE-LSTM có độ lỗi MAPE là 0.41219 so với 0.60573 của phương pháp LSTM. Phương pháp AELSTM cho kết quả dự báo vượt trội hơn so với tất cả phương pháp ở trên cả 3 độ lỗi, với sai số giảm khoảng 2 lần so với phương pháp LSTM và SAE-LSTM.

MAPE	EUR/USD	AUD/USD	NZD/USD	USD/CAD	GBP/USD	USD/JPY	CHF/JPY
DBN	7.03701	9.65140	4.05500	2.05151	23.71784	3.77356	11.72422
ANN	12.18927	5.92328	15.39032	4.57413	3.76057	3.12361	9.78524
CNN	0.77927	5.85975	4.17289	3.28666	1.0688	5.39861	3.36194
LSTM	0.53735	0.80995	0.73166	0.60573	0.88891	1.93891	11.61209
SAE-LSTM	0.57460	0.57635	0.71565	0.41219	2.66357	0.55215	0.47901
AELSTM	0.29531	0.37636	0.37141	0.32732	2.62478	0.34393	0.41924
tAELSTM	-	-	-	-	1.13371	0.30983	0.30450

Bảng 5.5: Độ lỗi MAPE của 7 bộ dữ liệu khi $k=1$

Ví dụ, AELSTM cho kết quả dự báo với MAPE là 0.29531 so với 0.57460 và 0.53735 của phương pháp SAE-LSTM và LSTM.

Với các tập dữ liệu có tính chất hỗn loạn là GBP/USD, USD/JPY, CHF/JPY, kết quả dự báo ở các phương pháp có nhiều thay đổi. Cụ thể, phương pháp DBN dự báo thiếu chính xác hơn so với phương pháp ANN ở cả 3 tập dữ liệu, đặc biệt ở tập GBP/USD có độ lỗi MAPE rất lớn là 23.71784. Ở tập dữ liệu USD/JPY, phương pháp CNN có sai số lớn nhất với giá trị MAPE là 5.39861. Trong khi đó, LSTM là phương pháp thiếu chính xác thứ hai sau phương pháp DBN với tập dữ liệu CHF/JPY với sai số MAPE là 11.61209. Trên 2 tập USD/JPY, CHF/JPY, các phương pháp LSTM kết hợp với auto-encoder vẫn là những kết quả dự báo tốt hơn những phương pháp còn lại. Trong đó, phương pháp AELSTM kết hợp với lý thuyết hỗn loạn cho kết quả dự báo chính xác cao nhất với sai số MAPE lần lượt là 0.30983 và 0.30450. Mặc dù vậy, ở 2 tập dữ liệu này sai số trên cả 3 độ đo đều còn lớn, chứng tỏ các mô hình chưa xử lý tốt với những bộ dữ liệu này. Đặc biệt, đối với tập dữ liệu GBP/USD, các phương pháp LSTM kết hợp với auto-encoder bao gồm cả tAELSTM cho kết quả dự báo kém hơn so với phương pháp LSTM.

Ngoài ra, chúng tôi còn tiến hành thí nghiệm cho bài toán dự báo nhiều bước, tức là chúng tôi dự báo kết quả đóng cửa của 7 ngày kế tiếp trong tương lai ($k=7$). Độ lỗi MAE, RMSE, MAPE lần lượt được thể hiện qua các bảng 5.6, 5.7, ??.

Với dự báo nhiều bước (multistep ahead prediction) trên các tập EUR/USD, AUD/USD, NZD/USD, USD/CAD, hầu hết các phương pháp cho kết quả dự

MAE	EUR/USD	AUD/USD	NZD/USD	USD/CAD
DBN	0.11872	0.05099	0.02294	0.07929
ANN	0.03877	0.01368	0.01335	0.01562
CNN	0.04649	0.04012	0.02436	0.07757
LSTM	0.00633	0.00624	0.00600	0.00887
SAE-LSTM	0.00581	0.00545	0.00497	0.00681
AELSTM	0.00534	0.00542	0.00410	0.00621

Bảng 5.6: Độ lỗi MAE của 4 bộ dữ liệu khi k=7


RMSE	EUR/USD	AUD/USD	NZD/USD	USD/CAD
DBN	0.12218	0.06007	0.02963	0.08530
ANN	0.04439	0.01846	0.01631	0.01959
CNN	0.04886	0.04118	0.02617	0.08089
LSTM	0.008161	0.00789	0.00746	0.01110
SAE-LSTM	0.00768	0.00708	0.00644	0.00905
AELSTM	0.00725	0.00699	0.00559	0.00837

Bảng 5.7: Độ lỗi RMSE của 4 bộ dữ liệu khi k=7


báo với độ chính xác thấp hơn khi dự báo đơn bước. Mặc dù phương pháp AELSTM vẫn cho kết quả dự báo với sai số nhỏ nhất, nhưng cách biệt so với phương pháp SAE-LSTM là không lớn như khi dự báo đơn bước.

Các hình 5.8, 5.9, 5.10, 5.11, 5.12, 5.13, 5.14 biểu thị kết quả dự báo (màu đỏ) giá trị đóng cửa với so giá trị thực tế (màu xanh) của các tập dữ liệu bằng phương pháp AELSTM. Với các tập dữ liệu không có tính chất hỗn loạn, kết quả dự báo tương đối khớp với dữ liệu thực tế. Các tập CHF/JPY, GBP/USD mô hình AELSTM dự báo chưa tốt với độ lệch giữa đường dự báo và đường giá trị thực tế lớn.


MAPE	EUR/USD	AUD/USD	NZD/USD	USD/CAD
DBN	10.3051	7.15280	3.27986	6.03078
ANN	3.39062	1.88589	1.95554	1.19692
CNN	3.99272	5.44608	3.54348	4.75023
LSTM	0.56333	0.85277	0.87947	0.68280
SAE-LSTM	0.54909	0.74448	0.75830	0.56490
AELSTM	0.54481	0.74051	0.74719	0.55500

Bảng 5.8: Độ lỗi MAPE của 4 bộ dữ liệu khi $k=7$ 


Hình 5.8: Kết quả dự báo của tỉ giá AUD/USD bằng mô hình AELSTM




Hình 5.9: Kết quả dự báo của tỉ giá EUR/USD bằng mô hình AELSTM




Hình 5.10: Kết quả dự báo của tỉ giá NZD/USD bằng mô hình AELSTM




Hình 5.11: Kết quả dự báo của tỉ giá USD/CAD bằng mô hình AELSTM



Hình 5.12: Kết quả dự báo của tỉ giá CHF/JPY bằng mô hình AELSTM



Hình 5.13: Kết quả dự báo của tỉ giá GBP/USD bằng mô hình AELSTM



Hình 5.14: Kết quả dự báo của tỉ giá USD/JPY bằng mô hình AELSTM

Chương 6

Kết luận

6.1 Kết quả đạt được

Qua nghiên cứu này, chúng tôi một lần nữa khẳng định với khả năng lưu nhớ thông tin trong quá khứ và mối quan hệ tương hỗ giữa các biến thể hiện giá trị giao dịch trong lịch sử, mạng nơ-ron học sâu LSTM thể hiện khả năng vượt trội của mình so với các kiến trúc mạng nơ-ron học sâu khác như DBN, CNN. Và auto-encoder thể hiện được khả năng trích xuất đặc trưng hiệu quả bằng việc giúp cho các mô hình kết hợp với auto-encoder đạt được kết quả dự báo chính xác hơn.

Từ đó, chúng tôi đề xuất phương pháp mới AELSTM kết hợp giữa auto-encoder dựa trên kiến trúc LSTM (LSTM-based AutoEncoder) có nhiệm vụ trích xuất thông tin cần thiết và loại bỏ những thông tin nhiễu từ tập dữ liệu ban đầu và một mô hình dự báo LSTM có chức năng dự đoán kết quả tương lai. Sự khác biệt giữa mô hình của chúng tôi và các mô hình khác ở 2 điểm chính:

1. Thông tin giá trị đóng phiên, cao nhất, thấp nhất phiên giao dịch kết hợp với dữ liệu được trích ra từ lớp encoder của mô hình auto-encoder. Điều này giúp dữ liệu khi được đưa vào mô hình dự báo LSTM vừa mang được những thông tin cần thiết và mang được những thông tin liên quan hỗ trợ quyết định đưa ra giá trị dự báo chính xác.
2. Với bộ dữ liệu có tính hỗn loạn, chúng tôi kết hợp mô hình AELSTM với lý thuyết hỗn loạn.

Chúng tôi thực nghiệm phương pháp đề xuất trên 7 bộ dữ liệu tỉ giá ngoại tệ AUD/USD, EUR/USD, NZD/USD, USD/CAD, GBP/USD, USD/JPY, CHF/JPY. Phương pháp của chúng tôi đề xuất cho kết quả dự báo tốt hơn những phương pháp đối sánh như ANN, DBN, CNN, LSTM, SAE-LSTM với các tập dữ liệu tỉ giá ngoại tệ không có tính hỗn loạn với cả dự báo đơn bước và đa bước. Chỉ riêng bộ dữ liệu tỉ giá ngoại tệ GBP/USD, phương pháp AELSTM thuần túy và kết hợp cả lý thuyết hỗn loạn đều cho kết quả không tốt bằng LSTM. Điều này chứng tỏ, không có phương pháp nào tốt cho tất cả các tập dữ liệu, khi sử dụng thực tế cần chọn những phương pháp phù hợp với từng tập dữ liệu cụ thể.

6.2 Hướng nghiên cứu tiếp theo

Ở nghiên cứu này, chúng tôi giả sử giá trị trong tương lai hoàn toàn phụ thuộc vào những thông tin giao dịch trong quá khứ. Tuy nhiên trong thực tế, tỉ giá ngoại tệ chịu tác động của rất nhiều thông tin khác nhau, ví dụ như các thông tin về chính trị, kinh tế, xã hội,... Vì vậy để kết quả dự báo chính xác hơn, chúng ta cần phải kết hợp thêm những thông tin này vào trong các yếu tố quyết định giá trị tương lai.

Bài báo công bố khoa học

Tran Van Hoa, Duong Tuan Anh and Duong Ngoc Hieu, "Foreign Exchange Rate Forecasting using Autoencoder and LSTM Networks", International Conference on Intelligent Information Technology, 25-28 Feb, 2021.

Hội được tổ chức vào ngày 25-28/02/2021 tại thành phố Hồ Chí Minh.

Bài báo sẽ được xuất bản vào khoảng 05/2021 trên kỷ yếu sau đây: Conference Proceedings by ACM (ISBN: 978-1-4503-8894-8), được lập chỉ mục bởi Ei Compendex và Scopus.

Tài liệu tham khảo

- [1] Historical data feed :: Dukascopy bank sa: Swiss forex bank: Ecn broker: Managed accounts: Swiss fx trading platform: Available at: <https://www.dukascopy.com/swiss/english/marketwatch/historical/> [accessed 12 dec. 2019].
- [2] Yaser S. Abu-Mostafa and Amir F. Atiya. Introduction to financial forecasting. *Applied Intelligence*, 6(3):205–213, Jul 1996.
- [3] Wei Bao, Jun Yue, and Yulei Rao. A deep learning framework for financial time series using stacked autoencoders and long-short term memory. *PloS one*, 12(7):e0180944, 2017.
- [4] Yoshua Bengio, Patrice Simard, Paolo Frasconi, et al. Learning long-term dependencies with gradient descent is difficult. *IEEE transactions on neural networks*, 5(2):157–166, 1994.
- [5] Omer Berat Sezer and Ahmet Murat Ozbayoglu. Financial trading model with stock bar chart image time series with deep convolutional neural networks. *arXiv*, pages arXiv–1903, 2019.
- [6] BIS. Triennial central bank survey foreign exchange turnover in april 2013 : preliminary global results. www.bis.org/publ/rpfx13fx.pdf, 2013.
- [7] George EP Box, Gwilym M Jenkins, Gregory C Reinsel, and Greta M Ljung. *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.
- [8] Ding-Zhou Cao, Su-Lin Pang, and Yuan-Huai Bai. Forecasting exchange rate using support vector machines. In *2005 International Conference on Machine Learning and Cybernetics*, volume 6, pages 3448–3452. IEEE, 2005.

-
- [9] Jing Chao, Furao Shen, and Jinxi Zhao. Forecasting exchange rate with deep belief networks. In *The 2011 International Joint Conference on Neural Networks*, pages 1259–1266. IEEE, 2011.
 - [10] Zhengping Che, Sanjay Purushotham, Kyunghyun Cho, David Sontag, and Yan Liu. Recurrent neural networks for multivariate time series with missing values. *Scientific reports*, 8(1):6085, 2018.
 - [11] Christian L Dunis and Mark Williams. Applications of advanced regression analysis for trading and investment. *Applied quantitative methods for trading and investment*, pages 1–40, 2003.
 - [12] Andrew M Fraser and Harry L Swinney. Independent coordinates for strange attractors from mutual information. *Physical review A*, 33(2):1134, 1986.
 - [13] Svitlana Galeshchuk and Sumitra Mukherjee. Deep networks for predicting direction of change in foreign exchange rates. *Intelligent Systems in Accounting, Finance and Management*, 24(4):100–110, 2017.
 - [14] Felix A Gers, Douglas Eck, and Jürgen Schmidhuber. Applying lstm to time series predictable through time-window approaches. In *Neural Nets WIRN Vietri-01*, pages 193–200. Springer, 2002.
 - [15] Geoffrey E Hinton, Simon Osindero, and Yee-Whye Teh. A fast learning algorithm for deep belief nets. *Neural computation*, 18(7):1527–1554, 2006.
 - [16] Geoffrey E Hinton and Ruslan R Salakhutdinov. Reducing the dimensionality of data with neural networks. *science*, 313(5786):504–507, 2006.
 - [17] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
 - [18] Qiang Jiang, Chenglin Tang, Chen Chen, Xin Wang, and Qing Huang. Stock price forecast based on lstm neural network. In *International Conference on Management Science and Engineering Management*, pages 393–408. Springer, 2018.
 - [19] Fazle Karim, Somshubra Majumdar, Houshang Darabi, and Shun Chen. Lstm fully convolutional networks for time series classification. *IEEE Access*, 6:1662–1669, 2017.

- [20] Matthew B Kennel, Reggie Brown, and Henry DI Abarbanel. Determining embedding dimension for phase-space reconstruction using a geometrical construction. *Physical review A*, 45(6):3403, 1992.
- [21] Yann LeCun, Y Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436–44, 05 2015.
- [22] Honglak Lee, Roger Grosse, Rajesh Ranganath, and Andrew Y Ng. Convolutional deep belief networks for scalable unsupervised learning of hierarchical representations. In *Proceedings of the 26th annual international conference on machine learning*, pages 609–616. ACM, 2009.
- [23] Zhenbo Li, Fang Peng, Bingshan Niu, Guangyao Li, Jing Wu, and Zheng Miao. Water quality prediction model combining sparse auto-encoder and lstm network. *IFAC-PapersOnLine*, 51(17):831–836, 2018.
- [24] Guifang Liu, Huaiqian Bao, and Baokun Han. A stacked autoencoder-based deep neural network for achieving gearbox fault diagnosis. *Mathematical Problems in Engineering*, 2018, 2018.
- [25] Pankaj Malhotra, Lovekesh Vig, Gautam Shroff, and Puneet Agarwal. Long short term memory networks for anomaly detection in time series. In *Proceedings*, page 89. Presses universitaires de Louvain, 2015.
- [26] Paraschos Maniatis. Forecasting the exchange rate between euro and usd: Probabilistic approach versus arima and exponential smoothing techniques. *Journal of Applied Business Research (JABR)*, 28(2):171–192, 2012.
- [27] Lukas Menkhoff and Mark P Taylor. The obstinate passion of foreign exchange professionals: Technical analysis. *Journal of Economic Literature*, 45:936–972, 12 2007.
- [28] Tomáš Mikolov, Martin Karafiát, Lukáš Burget, Jan Černocký, and Sanjeev Khudanpur. Recurrent neural network based language model. In *Eleventh annual conference of the international speech communication association*, 2010.

- [29] Ashok K Nag and Amit Mitra. Forecasting daily foreign exchange rates using genetically optimized neural networks. *Journal of Forecasting*, 21(7):501–511, 2002.
- [30] Junfei Qiao, Gongming Wang, Wenjing Li, and Xiaoli Li. A deep belief network with plsr for nonlinear system modeling. *Neural Networks*, 104:68–79, 2018.
- [31] Michael T Rosenstein, James J Collins, Carlo J De Luca, et al. Reconstruction expansion as a geometry-based framework for choosing proper delay times. *Physica-Section D*, 73(1):82–98, 1994.
- [32] Floris Takens. Detecting strange attractors in turbulence. In *Dynamical systems and turbulence, Warwick 1980*, pages 366–381. Springer, 1981.
- [33] Z Tang and PA Fishwick. Back-propagation neural nets as models for time series forecasting. *ORSA journal on computing*, 5(4):374–385, 1993.
- [34] Hannah Thinyane and Jonathan Millin. An investigation into the use of intelligent systems for currency trading. *Computational Economics*, 37(4):363–374, 2011.
- [35] Yun-Cheng Tsai, Jun-Hao Chen, and Jun-Jie Wang. Predict forex trend via convolutional neural networks. *Journal of Intelligent Systems*, 2018.
- [36] Jung-Hua Wang and Jia-Yann Leu. Stock market trend prediction using arima-based neural networks. In *Proceedings of International Conference on Neural Networks (ICNN’96)*, volume 4, pages 2160–2165. IEEE, 1996.
- [37] Max Welling, Michal Rosen-Zvi, and Geoffrey E Hinton. Exponential family harmoniums with an application to information retrieval. In *Advances in neural information processing systems*, pages 1481–1488, 2005.

Phụ lục A

Bảng đối chiếu thuật ngữ Anh - Việt

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt	Viết tắt
Time Series	Chuỗi thời gian	
Time Series Forecasting	Dự báo chuỗi thời gian	
Univariate Time Series	Chuỗi thời gian đơn biến	
Multivariate Time Series	Chuỗi thời gian đa biến	
Artificial Neural Network	Mạng nơ-ron nhân tạo	ANN
Deep Belief Network		DBN
Convolutional Neural Network	Mạng nơ-ron tích chập	CNN
Recurrent Neural Network	Mạng nơ-ron hồi quy	RNN
Long Short-time Memory		LSTM
Cell State	Trạng thái khối	
Forget Gate	Cổng bỏ thông tin	
Input Gate	Cổng đầu vào	
Output Gate	Cổng đầu ra	
Vanishing Gradient	Triệt tiêu gradient	
Exploding Gradient	Bùng nổ gradient	
Chaos Theory	Lý thuyết hỗn loạn	
Phase Space	Không gian pha	

Time Delay	Thời gian trễ	
Embedding Dimension	Số chiều nhúng	
Mutual Information	Thông tin chung	
False Nearest Neighbour	Lân cận gần nhất giả	
Non-parametric	Phi tham số	
Restricted Boltzmann Machine	Máy Boltzmann giới hạn	RBM
Fully Convolutional Network	Mạng tích chập đầy đủ	FCN
Mean Absolute Error	Sai số tuyệt đối trung bình	MAE
Mean Square Error	Sai số bình phương trung bình	MSE
Mean Absolute Percentage Error	Sai số phần trăm tuyệt đối trung bình	MAPE
Training Set	Tập huấn luyện	
Validation set	Tập kiểm định	
Testing Set	Tập thử	
Multistep Ahead Prediction	Dự báo nhiều bước	
Back Propagation	Lan truyền ngược	
Forward Propagation	Lan truyền thuận	

Lý Lịch Trích Ngang

Họ và tên: Trần Văn Hòa

Ngày sinh: 01/01/1995

Nơi sinh: Quảng Ngãi

Địa chỉ liên lạc: 66 Mỹ Huề, ấp Mỹ Huề, xã Trung Chánh, huyện Hóc Môn, thành phố Hồ Chí Minh.

Quá Trình Đào Tạo

Thời gian	Trường đào tạo	Chuyên ngành	Trình độ đào tạo
2013-2018	Đại Học Bách Khoa Tp. Hồ Chí Minh	Khoa học máy tính	Kỹ sư
2018-2020	Đại Học Bách Khoa Tp. Hồ Chí Minh	Khoa học máy tính	Thạc sĩ

Quá Trình Công Tác

Thời gian	Đơn vị công tác	Vị trí
1/2018 - 8/2018	Axon Active VietNam	Kỹ sư trí tuệ nhận tạo
8/2018 - Nay	Công ty cổ phần VNG	Kỹ sư trí tuệ nhận tạo